

# TRABAJO DE FIN DE GRADO

Grado en Ingeniería de Computadores

ESCUELA POLITÉCNICA SUPERIOR

Desarrollo y validación de plataforma experimental para  
el entrenamiento de exoesqueletos robóticos mediante  
aprendizaje por refuerzo

Carlos Eguren Esteban

Tutora: Ana Jiménez Martín

Cotutor: David Rodríguez Cianca

2026



# Agradecimientos

Me gustaría agradecer a todas las personas que han hecho posible la realización de este trabajo.

En primer lugar, gracias a la Universidad de Alcalá y a Ana Jiménez, tutora académica de este trabajo, por haber ayudado a que este proyecto se haya podido llevar a cabo y por su apoyo durante todo el proceso. Además, mi total agradecimiento a Luis de la Cruz por su ayuda y su sacrificio buscando al profesor que me pudiera tutelar.

Gracias a todo el grupo de investigación NAIR del CSIC del cual he formado parte durante la realización de este trabajo. Pablo, André, Adriana, Paula, Damián, Clara, Lucía, Abián, Javier, Fernando y, en especial, a mi tutor externo David Rodríguez por su comprensión, ayuda y paciencia durante todo el proceso de realización de este trabajo, y a Andrés, por su ayuda, su apoyo, su tiempo y sus consejos. Gracias a todos por haberme hecho sentir parte del grupo y por haberme ayudado a crecer profesionalmente y, más importante, personalmente.

Para terminar, gracias a mi familia por su apoyo incondicional desde siempre, su perseverancia y su esfuerzo en lograr de mí una mejor persona. Gracias a mis amigos por su apoyo, su comprensión y por haberme ayudado a desconectar de este trabajo cuando lo necesitaba.



# Resumen

El uso de exoesqueletos en humanos tiene como objetivo mejorar la calidad de vida de las personas, ya sea para ayudar a la movilidad de personas con discapacidad o para aumentar la fuerza y resistencia de personas sanas. En este trabajo se expone el desarrollo y la validación de una plataforma experimental para el entrenamiento de exoesqueletos robóticos mediante aprendizaje por refuerzo. Se presenta el diseño de un modelo musculoesquelético simplificado de cadera, su transferencia a hardware real, el entrenamiento en simulación de un agente con la base de ese modelo musculoesquelético para controlar un exoesqueleto y el despliegue de ese agente.

**Palabras clave:** Aprendizaje por refuerzo, Exoesqueletos robóticos, *Dummy*, Modelos musculoesqueléticos, Seguimiento de trayectorias.



# Abstract

The use of exoskeletons in humans aims to improve people's quality of life, either to help the mobility of people with disabilities or to increase the strength and endurance of healthy people. This work presents the development and validation of an experimental platform for training robotic exoskeletons using reinforcement learning. The project describes the design of a simplified musculoskeletal model of the hip, its transfer to real hardware, the simulation training of an agent based on that musculoskeletal model to control an exoskeleton, and the deployment of that agent.

**Keywords:** Reinforcement learning, Robotic exoskeletons, *Dummy*, Musculoskeletal models, Path following.



# Resumen extendido

A pesar de que el uso de exoesqueletos en humanos tiene como objetivo mejorar la calidad de vida de las personas, ya sea para ayudar a la movilidad de personas con discapacidad o para aumentar la fuerza y resistencia de personas sanas, el desarrollo de estos sistemas es un reto complejo. A estos efectos, el desarrollo de algoritmos de control basados en inteligencia artificial para exoesqueletos es un área de investigación activa. Además, debido a la complejidad de los sistemas, el desarrollo de estos algoritmos requiere de simulaciones y largos períodos de pruebas en entornos controlados antes de su despliegue en un exoesqueleto real.

Sin embargo, el entrenamiento de estos algoritmos de control requiere de un gran número de interacciones con el entorno, lo que hace que el entrenamiento en un exoesqueleto real sea inviable. Por ello, es necesario crear simulaciones biorealistas que permitan entrenar los algoritmos de control de manera eficiente y segura. El uso de simulaciones con modelos musculoesqueléticos tiene varias ventajas notables, como la posibilidad de realizar pruebas y entrenamientos sin riesgo para el usuario, la capacidad de ajustar parámetros y condiciones de manera rápida y sencilla, y la posibilidad de generar grandes cantidades de datos para el entrenamiento de algoritmos de inteligencia artificial.

Aún así, debido al conocido *sim-to-real gap*, una vez validado este algoritmo en simulación, es necesario tener la certeza de que ese sistema de control funcionará correctamente en un entorno real, porque si no lo hace correctamente, podría poner en riesgo la seguridad del usuario. Por ello, es necesario establecer un sistema intermedio entre simulación y este entorno real, que permita validar el comportamiento del algoritmo de control antes de su despliegue real con usuarios. Es aquí donde nace el concepto de *dummy*, un sistema hardware que simula las características dinámicas y el comportamiento de personas reales con el objetivo de facilitar pruebas con los algoritmos desarrollados en entornos no simulados.

Este proyecto se centra en el desarrollo de una plataforma que permita el entrenamiento y evaluación de exoesqueletos en condiciones de seguridad para el ser humano. Esta plataforma se compone de un *dummy* robótico que imita la morfología y dinámica del cuerpo humano, cuyos movimientos están regidos por un modelo musculoesquelético digital del cuerpo humano. Este modelo musculoesquelético simulado genera patrones de marcha en simulación imitando la dinámica de los músculos humanos, y que son posteriormente transformados en comandos de actuación para el *dummy*, obteniendo un control musculoesquelético para el *dummy*. Posteriormente, y como caso de uso de la plataforma, se plantea la implementación, entrenamiento y evaluación de un controlador de asistencia de la marcha de un exoesqueleto de cadera por medio de técnicas de aprendizaje por refuerzo.

Para ello, se ha simplificado un modelo musculoesquelético de la literatura científica. Haciendo uso de dicho modelo musculoesquelético y desarrollando un algoritmo de control, se ha conseguido simular la marcha humana y la generación de patrones de activación muscular, además del par utilizado para el control de ambas caderas. Se presenta la transferencia de este algoritmo a hardware real.

Para que esta transferencia funcione correctamente, es necesario que el *dummy* sea capaz de simular el comportamiento de un usuario real, lo que requiere de un diseño y desarrollo cuidadoso del sistema.

Se debe recrear el peso, dimensiones y características articulares del usuario para que el *dummy* pueda simular su comportamiento de manera efectiva. Es aquí donde aparece el modelo musculoesquelético desarrollado. Este modelo permite analizar fuerzas, movimientos y patrones de activación muscular, lo que es crucial para el desarrollo de algoritmos de control efectivos para exoesqueletos. Además, debido a que es un modelos simulado, este permite realizar pruebas y entrenamientos sin riesgo para el usuario, lo que es especialmente importante en el desarrollo de exoesqueletos para personas con problemas físicos.

Posteriormente, este modelo musculoesquelético es utilizado para el entrenamiento de un agente de control basado en aprendizaje por refuerzo, para así mejorar la asistencia que un exoesqueleto de cadera proporciona al usuario durante la marcha. El agente de control es entrenado en simulación, y utilizando el modelo musculoesquelético como entorno de entrenamiento, se valida su desempeño en simulación y posteriormente el agente es desplegado en el *dummy* de cadera para validar su desempeño en un entorno físico, estableciendo las bases para el despliegue del agente de control en un exoesqueleto real.

# Índice general

|                                                                                              |          |
|----------------------------------------------------------------------------------------------|----------|
| Agradecimientos                                                                              | iii      |
| Resumen                                                                                      | v        |
| Abstract                                                                                     | vii      |
| Resumen extendido                                                                            | ix       |
| Índice general                                                                               | xi       |
| Índice de figuras                                                                            | xv       |
| Índice de tablas                                                                             | xix      |
| <b>1 Introducción</b>                                                                        | <b>1</b> |
| 1.1 Motivación . . . . .                                                                     | 2        |
| 1.2 Objetivos . . . . .                                                                      | 3        |
| 1.2.1 Objetivo general . . . . .                                                             | 3        |
| 1.2.2 Objetivos específicos . . . . .                                                        | 3        |
| 1.3 Antecedentes . . . . .                                                                   | 3        |
| 1.4 Estructura del documento . . . . .                                                       | 4        |
| <b>2 Estado del Arte</b>                                                                     | <b>7</b> |
| 2.1 Aprendizaje por refuerzo para exoesqueletos . . . . .                                    | 7        |
| 2.1.1 Introducción . . . . .                                                                 | 7        |
| 2.1.2 Fundamentos del Aprendizaje por Refuerzo . . . . .                                     | 8        |
| 2.1.3 Aprendizaje por refuerzo en robótica de rehabilitación . . . . .                       | 9        |
| 2.1.4 Principales líneas de investigación . . . . .                                          | 10       |
| 2.1.5 Desafíos abiertos . . . . .                                                            | 13       |
| 2.1.6 Tendencias recientes . . . . .                                                         | 15       |
| 2.2 Réplicas robóticas del cuerpo humano para el estudio y mejora de exoesqueletos robóticos | 16       |
| 2.2.1 Introducción . . . . .                                                                 | 16       |
| 2.2.2 Réplicas robóticas de miembro inferior . . . . .                                       | 17       |
| 2.2.3 Sustitutos robóticos para validación biomecánica . . . . .                             | 18       |
| 2.2.4 Bancos de ensayo y validación experimental . . . . .                                   | 18       |
| 2.2.5 Limitaciones y perspectivas . . . . .                                                  | 19       |
| 2.3 Control neuromusculoesquelético . . . . .                                                | 20       |
| 2.3.1 Introducción . . . . .                                                                 | 20       |
| 2.3.2 Convergencia de la biomecánica y el aprendizaje profundo . . . . .                     | 20       |
| 2.3.3 Herramientas de código abierto . . . . .                                               | 21       |

|          |                                                                                                                       |           |
|----------|-----------------------------------------------------------------------------------------------------------------------|-----------|
| 2.3.4    | Desafíos abiertos y limitaciones . . . . .                                                                            | 23        |
| <b>3</b> | <b>Materiales y métodos</b>                                                                                           | <b>25</b> |
| 3.1      | Control basado en modelos musculoesqueléticos para motores eléctricos . . . . .                                       | 26        |
| 3.1.1    | Modelo musculoesquelético MIMo . . . . .                                                                              | 26        |
| 3.1.2    | Control de un motor eléctrico basado en el modelo musculoesquelético . . . . .                                        | 29        |
| 3.2      | Control de cadera de un <i>dummy</i> bio-inspirado basado en el modelo musculoesquelético . . . . .                   | 32        |
| 3.2.1    | <i>Dummy</i> de cadera bio-inspirado . . . . .                                                                        | 32        |
| 3.2.2    | Implementación del modelo musculoesquelético en Scone . . . . .                                                       | 33        |
| 3.2.3    | Interfaz gráfica de control . . . . .                                                                                 | 36        |
| 3.3      | Entrenamiento de un exoesqueleto de cadera usando aprendizaje por refuerzo . . . . .                                  | 41        |
| 3.3.1    | Entrenamiento en tarea de asistencia del exoesqueleto usando Aprendizaje por Refuerzo . . . . .                       | 42        |
| 3.3.2    | Despliegue del agente entrenado . . . . .                                                                             | 47        |
| 3.4      | Métricas de evaluación de marcha . . . . .                                                                            | 49        |
| <b>4</b> | <b>Resultados y discusión</b>                                                                                         | <b>53</b> |
| 4.1      | Resultados del control de motores eléctricos basados en modelos musculoesqueléticos . . . . .                         | 53        |
| 4.1.1    | Seguimiento de trayectoria de marcha con un modelo musculoesquelético . . . . .                                       | 53        |
| 4.1.2    | Transferencia del modelo musculoesquelético a un motor real . . . . .                                                 | 55        |
| 4.2      | Control de <i>dummy</i> de pruebas basado en el modelo musculoesquelético . . . . .                                   | 56        |
| 4.2.1    | Resultados del episodio con el modelo musculoesquelético en Scone . . . . .                                           | 57        |
| 4.2.2    | Control del <i>dummy</i> con el modelo musculoesquelético de Scone . . . . .                                          | 59        |
| 4.3      | Resultados del despliegue del agente entrenado . . . . .                                                              | 61        |
| 4.3.1    | Análisis del entrenamiento . . . . .                                                                                  | 61        |
| 4.3.2    | Resultados del entrenamiento del agente en el entorno de simulación . . . . .                                         | 63        |
| 4.3.3    | Resultados del despliegue del controlador en el entorno real . . . . .                                                | 64        |
| <b>5</b> | <b>Conclusiones y trabajos futuros</b>                                                                                | <b>67</b> |
| 5.1      | Conclusiones . . . . .                                                                                                | 67        |
| 5.1.1    | Desarrollo de un modelo musculoesquelético de cadera capaz de seguir trayectorias de marcha humana . . . . .          | 67        |
| 5.1.2    | Transferencia del modelo musculoesquelético al <i>dummy</i> real y control de sus caderas . . . . .                   | 67        |
| 5.1.3    | Entrenamiento del agente por medio de técnicas de aprendizaje por refuerzo para el control de exoesqueletos . . . . . | 68        |
| 5.1.4    | Despliegue del agente entrenado en un sistema físico real . . . . .                                                   | 68        |
| 5.1.5    | Conclusión final . . . . .                                                                                            | 69        |
| 5.2      | Limitaciones del trabajo . . . . .                                                                                    | 69        |
| 5.3      | Trabajos futuros . . . . .                                                                                            | 69        |
|          | <b>Bibliografía</b>                                                                                                   | <b>71</b> |
|          | <b>Apéndice A Presupuesto</b>                                                                                         | <b>77</b> |
|          | <b>Apéndice B Manual de despliegue</b>                                                                                | <b>81</b> |
| B.1      | Descarga e instalación de dependencias . . . . .                                                                      | 81        |
| B.2      | Ejecución del proyecto . . . . .                                                                                      | 83        |
| B.2.1    | Simulación del modelo MIMo en MUJoCo y transferencia a hardware . . . . .                                             | 83        |
| B.2.2    | Entrenamiento e inferencia del agente de aprendizaje por refuerzo . . . . .                                           | 83        |

|                                                                      |           |
|----------------------------------------------------------------------|-----------|
| B.2.3  Lanzamiento de la interfaz gráfica de usuario (GUI) . . . . . | 84        |
| <b>Apéndice C  Planificación temporal del proyecto</b>               | <b>85</b> |



# Índice de figuras

|     |                                                                                                                                                                                                                                                                                                                                                                             |    |
|-----|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 2.1 | Configuración usual de un sistema de aprendizaje por refuerzo. Figura obtenida de [13]. Se observa que el agente ( <i>Controller</i> ) recibe observaciones ( <i>State</i> ) del entorno ( <i>System</i> ), selecciona una acción ( <i>Action</i> ) y recibe una recompensa ( <i>Reward</i> ). . . . .                                                                      | 9  |
| 2.2 | Ambas imágenes extraídas de [18]. . . . .                                                                                                                                                                                                                                                                                                                                   | 11 |
| 2.3 | Resultados sobre el coste metabólico del trabajo de Choi et al. (2026). Figura obtenida de [19]. La figura a muestra el coste metabólico sin el uso de exoesqueletos, con exoesqueleto de rodilla y con exoesqueleto de cadera a distintas velocidades de marcha. La figura b muestra el coste metabólico medio al andar (parte superior) y al correr (parte inferior). . . | 12 |
| 2.4 | Resultados del experimento de "Luo et al. (2024)"[22]. Se muestra un diagrama de caja comparando el coste metabólico del usuario al andar, correr y subir escaleras, tanto sin usar el exoesqueleto como con el exoesqueleto con y sin asistencia. . . . .                                                                                                                  | 12 |
| 2.5 | Robot PETMAN en una cinta de correr. Imagen extraída de [33]. . . . .                                                                                                                                                                                                                                                                                                       | 17 |
| 2.6 | Leg Replica. En ella podemos observar las articulaciones de cadera y tobillo (en azul, ambas con 3 grados de libertad), y la articulación de rodilla (en rojo, con 1 grado de libertad). Imagen extraída de [35]. . . . .                                                                                                                                                   | 18 |
| 2.7 | Brazo robótico. Cuenta con 4 motores para simular los movimientos de codo y de muñeca. Imagen extraída de [38]. . . . .                                                                                                                                                                                                                                                     | 19 |
| 2.8 | Interfaz de Opensim con varios modelos musculoesqueléticos. En uno de ellos se observa un exoesqueleto de tobillo. Imagen extraída de [49]. . . . .                                                                                                                                                                                                                         | 21 |
| 2.9 | Ejemplos de modelos humanos desarrollados en MuJoCo y Scone. . . . .                                                                                                                                                                                                                                                                                                        | 22 |
| 3.1 | Diagrama del flujo de trabajo seguido en el proyecto. En color verde se muestra el flujo de trabajo realizado en MuJoCo, en color naranja el trabajo realizado en Scone y en color azul las partes realizadas en el mundo real, tanto con los motores AK60-6 como con el <i>dummy</i> de cadera y sus motores AK80-9. . . . .                                               | 25 |
| 3.2 | Evolución del modelo MIMo utilizado en el simulador MuJoCo. La figura 3.2a muestra el modelo original, mientras que la figura 3.2b muestra el modelo simplificado. . . . .                                                                                                                                                                                                  | 26 |
| 3.3 | Límites de movimiento para las caderas en el modelo MIMo simplificado. . . . .                                                                                                                                                                                                                                                                                              | 27 |
| 3.4 | Comienzo de posiciones objetivo de cada cadera. La línea azul representa la posición objetivo de la cadera derecha, y la línea naranja representa la posición objetivo de la cadera izquierda. Obtenida a partir de Winter (1991) y Perry y Burnfield (2010). . . . .                                                                                                       | 28 |
| 3.5 | Esquema de control utilizado en MuJoCo con el fin de mover el modelo musculoesquelético. . . . .                                                                                                                                                                                                                                                                            | 28 |

|      |                                                                                                                                                                                                                                                                                                                                                                                                                            |    |
|------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 3.6  | Vista frontal del <i>CANdle</i> . Se observa el puerto de conexión USB-C para la conexión al ordenador personal. . . . .                                                                                                                                                                                                                                                                                                   | 30 |
| 3.7  | Ecosistema de MAB Robotics con dispositivos hardware. Se muestra tanto el diagrama de conexión del motor AK60-6 con el dispositivo <i>CANdle</i> como el ecosistema real completo. .                                                                                                                                                                                                                                       | 30 |
| 3.8  | Diagrama de la comunicación con el motor AK60-6 mediante ROS2. . . . .                                                                                                                                                                                                                                                                                                                                                     | 31 |
| 3.9  | <i>Dummy</i> de pruebas. Se observa que dentro del torso se encuentran las baterías para alimentar todo el circuito. . . . .                                                                                                                                                                                                                                                                                               | 32 |
| 3.10 | Motor AK80-9. Figura obtenida de la página web de MAB Robotics [62]. . . . .                                                                                                                                                                                                                                                                                                                                               | 33 |
| 3.11 | Vista lateral del <i>dummy</i> de pruebas con los límites de movimiento para sus caderas. . . .                                                                                                                                                                                                                                                                                                                            | 34 |
| 3.12 | Diagrama del flujo de entrenamiento de un agente de aprendizaje por refuerzo. . . . .                                                                                                                                                                                                                                                                                                                                      | 34 |
| 3.13 | Modelo musculoesquelético en Scone. Se muestran en azul los músculos del modelo, concretamente el glúteo mayor y el iliopsoas de cada cadera. . . . .                                                                                                                                                                                                                                                                      | 35 |
| 3.14 | Modelo musculoesquelético en Scone y el <i>dummy</i> robótico. . . . .                                                                                                                                                                                                                                                                                                                                                     | 35 |
| 3.15 | Pantalla principal de la interfaz gráfica desarrollada. . . . .                                                                                                                                                                                                                                                                                                                                                            | 36 |
| 3.16 | Interfaz gráfica con el panel de impedancia funcionando y gráficas de posición, velocidad y par en tiempo real. . . . .                                                                                                                                                                                                                                                                                                    | 37 |
| 3.17 | Interfaz gráfica con el panel del simulador con entorno MIMo. . . . .                                                                                                                                                                                                                                                                                                                                                      | 37 |
| 3.18 | Salida de la simulación desde la interfaz. En el fondo de la imagen la ventana de la interfaz gráfica desarrollada, y en primer plano la ventana del simulador MuJoCo con el modelo MIMo simplificado. . . . .                                                                                                                                                                                                             | 38 |
| 3.19 | Interfaz gráfica del panel de entrenamiento. Se observa el selector de episodios y el selector de la frecuencia de guardado del agente. Además, se muestra un panel con la salida del terminal de la ejecución de un entrenamiento. . . . .                                                                                                                                                                                | 39 |
| 3.20 | Visualización de datos de los motores mediante la herramienta PlotJuggler. . . . .                                                                                                                                                                                                                                                                                                                                         | 41 |
| 3.21 | Modelo musculoesquelético con exoesqueleto en Scone. . . . .                                                                                                                                                                                                                                                                                                                                                               | 42 |
| 3.22 | Interfaz de la aplicación de Scone con el modelo musculoesquelético. De izquierda a derecha: explorador de archivos, editor de texto, visualización del modelo musculoesqueletico con el exoesqueleto acoplado, y visualización de las propiedades del modelo. En la parte inferior se encuentra una gráfica con las variables de interés en tiempo real. . . . .                                                          | 48 |
| 4.1  | Resultados obtenidos en la simulación de seguimiento de la trayectoria de marcha en MuJoCo. Las gráficas, de arriba a abajo: posición actual y posición objetivo de ambas caderas, torque aplicado en las articulaciones de ambas caderas, activaciones musculares de la cadera derecha y activaciones musculares de la cadera izquierda. . . . .                                                                          | 54 |
| 4.2  | Resultados de seguimiento de trayectoria de marcha de cadera en el motor real en base a comandos de par calculados por el modelo musculoesquelético en MuJoCo. La gráfica superior muestra la posición objetivo y real del motor, mientras que la gráfica inferior muestra el par aplicado en el motor, que se corresponde con el par de la cadera derecha de la simulación en MuJoCo mostrada en la figura 4.1.1. . . . . | 56 |

|      |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    |    |
|------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 4.3  | Comparativa del error de posición de la figura 4.2. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        | 57 |
| 4.4  | Esquema de control utilizado en Scone. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                     | 57 |
| 4.5  | Desempeño del modelo musculoesquelético sin la influencia del agente. En la primera gráfica se muestra la posición objetivo y la posición real de ambas caderas, mientras que en la segunda gráfica se muestra la velocidad objetivo y la velocidad real de ambas caderas. La tercera gráfica muestra la activación de cada uno de los músculos. El eje X de las 3 gráficas representa un paso de tiempo de 0,01 segundos. . . . .                                                                                                                 | 58 |
| 4.6  | Diagrama de flujo de control del <i>dummy</i> de pruebas. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                  | 59 |
| 4.7  | Resultados obtenidos al lanzar la inferencia sin aplicar par del agente entrenado. La columna izquierda representa los resultados de la cadera izquierda, y de forma similar para la columna derecha. La primera fila muestra la posición real y objetivo de la cadera, la segunda fila muestra la velocidad real y objetivo de la cadera, y la tercera fila muestra el par aplicado en la cadera. . . . .                                                                                                                                         | 60 |
| 4.8  | Esquema de control utilizado en Scone. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                     | 61 |
| 4.9  | Evolución de la recompensa obtenida por el agente durante el proceso de entrenamiento. El eje horizontal representa el episodio de entrenamiento. El eje vertical de la gráfica izquierda representa la recompensa obtenida por el agente en ese episodio concreto, mientras que el eje vertical de la gráfica derecha representa la recompensa máxima hasta ese episodio. . .                                                                                                                                                                     | 62 |
| 4.10 | Desempeño del agente en el episodio 2000 del entrenamiento en simulación. El eje horizontal representa los pasos del episodio. Cada paso corresponde con 0,01 segundos. La gráfica superior izquierda muestra las posiciones objetivo y reales de ambas caderas, mientras que la gráfica superior derecha muestra las velocidades objetivo y reales de ambas caderas. La gráfica inferior izquierda muestra las activaciones musculares, y por último, la gráfica inferior derecha muestra el par aplicado por el agente en ambas caderas. . . . . | 63 |
| 4.11 | Resultados obtenidos al lanzar la inferencia en el <i>dummy</i> de pruebas aplicando par del agente entrenado. En la primera fila se muestran la posición real y objetivo de ambas caderas, mientras que en la segunda fila se muestra el par aplicado por el controlador PID utilizado (verde), el par calculado por el agente entrenado (morado) y el par total aplicado (naranja). La columna izquierda muestra los resultados de la cadera izquierda, mientras que la columna derecha muestra los resultados de la cadera derecha. . . . .     | 65 |
| 4.12 | Comparativa de error de posición entre controlador PID únicamente y aplicando el par calculado por el agente entrenado. Datos obtenidos a partir de los experimentos detallados en la sección 4.2.2 y la sección 4.3.3, ambos en el entorno real con el <i>dummy</i> de pruebas. .                                                                                                                                                                                                                                                                 | 66 |
| C.1  | Diagrama de Gantt del proyecto mostrando las tareas principales y la duración estimada de cada una. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                        | 85 |



# Índice de tablas

|     |                                                                                                                                                                                                                                                                                                                                                                                                                                                                  |    |
|-----|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 3.1 | Ganancias del controlador PID de la cadera simulada en MuJoCo. . . . .                                                                                                                                                                                                                                                                                                                                                                                           | 29 |
| 3.2 | Masa de los componentes del <i>dummy</i> . . . . .                                                                                                                                                                                                                                                                                                                                                                                                               | 33 |
| 3.3 | Dimensiones de los componentes del <i>dummy</i> . . . . .                                                                                                                                                                                                                                                                                                                                                                                                        | 33 |
| 3.4 | Parámetros de control para ambos motores al grabar datos desde la interfaz de usuario. .                                                                                                                                                                                                                                                                                                                                                                         | 40 |
| 3.5 | Pesos de cada término de la función de recompensa. . . . .                                                                                                                                                                                                                                                                                                                                                                                                       | 44 |
| 3.6 | Comparación de algoritmos de aprendizaje por refuerzo. . . . .                                                                                                                                                                                                                                                                                                                                                                                                   | 46 |
| 3.7 | Configuración del entrenamiento del agente de aprendizaje por refuerzo. . . . .                                                                                                                                                                                                                                                                                                                                                                                  | 47 |
| 3.8 | Ganancias del controlador PID de la cadera del <i>dummy</i> . . . . .                                                                                                                                                                                                                                                                                                                                                                                            | 48 |
| 4.1 | Resultados obtenidos en la simulación de seguimiento de la trayectoria de marcha en MuJoCo. Se muestran métricas de posición para visualizar el error de seguimiento de trayectoria, tanto los valores absolutos como los porcentuales. Además, se muestran métricas de par para visualizar el par aplicado en ambas caderas, y métricas de activación media para visualizar la activación media de los músculos flexores y extensores de ambas caderas. . . . . | 55 |
| 4.2 | Resultados numéricos obtenidos con el envío del par generado en la simulación de MuJoCo al motor real. . . . .                                                                                                                                                                                                                                                                                                                                                   | 56 |
| 4.3 | Resultados del modelo musculoesquelético sin la influencia del agente. . . . .                                                                                                                                                                                                                                                                                                                                                                                   | 58 |
| 4.4 | Resultados del control del <i>dummy</i> de pruebas únicamente con el modelo musculoesquelético de Scone y el controlador PID. . . . .                                                                                                                                                                                                                                                                                                                            | 60 |
| 4.5 | Pesos de cada término de la función de recompensa. . . . .                                                                                                                                                                                                                                                                                                                                                                                                       | 62 |
| 4.6 | Resultados del agente en el episodio 2000 del entrenamiento en simulación. . . . .                                                                                                                                                                                                                                                                                                                                                                               | 63 |
| 4.7 | Resultados de la inferencia del agente entrenado en el entorno real con el <i>dummy</i> de pruebas. .                                                                                                                                                                                                                                                                                                                                                            | 64 |
| A.1 | Precio aproximado de los recursos humanos utilizados en el proyecto. . . . .                                                                                                                                                                                                                                                                                                                                                                                     | 77 |
| A.2 | Precios aproximados de los materiales hardware utilizados en el proyecto. . . . .                                                                                                                                                                                                                                                                                                                                                                                | 78 |
| A.3 | Precios aproximados de los materiales software utilizados en el proyecto. . . . .                                                                                                                                                                                                                                                                                                                                                                                | 78 |
| A.4 | Coste total aproximado del proyecto. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                     | 79 |



# Capítulo 1

## Introducción

Un exoesqueleto es un robot acoplado a una extremidad del cuerpo humano cuyo objetivo es aumentar su rendimiento de alguna forma. La principal aplicación de esta tecnología es en el ámbito militar, aunque cada vez está más presente en la industria o en la medicina [1], y aunque lleva años creciendo, se estima que en los próximos años su cuota de mercado aumentará un 1,724.7% [2]. En esta última área, resulta especialmente importante el desarrollo de robots avanzados para la rehabilitación o la asistencia diaria porque estos dispositivos tienen una gran capacidad para mejorar la calidad de vida de la población.

Aún así, el desarrollo de exoesqueletos es un área de investigación activa y en constante evolución. La mejora de la asistencia que estos dispositivos proporcionan a los usuarios es un objetivo clave y, al mismo tiempo, es un reto importante debido a la complejidad de la interacción entre el exoesqueleto y el cuerpo humano. En este contexto, la medición de las interacciones físicas y la adaptación del comportamiento del exoesqueleto a las necesidades individuales de cada usuario son aspectos fundamentales para lograr una asistencia efectiva y segura. Sin embargo, cuantificar estas interacciones y adaptar el comportamiento del exoesqueleto de manera óptima es un desafío complejo que requiere enfoques innovadores, técnicas avanzadas de control y la participación activa de sujetos de prueba.

En este sentido, las técnicas de inteligencia artificial, como el aprendizaje por refuerzo (*Reinforcement Learning*, RL), presentan un elevado potencial para mejorar el control de los exoesqueletos. A diferencia de los métodos de control convencionales, que suelen basarse en modelos previamente definidos o en parámetros ajustados para unas condiciones concretas, el aprendizaje por refuerzo permite obtener políticas de control capaces de adaptarse a las características del usuario y a las variaciones de la interacción humano-robot. Mediante la experiencia acumulada durante el entrenamiento, estos algoritmos pueden aprender a proporcionar una asistencia más eficiente, reducir las fuerzas de interacción no deseadas y responder ante diferentes condiciones de movimiento o alteraciones motoras.

Sin embargo, el entrenamiento de una política de aprendizaje por refuerzo requiere que el agente explore numerosas acciones y situaciones antes de alcanzar un comportamiento adecuado. Durante este proceso pueden producirse movimientos inestables, esfuerzos excesivos o respuestas inesperadas, por lo que el entrenamiento directo con personas supondría un riesgo difícilmente asumible. Del mismo modo, la evaluación y validación de estos algoritmos en sujetos humanos está condicionada por requisitos éticos y de seguridad, especialmente durante las primeras etapas de desarrollo o cuando se estudian condiciones patológicas. Estas limitaciones hacen necesario disponer de entornos experimentales que permitan reproducir la interacción entre el usuario y el exoesqueleto de forma segura, controlada y repetible.

Es así como adquiere relevancia el término *dummy*, que hace referencia a un modelo físico capaz de reproducir determinadas características mecánicas y dinámicas del cuerpo humano. El uso de estas plataformas permite entrenar, evaluar y ajustar los controladores del exoesqueleto sin exponer a personas a los riesgos asociados a políticas todavía no validadas. Además, los *dummies* permiten realizar pruebas más seguras, controladas y repetibles, lo que resulta especialmente importante durante las etapas iniciales del desarrollo de un exoesqueleto.

No obstante, para que los resultados obtenidos mediante estas plataformas sean representativos, el comportamiento del *dummy* debe aproximarse de forma adecuada al de una extremidad humana real. La similitud entre ambos es un aspecto crucial para garantizar la validez de las pruebas realizadas. Por este motivo, tecnologías como el modelado musculoesquelético constituyen una herramienta fundamental para mejorar la precisión de los *dummies* y permitir una reproducción más realista de la interacción entre el exoesqueleto y el cuerpo humano. Estos modelos permiten caracterizar con mayor detalle la dinámica articular, la actuación muscular y la respuesta del cuerpo ante perturbaciones o alteraciones motoras. La combinación de modelos musculoesqueléticos, simulación y *dummies* robóticos proporciona así una plataforma intermedia entre el entrenamiento puramente virtual y la posterior validación con usuarios reales.

El presente proyecto se centra en el desarrollo de una plataforma que permita el entrenamiento y evaluación de algoritmos de control basados en aprendizaje por refuerzo en exoesqueletos. Este algoritmo será validado en un *dummy* de cadera que simula el comportamiento de un cuerpo humano, lo que permitirá evaluar la efectividad del control del exoesqueleto en un entorno seguro y controlado. El trabajo realizado junto con el Consejo Superior de Investigaciones Científicas (CSIC) y su grupo de investigación *Neuro AI and Robotics* (NAIR) ha sido fundamental para el desarrollo de este proyecto, ya que ha proporcionado acceso a recursos y conocimientos especializados en el campo de la robótica y la interacción humano-robot.

## 1.1 Motivación

Es inevitable el envejecimiento de las personas, y con ello la aparición de problemas de movilidad que afectan a la calidad de vida de los individuos. Además, el ejercicio físico, específicamente caminar, se ha consolidado como una herramienta segura y efectiva en el manejo de distintas enfermedades y en la rehabilitación de personas con problemas de movilidad [3]. Por ello, el desarrollo de tecnologías que faciliten la movilidad y la asistencia diaria es un área de investigación activa y en constante evolución.

Sin embargo, el desarrollo de exoesqueletos efectivos y seguros es un desafío complejo que requiere enfoques innovadores y técnicas avanzadas de control. Métodos clásicos de control, como el control proporcional-integral-derivativo (PID), pueden no ser suficientes para abordar la complejidad de la interacción entre el exoesqueleto y el cuerpo humano porque asumen que todos los cuerpos son iguales y no tienen en cuenta las diferencias individuales entre los usuarios. Por ello, el ajuste manual de los parámetros de control puede ser un proceso tedioso y poco eficiente, especialmente cuando se trata de usuarios con diferentes características físicas y necesidades de asistencia.

Es posible que tecnologías avanzadas de inteligencia artificial, como el aprendizaje por refuerzo, permitan a los exoesqueletos aprender de la experiencia y sea capaz de adaptarse a la biomecánica única de cada persona, optimizando la asistencia proporcionada y aumentando la seguridad y comodidad del usuario. Además, el diseño de modelos matemáticos que simulen la interacción entre el exoesqueleto y el cuerpo humano es una tarea compleja que podría solucionarse mediante el uso de técnicas de aprendizaje por refuerzo, que también permiten equilibrar varios objetivos distintos, como la eficiencia energética, la

comodidad del usuario y la seguridad del exoesqueleto, para lograr un control más efectivo y seguro del exoesqueleto.

Por lo tanto, este proyecto surge de la necesidad de desarrollar sistemas de control avanzados para exoesqueletos de asistencia, utilizando técnicas de aprendizaje por refuerzo para reducir la distancia entre la rigidez robótica y la flexibilidad humana, y mejorar la asistencia proporcionada a los usuarios.

## 1.2 Objetivos

Como se ha mencionado anteriormente, lograr una asistencia efectiva y segura mediante el uso de exoesqueletos es un desafío complejo que requiere enfoques innovadores y técnicas avanzadas de control.

### 1.2.1 Objetivo general

El objetivo general de este proyecto es desarrollar y evaluar una plataforma que permita entrenar y validar algoritmos de control basados en aprendizaje por refuerzo para el control de exoesqueletos. Esta plataforma incluirá el diseño y control de un modelo musculoesquelético simulado en trayectorias de marcha humana, así como su transferencia a un *dummy* robótico de cadera para evaluar su funcionamiento. Se debe establecer la base tanto para el entrenamiento de un agente que controle el exoesqueleto por medio de técnicas de aprendizaje por refuerzo, como para su despliegue en hardware real para evaluar su desempeño en un entorno físico.

### 1.2.2 Objetivos específicos

Como objetivos específicos, se plantean los siguientes:

- Desarrollar un modelo musculoesquelético de cadera capaz de seguir trayectorias de marcha humana.
- Transferir el modelo musculoesquelético a un *dummy* real, controlar sus articulaciones de cadera y evaluar su funcionamiento.
- Entrenar un agente por medio de técnicas de aprendizaje por refuerzo que sea capaz de controlar el exoesqueleto de cadera de modo que asista la marcha humana.
- Desplegar y evaluar el agente entrenado en un sistema físico real.

## 1.3 Antecedentes

El presente proyecto se ha realizado junto con el Consejo Superior de Investigaciones Científicas (CSIC), especialmente con el grupo de investigación conocido como *Neuro AI and Robotics* (NAIR) [4]. Este grupo de investigación se centra en mejorar sistemas robóticos estudiando cómo los humanos perciben e interactúan con su cuerpo, y consideran que el uso de modelos musculoesqueléticos es una herramienta fundamental para lograr este objetivo. Además, el grupo NAIR ha desarrollado un *dummy* robótico de cadera que permite simular el movimiento de flexión y extensión de ambas caderas, lo que facilita la investigación y el desarrollo de nuevas tecnologías en el campo de los exoesqueletos.

En este campo, miembros del grupo publicaron en 2025 un artículo centrado en el desarrollo de un controlador de par mediante aprendizaje por refuerzo profundo con el objetivo de optimizar el uso de

exoesqueletos de rodilla en pacientes con espasticidad [5]. Chavarriás et al. (2025) proponen un entorno de simulación basado en un gemelo digital y modelos musculoesqueléticos para entrenar un algoritmo de aprendizaje por refuerzo profundo para así evitar el riesgo de los métodos de control tradicionales. Sus resultados muestran que el agente entrenado es capaz de reducir un 10.6 % el par máximo aplicado por el exoesqueleto y de reducir las fuerzas de impacto involuntarias, mejorando la seguridad del usuario. Este trabajo sitúa a la rehabilitación robótica como un enfoque prometedor para pacientes con altos grados de espasticidad al ofrecer un control más adaptativo y personalizado, lo que permite una asistencia más efectiva y segura.

Enmarcado dentro de la línea de investigación de este grupo, que busca desarrollar algoritmos de control avanzados para exoesqueletos mediante el uso de técnicas de aprendizaje por refuerzo con el objetivo de ayudar en la rehabilitación o asistencia de personas con problemas de movilidad, mi trabajo se ha centrado en el desarrollo de una plataforma que permita el diseño y la validación de algoritmos de control basados en aprendizaje por refuerzo para el control de exoesqueletos. Se incluye el diseño de modelos musculoesqueléticos simulados, la conexión con el hardware real de validación, el diseño de la arquitectura de entrenamiento del agente y la evaluación de su desempeño tanto en simulación como en un entorno seguro y controlado en un *dummy* de pruebas real.

Todo esto permitirá avanzar en el desarrollo de exoesqueletos más efectivos y seguros, facilitando la investigación de nuevas tecnologías y técnicas de control que mejoren la asistencia proporcionada a los usuarios y aumenten su calidad de vida.

## 1.4 Estructura del documento

En esta sección se describe la estructura del documento, indicando el contenido de cada capítulo. El documento se divide de la siguiente forma:

- **Capítulo 1. Introducción:** Se presenta el contexto del proyecto, la motivación, los objetivos y la estructura del documento. Además, se exponen los antecedentes del proyecto en el grupo de investigación y las razones por las que se ha decidido realizar el proyecto.
- **Capítulo 2. Estado del arte:** Análisis de los trabajos previos y tecnologías existentes en el ámbito de los exoesqueletos, *dummies*, modelos musculoesqueléticos y aprendizaje por refuerzo, entre otras áreas. Se realiza una revisión de la literatura y se identifican problemas aún no resueltos.
- **Capítulo 3. Materiales y métodos:** Este capítulo se orienta a describir los materiales utilizados durante el proyecto, así como los métodos y técnicas empleadas para su desarrollo. Se detallan los componentes de hardware y software, siendo uno de ellos el *dummy* robótico de cadera, y se explica la metodología seguida para el diseño y validación del algoritmo de aprendizaje por refuerzo.
- **Capítulo 4. Resultados y discusión:** Este capítulo muestra y discute los resultados obtenidos durante el desarrollo del proyecto, incluyendo análisis de desempeño y comparaciones. En particular, se presentan comparaciones entre el comportamiento del modelo musculoesquelético simulado y el del *dummy* robótico, así como la evaluación del desempeño del agente entrenado en el control del exoesqueleto de cadera.
- **Capítulo 5. Conclusiones y trabajos futuros:** Se presentan las conclusiones finales del proyecto, destacando los objetivos alcanzados y las limitaciones encontradas. Además, se proponen posibles líneas de trabajo futuro para ampliar el alcance del proyecto y mejorar los resultados obtenidos, especialmente en el despliegue de los algoritmos de control en hardware real.

- **Bibliografía:** Se incluyen todas las referencias bibliográficas utilizadas en el documento.
- **Apéndice A: Presupuesto:** Se cuantifican los costes económicos del proyecto.
- **Apéndice B: Manual de despliegue:** Se describe el proceso de instalación y despliegue del proyecto de forma que se pueda reproducir.
- **Apéndice C: Planificación temporal:** Se muestra la planificación temporal del proyecto que se ha seguido durante su desarrollo.



# Capítulo 2

## Estado del Arte

En este capítulo se realiza una revisión del estado del arte actual sobre el uso de Aprendizaje por Refuerzo en exoesqueletos, así como el uso de dummies robóticos para la evaluación de exoesqueletos antes de probarlos en humanos reales o recientes sistemas de control para estos propios exoesqueletos. Además, se describen los principales trabajos de investigación en este campo, así como los desafíos abiertos y las tendencias recientes en la investigación.

### 2.1 Aprendizaje por refuerzo para exoesqueletos

#### 2.1.1 Introducción

Durante los últimos años, la intersección entre el Aprendizaje por Refuerzo (*Reinforcement Learning*, RL) y los sistemas robóticos de asistencia física, también llamados exoesqueletos, se ha consolidado como una de las líneas de investigación con mayor crecimiento y potencial dentro de la bioingeniería y la robótica inteligente. Los exoesqueletos, definidos como dispositivos mecánicos vestibles que se acoplan al cuerpo humano, tienen como objetivo principal recuperar, asistir o mejorar las capacidades motoras de sus usuarios [6]. No obstante, la implementación de estos sistemas plantea un desafío importante desde el punto de vista del control, debido a la complejidad no lineal de la interacción entre el exoesqueleto y el cuerpo humano. A diferencia de los robots industriales tradicionales, cuyas trayectorias se desarrollan en entornos controlados y predecibles, un exoesqueleto interactúa de manera continua y directa con el cuerpo humano, introduciendo una dinámica acoplada de carácter estocástico y variable, condicionada por varios factores propios del usuario, entre los que se encuentran la fatiga muscular, las diferencias biomecánicas entre usuarios, la intención de movimiento en cada instante, las variaciones en el terreno o el estado emocional de la persona.

Tradicionalmente, el control de exoesqueletos se ha basado en técnicas clásicas de control, como el control proporcional-integral-derivativo (PID), utilizado generalmente para la regulación de posición y el seguimiento de trayectorias; el control por impedancia, cuyo propósito es gestionar la interacción fuerza-movimiento entre el usuario y el dispositivo; y el control basado en dinámica inversa o *Computed Torque Control*, empleado para compensar las no linealidades del sistema mediante el uso de su modelo dinámico [7], [8]. Si bien estos enfoques proporcionan garantías de estabilidad asintótica en condiciones ideales, presentan limitaciones importantes frente al comportamiento variable de los seres humanos. En particular, requieren procedimientos de calibración largos y personalizados para cada usuario, además de carecer de la capacidad de adaptación en tiempo real ante perturbaciones no modeladas [9]. En este

contexto, el aprendizaje por refuerzo ha adquirido un papel relevante como una alternativa innovadora y un complemento a los métodos convencionales [10]. Al abordar el problema del control como un proceso de optimización continuo basado en la interacción con el entorno, esta técnica permite que el sistema ajuste su política de actuación de forma progresiva, adaptándose a las características biomecánicas individuales de cada usuario [1].

A pesar del potencial que ofrece este nuevo enfoque, resulta necesario mantener una visión crítica y reconocer que esta área de investigación se encuentra en una etapa relativamente temprana de desarrollo. Una parte significativa de los trabajos científicos publicados describe resultados satisfactorios obtenidos únicamente en entornos de simulación o en pruebas experimentales realizadas en laboratorios bajo condiciones controladas. Esta situación pone de manifiesto la existencia de una brecha de transferencia (*reality gap*) que no puede ignorarse. Con frecuencia, el rendimiento de un agente de RL entrenado en un entorno determinista disminuye de forma considerable cuando es implementado en un sistema real, debido a factores como la fricción de los actuadores, los retardos en la adquisición de datos de señales de los sensores o la naturaleza impredecible del comportamiento humano [11]. En las secciones siguientes se presentan los fundamentos teóricos de esta metodología, se revisan las principales líneas de investigación actuales y se analizan los desafíos más importantes que aún todavía dificultan su implantación en aplicaciones reales.

### 2.1.2 Fundamentos del Aprendizaje por Refuerzo

El aprendizaje por refuerzo constituye un enfoque de aprendizaje automático en el que un agente adquiere la capacidad de tomar decisiones de manera secuencial mediante su interacción con un entorno, con el objetivo de maximizar una recompensa obtenida a lo largo del tiempo. A diferencia del aprendizaje supervisado, en el que un modelo se entrena utilizando ejemplos previamente etiquetados, en RL el agente aprende a partir de la experiencia, recibiendo información en forma de recompensas o penalizaciones como consecuencia de sus acciones [12]. Habitualmente, este proceso de interacción se diseña como un Proceso de Decisión de Markov (MDP), que se compone de varios elementos fundamentales:

- **Entorno:** Es el sistema físico o simulado donde el agente opera e interactúa. En el caso de un exoesqueleto, el entorno incluye tanto el propio dispositivo como el usuario y su contexto físico.
- **Estados:** Representan la situación actual del entorno. En el contexto de la robótica de rehabilitación, los estados pueden incluir información sobre la posición y velocidad de las articulaciones del exoesqueleto, la fuerza aplicada por el usuario, y otros parámetros fisiológicos relevantes.
- **Agente:** Es el sistema que toma decisiones y aprende a través de la interacción con el entorno. En este caso, el agente es el algoritmo de RL que controla el exoesqueleto.
- **Acciones:** Son las decisiones que el agente puede tomar en cada estado para interactuar con el entorno. En un exoesqueleto, las acciones pueden ser comandos de par de torsión a los motores.
- **Observaciones:** Es la información del estado que el agente puede percibir. En muchos casos, el agente no tiene acceso completo al estado del entorno, por lo que debe basar sus decisiones en observaciones parciales. En exoesqueletos, estas observaciones pueden ser la posición de las articulaciones, la velocidad angular, la fuerza de interacción o señales fisiológicas del usuario.
- **Recompensa:** Es una señal numérica que el entorno proporciona al agente después de cada acción, indicando qué tan buena fue la acción tomada en términos de alcanzar el objetivo deseado. En la

rehabilitación, la recompensa puede estar relacionada con la eficiencia del movimiento, la comodidad del usuario o la reducción del esfuerzo físico.

- **Política:** Es la estrategia que sigue el agente para decidir qué acción tomar en cada estado.

El funcionamiento de un sistema de RL aplicado al control de un exoesqueleto puede describirse mediante un ciclo continuo de interacción entre el agente y el entorno. En cada iteración, el agente obtiene información sobre el estado del entorno, determina la acción más adecuada y, tras ejecutarla, recibe una recompensa que evalúa el resultado de la acción tomada. Una representación esquemática de este proceso se puede observar en la figura 2.1.




Figura 2.1: Configuración usual de un sistema de aprendizaje por refuerzo. Figura obtenida de [13]. Se observa que el agente (*Controller*) recibe observaciones (*State*) del entorno (*System*), selecciona una acción (*Action*) y recibe una recompensa (*Reward*).

### 2.1.3 Aprendizaje por refuerzo en robótica de rehabilitación

Desde un punto de vista matemático, el Aprendizaje por Refuerzo se estructura sobre los Procesos de Decisión de Markov (MDP), que proporcionan el marco teórico de referencia para describir la toma de decisiones secuenciales en entornos estocásticos [14], [15]. Un MDP se define mediante la tupla  $(S, A, P, R, \gamma)$ , donde  $S$  corresponde al conjunto de estados,  $A$  al conjunto de acciones,  $P$  describe las probabilidades de transición entre estados,  $R$  representa la función de recompensa y  $\gamma$  es el factor de descuento. En el ámbito de la robótica de rehabilitación, cada uno de estos elementos adquiere una interpretación directamente relacionada con el comportamiento físico del sistema y la interacción entre el exoesqueleto y el usuario. Asimismo, la incorporación de arquitecturas basadas en redes neuronales ha dado lugar al Aprendizaje por Refuerzo Profundo (*Deep Reinforcement Learning*, Deep RL), permitiendo abordar de forma eficiente espacios de estados de elevada dimensionalidad y superando las restricciones inherentes a los enfoques tabulares convencionales [16].

La definición del espacio de estados  $S$  es crítica y, por lo general, incorpora variables cinemáticas y dinámicas obtenidas en tiempo real. Entre ellas se incluyen los ángulos articulares, las velocidades angulares, las aceleraciones de los distintos segmentos corporales registradas mediante unidades de medición inercial (IMU) y las fuerzas de interacción entre el usuario y el exoesqueleto, medidas a través de celdas de carga. Por su parte, el espacio de acciones  $A$  suele estar formado por las órdenes de control que el agente envía al sistema, como comandos de par aplicados a los motores eléctricos o valores de presión de referencia destinados a actuadores neumáticos blandos.

El núcleo del éxito del aprendizaje radica en el diseño de la función de recompensa  $R$ . Esta función debe sintetizar los objetivos clínicos y matemáticos de la terapia, y suele adoptar una estructura multiobjetivo escalarizada como:

$$R_t = w_1 R_{\text{eficiencia}} + w_2 R_{\text{suavidad}} + w_3 R_{\text{postura}} - w_4 R_{\text{penalización}}$$

En esta expresión, los coeficientes  $w_i$  establecen la importancia relativa de cada uno de los términos de la función. La definición adecuada de esta función de recompensa representa uno de los desafíos más complejos y aún no resueltos dentro del Aprendizaje por Refuerzo. Un diseño inadecuado o un desequilibrio entre sus componentes puede llevar al agente a encontrar soluciones que maximizan la recompensa desde un punto de vista matemático, pero que resultan inapropiadas o incluso peligrosas en la práctica. Entre estos comportamientos se encuentran la generación de movimientos espasmódicos de alta frecuencia, con el consiguiente riesgo para la integridad de las articulaciones del paciente, o la ausencia de asistencia por parte del exoesqueleto, trasladando todo el esfuerzo físico al usuario con el fin de reducir el consumo energético del sistema robótico.

#### 2.1.4 Principales líneas de investigación

Pese a que muchos estudios recientes combinan varias líneas de investigación distintas, se pueden identificar tres áreas principales de trabajo que han concentrado la mayor parte de los esfuerzos en el desarrollo de controladores de exoesqueletos basados en aprendizaje por refuerzo:

##### **A: Control de marcha asistida y optimización de la locomoción**

La rehabilitación y asistencia durante la marcha en personas con alteraciones neurológicas, como las ocasionadas por accidentes cerebrovasculares, lesiones medulares o parálisis cerebral, es el área de investigación más investigada en este ámbito. Trabajos de referencia, como los desarrollados por Rose y Bazzocchi (2022), han empleado algoritmos de RL profundo basados en arquitecturas actor-crítico con gradiente de política, entre los que destacan *Proximal Policy Optimization* (PPO) y *Soft Actor-Critic* (SAC) [17]. Estos algoritmos hacen posible el aprendizaje de políticas de control continuas en espacios de alta dimensionalidad, capaces de adaptarse de forma sincronizada con el patrón de marcha natural del usuario y de ajustar el nivel de asistencia en función de la fase del ciclo de marcha.

No obstante, la implementación directa de estas políticas en sistemas físicos continúa representando un importante desafío debido a los problemas de inestabilidad transitoria que pueden aparecer durante su despliegue. Las diferencias dinámicas existentes entre el entorno simulado y el sistema real, conocidas como *sim-to-real gap*, generan variaciones en la respuesta del controlador que pueden comprometer la estabilidad y el equilibrio del usuario. Con el objetivo de reducir este efecto, diversos autores, entre ellos Luo et al. (2023), han recurrido a técnicas avanzadas de aleatorización de dominio (*domain randomization*) durante el entrenamiento en simulación [9]. Esta metodología consiste en modificar de forma aleatoria parámetros físicos relevantes, como la masa de los distintos segmentos del robot, los coeficientes de fricción de las articulaciones, los retardos del lazo de control o la inercia asociada al usuario. De este modo, el agente de RL aprende una política de control menos dependiente de un único modelo de simulación y, por tanto, más robusta y con mayor capacidad de generalización cuando se transfiere al hardware real. Aún así, este enfoque incrementa de forma considerable el coste computacional y el tiempo necesario para que el algoritmo alcance la convergencia.

##### **B: Minimización de las fuerzas de interacción humano-robot y costo metabólico**

Como se ha mencionado anteriormente, algunos de los problemas de seguridad más relevantes en la interacción entre un exoesqueleto y un usuario humano se derivan de la aplicación de fuerzas de contacto excesivas, que pueden provocar lesiones musculoesqueléticas o daños en los tejidos blandos. Además, la fatiga muscular y el gasto energético del usuario constituyen factores críticos que limitan la duración de las sesiones de rehabilitación y la eficacia de los tratamientos. Por este motivo, una línea de investigación emergente se centra en el desarrollo de algoritmos de aprendizaje por refuerzo capaces de reducir tanto las fuerzas de interacción como el coste metabólico del usuario durante la marcha asistida. Este enfoque se basa en la premisa de que un exoesqueleto debe actuar como un asistente inteligente, proporcionando únicamente la cantidad de asistencia necesaria para facilitar el movimiento, sin imponer trayectorias rígidas ni generar esfuerzos adicionales que puedan resultar perjudiciales para el paciente.

En este contexto, el estudio de Zhang et al. (2017) marcó un punto de inflexión en este ámbito de investigación [18]. Los autores desarrollaron un sistema de optimización *human-in-the-loop* que combinaba algoritmos evolutivos con técnicas de RL, permitiendo ajustar de manera adaptativa los perfiles de asistencia de par aplicados en los tobillos a partir de una estimación en tiempo real del gasto energético del usuario. La figura 2.2a muestra el exoesqueleto de tobillo empleado durante los experimentos, mientras que la figura 2.2b presenta los valores medios del par de asistencia proporcionado por el exoesqueleto a cada uno de los participantes, representados cada uno por un color.




Figura 2.2: Ambas imágenes extraídas de [18].

Posteriormente, ha habido otros trabajos que también han sido capaces de desarrollar algoritmos basados en RL que reducen el coste metabólico del usuario durante la marcha asistida [19], [20]. Por ejemplo, el trabajo de Choi et al. (2026) constituye un avance significativo al demostrar que no sólo es posible reducir el coste metabólico, sino que también es capaz de proporcionar asistencia personalizada e incluso compensar déficits musculares mediante un entrenamiento realizado exclusivamente en el motor de físicas Hyfydy [19] (el motor Hyfydy se detalla más adelante en la sección 2.3.3). Para ello, los autores emplearon un modelo musculoesquelético que incorporaba alteraciones musculares específicas, permitiendo que el agente de RL aprendiera políticas de control adaptadas a distintas patologías. Además, el sistema consiguió reducir el coste metabólico durante la marcha, lo que pone de manifiesto el potencial de este enfoque para desarrollar estrategias de asistencia más personalizadas y eficaces. Los resultados de este trabajo se muestran en la figura 2.3.

Los trabajos en este área han demostrado que el aprendizaje por refuerzo puede ser una herramienta poderosa para desarrollar controladores de exoesqueletos que no solo garanticen la seguridad y estabilidad




Figura 2.3: Resultados sobre el coste metabólico del trabajo de Choi et al. (2026). Figura obtenida de [19]. La figura a muestra el coste metabólico sin el uso de exoesqueletos, con exoesqueleto de rodilla y con exoesqueleto de cadera a distintas velocidades de marcha. La figura b muestra el coste metabólico medio al andar (parte superior) y al correr (parte inferior).

del usuario, sino que también optimicen su experiencia de uso, minimizando el esfuerzo físico requerido durante la marcha asistida.

### C: Aprendizaje en simulación y transferencia Sim-to-Real

Uno de los principales desafíos en la interacción entre humanos y robots es la gran cantidad de ensayos con participantes reales necesarios para validar y perfeccionar los algoritmos de control [21]. Esta dependencia supone una limitación importante, ya que, además de la dificultad para reclutar voluntarios, las pruebas requieren un elevado consumo de tiempo y recursos, lo que dificulta el desarrollo de controladores capaces de abordar múltiples tareas de forma eficiente [22]. Como alternativa, numerosos investigadores han trasladado el entrenamiento de estos algoritmos a simuladores físicos, permitiendo acelerar significativamente el proceso de aprendizaje. En esta línea, Luo et al. (2024) demostraron que, mediante el empleo de modelos musculoesqueléticos y de exoesqueletos con un alto grado de realismo, junto con técnicas de inteligencia artificial para entrenar agentes de RL, es posible desarrollar completamente un controlador en simulación y transferirlo posteriormente a un exoesqueleto real sin necesidad de realizar ajustes o calibraciones adicionales [22]. Este resultado representa un avance relevante, ya que evidencia la posibilidad de reducir de forma considerable el tiempo dedicado al desarrollo de algoritmos de control, al mismo tiempo que disminuye los riesgos asociados a las pruebas experimentales con personas durante las etapas iniciales de diseño. Los resultados obtenidos pueden observarse en la figura 2.4, donde el exoesqueleto demuestra ser capaz de asistir al usuario en diferentes actividades, como caminar, correr o subir escaleras, utilizando el mismo agente entrenado en simulación y sin requerir modificaciones adicionales.




Figura 2.4: Resultados del experimento de "Luo et al. (2024)" [22]. Se muestra un diagrama de caja comparando el coste metabólico del usuario al andar, correr y subir escaleras, tanto sin usar el exoesqueleto como con el exoesqueleto con y sin asistencia.

Podemos observar como, sin necesidad de ajustar el agente entrenado, el exoesqueleto es capaz de asistir y reducir el coste metabólico del usuario al andar, correr y subir escaleras.

A pesar de estos avances, los entornos de simulación todavía no son capaces de representar con total fidelidad la complejidad y la variabilidad presentes en el mundo físico. Por este motivo, resulta necesario recurrir a técnicas como la aleatorización de dominio (*domain randomization*), que facilitan la adaptación del agente de RL a las diferencias existentes entre la simulación y el sistema real. Este enfoque consiste en introducir variaciones aleatorias en distintos parámetros del simulador durante el entrenamiento, tales como la masa del exoesqueleto, la fricción de las articulaciones o los retardos del sistema de control, con el fin de que el agente aprenda políticas más robustas frente a dichas incertidumbres. Trabajos como el de Tobin et al. (2018) demostraron que esta estrategia mejora de forma significativa la transferencia *sim-to-real*, ya que favorece la capacidad de generalización del agente y permite obtener controladores con una elevada precisión y una gran resistencia al ruido [23]. No obstante, esta metodología también presenta ciertas limitaciones, entre las que destacan el incremento del tiempo de entrenamiento y la imposibilidad de garantizar una transferencia completamente libre de discrepancias entre la simulación y el entorno real.

Pese a estos problemas, se ha demostrado que es posible entrenar un agente de RL completamente en un entorno de simulación y transferir posteriormente la política aprendida a un exoesqueleto real sin necesidad de efectuar ajustes o procesos de calibración adicionales. Este resultado fue posible gracias a la combinación de técnicas de aleatorización de dominio con modelos detallados tanto del sistema musculoesquelético como del propio exoesqueleto [24]. Los autores lograron una reducción aproximada del 15 % en el coste metabólico del usuario al andar y, con la incorporación de redes LSTM (*Long Short-Term Memory*) se consiguió mejorar la adaptación del controlador a distintas velocidades de desplazamiento y tipos de terreno, proporcionando una asistencia más estable, suave y controlada.

#### D: Otras investigaciones recientes

Otro de los grandes retos en el control de exoesqueletos es la capacidad de desarrollar algoritmos que no solo puedan generalizar entre distintos usuarios, sino que también se adapten a las diferentes patologías que estos pueden presentar. Este desafío es considerablemente más complejo debido a la gran variabilidad biomecánica y funcional asociada a cada condición clínica.

En este sentido, ya se ha propuesto un entorno de simulación basado en aprendizaje por refuerzo orientado a la optimización automática de los parámetros de los exoesqueletos [25]. Como se ha señalado previamente, el ajuste de controladores para este tipo de dispositivos suele ser un procedimiento largo y costoso, debido a la necesidad de realizar numerosas pruebas con intervención humana. La metodología planteada por estos autores permite automatizar gran parte de este proceso mediante simulaciones neuromecánicas, facilitando tanto la optimización de los parámetros del exoesqueleto como la generalización del controlador a diferentes patologías. Gracias a este enfoque, fue posible reducir de forma significativa el tiempo necesario para el desarrollo y ajuste de algoritmos de control destinados a exoesqueletos.

#### 2.1.5 Desafíos abiertos

A pesar del ritmo vertiginoso al que avanza la investigación teórica, el despliegue del Aprendizaje por Refuerzo en exoesqueletos de grado médico se enfrenta a barreras críticas de naturaleza técnica, de seguridad y regulatoria:

- **Garantías de seguridad crítica:** En aplicaciones de robótica industrial o de servicios, una acción incorrecta durante la fase de exploración de un agente de RL suele tener como consecuencia

pérdidas económicas o daños materiales que, en la mayoría de los casos, pueden repararse o sustituirse. En cambio, cuando el sistema robótico está acoplado directamente al cuerpo de un paciente con fragilidad ósea o muscular, una decisión inadecuada del controlador puede ocasionar caídas, fracturas o lesiones musculares de gravedad. Por este motivo, una parte importante de la investigación actual se centra en el desarrollo de técnicas de Aprendizaje por Refuerzo Seguro (*Safe RL*). Estos enfoques incorporan mecanismos como las Funciones de Barrera de Control (CBF) o los Procesos de Decisión de Markov Restringidos (CMDP), que actúan como filtros de seguridad capaces de impedir la ejecución de acciones que sobrepasen los límites anatómicos o dinámicos considerados seguros para el usuario [26].

Además, Brunke et al. (2022) clasifican las restricciones de seguridad en tres categorías principales. Las restricciones de nivel 1, también denominadas restricciones débiles, corresponden a condiciones que no son críticas para la seguridad del sistema y cuyo cumplimiento se incentiva mediante penalizaciones incorporadas a la función de recompensa. Las restricciones de nivel 2, o restricciones probabilísticas, buscan garantizar que determinadas condiciones de seguridad se satisfagan con una elevada probabilidad, constituyendo habitualmente el máximo nivel de garantía alcanzable mediante métodos basados en aprendizaje. Finalmente, las restricciones de nivel 3, conocidas como restricciones duras, deben cumplirse en todo momento sin excepción. En el contexto de este trabajo, estas últimas son las encargadas de asegurar que el exoesqueleto no genere fuerzas que puedan comprometer la integridad física del usuario.

García y Fernández (2015) realizaron una revisión exhaustiva de los principales enfoques de Aprendizaje por Refuerzo Seguro (*Safe RL*), en la que identificaron dos estrategias fundamentales [27]. La primera consiste en modificar la función de recompensa para penalizar las acciones que puedan comprometer la seguridad, de modo que el agente no solo aprenda a maximizar la recompensa obtenida, sino también a evitar comportamientos potencialmente peligrosos. La segunda estrategia se basa en intervenir sobre el proceso de exploración del agente durante el entrenamiento. En este caso, el aprendizaje se guía especialmente en las etapas iniciales y se apoya en un modelo matemático capaz de estimar las consecuencias de las acciones antes de ejecutarlas, con el objetivo de impedir que el agente realice decisiones que puedan resultar inseguras.

- **La opacidad algorítmica y la crisis de interpretabilidad:** Las políticas de control obtenidas mediante Aprendizaje por Refuerzo Profundo suelen implementarse a través de redes neuronales con cientos de miles de parámetros ajustables, lo que hace que su funcionamiento sea, en la práctica, difícil de interpretar y las convierta en auténticas cajas negras [28]. Esta falta de interpretabilidad supone un importante obstáculo en el ámbito sanitario, donde las decisiones clínicas deben ser comprensibles, justificables y trazables. Médicos y fisioterapeutas necesitan conocer con claridad los motivos que llevan al controlador robótico a seleccionar una determinada acción. La ausencia de transparencia dificulta anticipar el comportamiento del sistema ante situaciones poco frecuentes o inesperadas, generando desconfianza en la comunidad médica y complicando los procesos de validación y certificación exigidos por organismos reguladores como la FDA o la Agencia Europea de Medicamentos (EMA).

En este sentido, la EMA publicó en julio de 2025 una serie de requisitos para el empleo de inteligencia artificial y aprendizaje automático (*Machine Learning*) en la fabricación de medicamentos. Entre las principales exigencias se encuentran la definición y aprobación del uso previsto de estos sistemas, el cumplimiento de las normas de buenas prácticas aplicables a la industria farmacéutica y biotecnológica, el entrenamiento de los modelos con datos de alta calidad y la supervisión de las decisiones adoptadas por los sistemas de IA, entre otros aspectos [29].

- **Eficiencia de muestreo e inviabilidad de exploración directa:** El entrenamiento de un agente de aprendizaje por refuerzo profundo suele requerir millones de interacciones con el entorno antes de alcanzar una política de control satisfactoria. Aplicar este proceso de aprendizaje basado en prueba y error directamente sobre un paciente durante una sesión de rehabilitación resulta inviable, tanto por el elevado esfuerzo físico que implicaría como por los riesgos éticos y de seguridad asociados. Por este motivo, las investigaciones más recientes dependen en gran medida del entrenamiento previo en simulación y del empleo de modelos que permitan transferir posteriormente las políticas aprendidas al sistema real. Tras esta transferencia, es habitual realizar una fase de ajuste fino (*fine-tuning*) para adaptar rápidamente el controlador a las condiciones reales de funcionamiento. No obstante, la obtención de métodos de transferencia robustos y generalizables continúa siendo uno de los principales desafíos abiertos en este campo de investigación.

### 2.1.6 Tendencias recientes

Las líneas de investigación más recientes muestran una transición progresiva desde los enfoques tradicionales de Aprendizaje por Refuerzo sin modelo (*model-free*) hacia arquitecturas híbridas que incorporan conocimiento bioinspirado. Una de las tendencias con mayor proyección consiste en combinar el RL con modelos musculoesqueléticos y biomecánicos capaces de representar de forma predictiva el comportamiento del cuerpo humano. La integración de restricciones matemáticas que describen la dinámica de los tendones, la activación de los músculos y los límites cinemáticos del sistema esquelético dentro del propio proceso de aprendizaje permite reducir de manera significativa el espacio de búsqueda que debe explorar el agente. Como consecuencia, se acelera la convergencia del algoritmo y se favorece que las trayectorias generadas sean compatibles, desde su diseño, con la biomecánica y la fisiología del movimiento humano.

De forma paralela, está creciendo el interés por aplicar el Aprendizaje por Refuerzo Multiagente (MARL) a problemas de asistencia coordinada de mayor complejidad, como el control simultáneo de exoesqueletos bilaterales independientes o la colaboración entre un exoesqueleto y un sistema de estimulación eléctrica funcional (FES) [30], [31]. En estos escenarios, varios agentes cooperan para alcanzar un objetivo común, permitiendo una coordinación más eficiente entre los distintos sistemas de asistencia.

Asimismo, la aparición del Aprendizaje por Refuerzo a partir de Retroalimentación Humana (*Reinforcement Learning from Human Feedback*, RLHF) ha introducido una nueva perspectiva en el diseño de controladores inteligentes. Este enfoque plantea la posibilidad de que el propio usuario influya directamente en el proceso de aprendizaje mediante mecanismos de retroalimentación cualitativa, como escalas analógicas visuales, instrucciones verbales o interfaces táctiles sencillas. De este modo, el paciente puede contribuir al ajuste de la función de recompensa del agente, favoreciendo una mayor personalización del sistema. Como resultado, el exoesqueleto adapta su comportamiento no solo a partir de criterios objetivos relacionados con el rendimiento cinemático, sino también considerando la percepción subjetiva de comodidad, confort y bienestar experimentada por el usuario.

## 2.2 Réplicas robóticas del cuerpo humano para el estudio y mejora de exoesqueletos robóticos

### 2.2.1 Introducción

Uno de los principales desafíos en el desarrollo de exoesqueletos es la evaluación del dispositivo antes de realizar ensayos con personas. Aunque las simulaciones por ordenador constituyen una herramienta muy útil para una primera fase de validación, estos modelos aún presentan limitaciones a la hora de reproducir con precisión fenómenos como la variabilidad del tejido blando, la fatiga muscular, la interacción física entre el humano y el exoesqueleto o la complejidad de los movimientos humanos reales [32]. Por otro lado, las pruebas con usuarios están sujetas a importantes restricciones éticas y de seguridad, especialmente durante las etapas iniciales del desarrollo, en las que el sistema todavía puede generar fuerzas de interacción potencialmente peligrosas para el usuario.

La necesidad de disponer de una etapa intermedia entre la simulación y las pruebas con personas ha impulsado el desarrollo de réplicas robóticas, conocidas como *dummies*. Estas plataformas, diseñadas con una geometría similar a la del cuerpo humano, permiten estudiar la interacción entre un exoesqueleto y su usuario sin exponer a personas a posibles riesgos durante las fases iniciales de desarrollo. Deben ser capaces de reproducir con fidelidad el peso y la distribución de masas de un usuario real, así como las características mecánicas de los tejidos blandos y la cinemática de las articulaciones. Además, es deseable que incorporen sensores capaces de medir fuerzas, momentos y presiones en los puntos de contacto con el exoesqueleto, proporcionando información objetiva y cuantificable sobre la interacción humano-robot.

Este concepto no es reciente. Uno de los ejemplos más representativos es PETMAN (*Protection Ensemble Test Mannequin*), un robot humanoide desarrollado por Boston Dynamics para el ejército de los Estados Unidos. Con un peso aproximado de 80 kilogramos y una altura de 175 centímetros, PETMAN era capaz de caminar, agacharse y realizar ejercicios físicos sencillos, y fue concebido para evaluar trajes de protección química en condiciones de uso reales. Además, incorporaba sistemas capaces de reproducir determinadas características fisiológicas humanas, como la temperatura corporal, la humedad e incluso la sudoración, con el objetivo de recrear en el interior del traje unas condiciones lo más similares posible a las de un usuario real [33]. Aunque este robot no fue diseñado específicamente para aplicaciones de rehabilitación mediante exoesqueletos, supuso un importante precedente al demostrar el potencial de los robots humanoides como sustitutos del cuerpo humano en ensayos experimentales. Una imagen del robot PETMAN se muestra en la figura 2.5.

Estudios como el de "Klankers et al. (2024)" ponen de manifiesto que los *dummies* robóticos pueden constituir una alternativa parcial a los ensayos realizados con personas durante el desarrollo de exoesqueletos [21]. No obstante, los propios autores señalan que existen aspectos fundamentales de la interacción humano-exoesqueleto que todavía no pueden reproducirse con fidelidad mediante este tipo de plataformas, siendo algunos de ellos el comportamiento del tejido blando durante el contacto con el dispositivo y fenómenos fisiológicos como la fatiga muscular, cuya reproducción en un robot resulta actualmente inviable. En consecuencia, los *dummies* robóticos no pueden reemplazar por completo las pruebas con usuarios reales, aunque sí representan una herramienta de gran utilidad para disminuir los riesgos asociados a las fases iniciales de validación y acelerar el desarrollo de nuevos exoesqueletos.

Pese a que el uso de dummies en la industria automovilística y en la investigación de seguridad vial está ampliamente extendido con los llamados *crash test dummies* utilizados para medir el riesgo de lesión en los impactos de vehículos, su aplicación en el ámbito de la robótica de asistencia y rehabilitación es todavía incipiente. En este contexto, el presente capítulo tiene como objetivo ofrecer una visión




Figura 2.5: Robot PETMAN en una cinta de correr. Imagen extraída de [33].

general de los principales avances en el desarrollo de réplicas robóticas del cuerpo humano, con especial énfasis en aquellas que reproducen las extremidades inferiores. Se abordarán aspectos relacionados con la cinemática, la dinámica y la instrumentación de estos sistemas, así como sus aplicaciones en la validación de exoesqueletos y órtesis robóticas.

### 2.2.2 Réplicas robóticas de miembro inferior

En el ámbito de los exoesqueletos de rehabilitación se han desarrollado plataformas específicas capaces de reproducir uno o varios segmentos de las extremidades inferiores. El objetivo de estos sistemas es analizar de forma precisa la interacción entre el exoesqueleto y un usuario artificial, evitando la necesidad de realizar ensayos con personas durante las primeras etapas de evaluación.

Un ejemplo destacado es el trabajo de Bessler-Etten et al. (2022), quienes desarrollaron un simulador de pierna instrumentado para investigar cómo afectan los desalineamientos entre el exoesqueleto y la pierna a las cargas internas de la articulación de la rodilla. Esta plataforma permitía medir con precisión las fuerzas y los momentos generados en función del tipo y la magnitud del desalineamiento, información que sería mucho más difícil y arriesgada de obtener mediante experimentos con sujetos humanos. Los resultados obtenidos mostraron que incluso pequeños errores de alineación pueden producir incrementos significativos en las cargas articulares, poniendo de manifiesto la necesidad de disponer de herramientas de validación previas a los ensayos clínicos [34].

De manera similar, Dežman, Massardi et al. (2023) presentaron *Leg Replica*, una plataforma robótica mecatrónica concebida como un banco de ensayos estandarizado para el estudio de la interacción entre exoesqueletos y usuarios. Este dispositivo reproduce tanto la geometría como los movimientos de la

extremidad inferior e incorpora sensores de par y de fuerza en las articulaciones, lo que permite obtener medidas objetivas y reproducibles, independientes de la variabilidad entre sujetos. Según sus autores, esta tecnología resulta especialmente útil durante las primeras fases del desarrollo, cuando las limitaciones éticas y de seguridad dificultan la realización de pruebas con personas [35]. La plataforma *Leg Replica* puede observarse en la figura 2.6.

Posteriormente, Massardi et al. (2023) utilizaron *Leg Replica* para evaluar un mecanismo de compensación de desalineamientos integrado en un exoesqueleto de rodilla. Gracias al uso de este *dummy*, fue posible analizar el comportamiento del dispositivo bajo diferentes configuraciones experimentales, reduciendo la influencia de la variabilidad inherente a los ensayos con participantes humanos y obteniendo resultados más consistentes [36].




Figura 2.6: Leg Replica. En ella podemos observar las articulaciones de cadera y tobillo (en azul, ambas con 3 grados de libertad), y la articulación de rodilla (en rojo, con 1 grado de libertad). Imagen extraída de [35].

### 2.2.3 Sustitutos robóticos para validación biomecánica

Además del estudio de la interacción a nivel articular, diversas investigaciones han explorado el empleo de *dummies* capaces de reproducir una extremidad completa, en lugar de centrarse únicamente en una articulación específica. En este contexto, McGrath et al. (2024) desarrollaron una pierna robótica con el objetivo de analizar los efectos de una órtesis de tobillo-pie sobre el hueso tibial, permitiendo medir variables que resultan muy difíciles o incluso imposibles de obtener mediante ensayos con personas. La plataforma incorporaba un mecanismo de doble actuación para simular el complejo formado por el músculo sóleo y el tendón de Aquiles, lo que facilitó la realización de experimentos repetibles y controlados. No obstante, los propios autores señalaron que todavía existen incertidumbres acerca de la capacidad de extrapolar completamente los resultados obtenidos con este tipo de sistemas a las condiciones reales de uso en humanos [37].

### 2.2.4 Bancos de ensayo y validación experimental

Como se ha señalado anteriormente, los *dummies* robóticos constituyen una herramienta de gran utilidad para validar exoesqueletos sin exponer a personas a posibles riesgos durante las fases de desarrollo. En esta línea, Nguialem et al. (2021) presentaron una plataforma mecánica capaz de reproducir el comportamiento de un brazo humano. Este brazo robótico fue diseñado con una estructura ajustable, tanto en longitud como en rangos de movimiento, permitiendo adaptarlo a distintas configuraciones

anatómicas. Además, incorporaba sensores y encoders destinados a medir variables como la posición y el par en las articulaciones. Gracias a estas características, el sistema hacía posible evaluar el funcionamiento del exoesqueleto y analizar su interacción con el brazo robótico en condiciones de funcionamiento tanto activas como pasivas [38]. La figura 2.7 muestra una imagen de esta plataforma robótica.



Figura 2.7: Brazo robótico. Cuenta con 4 motores para simular los movimientos de codo y de muñeca. Imagen extraída de [38].

Investigaciones más recientes plantean que la validación de sistemas de control no requiere necesariamente la participación de personas y que los *dummies* robóticos representan una alternativa más segura, controlada y reproducible [39]. En este trabajo se desarrolló una rodilla robótica capaz de reproducir la cinemática de la articulación humana, cuyo comportamiento se comparaba con el esperado mediante el uso de un gemelo digital encargado de mantener sincronizados el sistema físico y su modelo virtual. Este enfoque permite verificar el rendimiento, la seguridad y la eficacia de los exoesqueletos antes de realizar ensayos con usuarios reales, reduciendo los riesgos asociados a las primeras fases de desarrollo y agilizando el proceso de validación. En consecuencia, los *dummies* robóticos están adquiriendo un papel cada vez más relevante en la investigación y el desarrollo de exoesqueletos, y todo apunta a que su utilización continuará expandiéndose en los próximos años.

Los gemelos digitales son representaciones virtuales de alta fidelidad de un sistema físico, como un exoesqueleto, que permiten reproducir y analizar su comportamiento bajo diferentes condiciones de funcionamiento. Estas réplicas digitales pueden emplearse para optimizar el diseño del dispositivo, estimar su rendimiento y verificar su seguridad antes de su fabricación o de su utilización en personas. La integración de gemelos digitales con *dummies* robóticos proporciona un entorno de validación más completo y fiable, ya que combina la experimentación física con el análisis virtual. De este modo, es posible reducir la dependencia de ensayos con usuarios reales durante las primeras etapas de desarrollo y acelerar el proceso de diseño y validación de los exoesqueletos.

### 2.2.5 Limitaciones y perspectivas

El empleo de *dummies* robóticos presenta numerosas ventajas, entre las que destacan la eliminación de los riesgos asociados a los ensayos con personas, la ausencia de efectos derivados de la fatiga, la elevada repetibilidad de los experimentos y el control preciso de las condiciones de prueba. Sin embargo, esta tecnología también presenta limitaciones importantes. La más relevante es la dificultad para reproducir con fidelidad las propiedades mecánicas del tejido blando, un elemento esencial en la interacción entre el exoesqueleto y el cuerpo humano [40]. En este sentido, Massardi et al. (2022) señalan que tanto la capacidad de deformación de los tejidos como su comportamiento en la absorción de energía constituyen algunos de los aspectos más complejos de replicar mediante plataformas robóticas [41].

A pesar de estas limitaciones, la evolución de este campo apunta claramente hacia una mayor incorporación de este tipo de tecnologías. Aunque todavía no existen protocolos de validación plenamente estandarizados y muchas evaluaciones continúan requiriendo la participación de usuarios reales, el uso de una etapa intermedia basada en *dummies* robóticos entre la simulación y los ensayos clínicos está adquiriendo una relevancia creciente. Este enfoque permite reducir significativamente los riesgos durante las primeras fases de desarrollo sin renunciar a una validación experimental más allá de los entornos puramente simulados [42].

## 2.3 Control neuromusculoesquelético

### 2.3.1 Introducción

Tradicionalmente, la robótica asistencial ha situado al usuario en un papel mayoritariamente pasivo. La mayoría de los sistemas convencionales conducen el movimiento del paciente mediante trayectorias predefinidas y rígidas, reduciendo al mínimo su participación durante la ejecución de la tarea [43]. No obstante, en el contexto de la rehabilitación neuromuscular, este planteamiento presenta una importante limitación clínica. Cuando el sistema nervioso central no participa activamente en la planificación y el control del movimiento, los procesos responsables de la plasticidad neuronal apenas se estimulan. Por ello, para favorecer una recuperación funcional efectiva, es fundamental que el paciente desempeñe un papel activo, utilizando su propia intención motora para dirigir el funcionamiento del exoesqueleto en lugar de limitarse a seguir un movimiento impuesto por el dispositivo.

El control basado en modelos neuromusculoesqueléticos (NMS) surge con el propósito de superar esta limitación. Su principio fundamental consiste en que el exoesqueleto deje de seguir patrones de movimiento preestablecidos y pase a interactuar directamente con la fisiología del usuario [44]. Para ello, el sistema construye un modelo digital en tiempo real capaz de estimar el comportamiento de los músculos, los tendones y las señales neurales, permitiéndole inferir la intención motora del paciente. Gracias a esta información, el exoesqueleto puede proporcionar una asistencia adaptativa que complemente el esfuerzo residual del usuario, en lugar de reemplazarlo por completo. Este enfoque favorece una participación activa del paciente, un aspecto esencial para estimular los mecanismos de plasticidad neuronal y facilitar la recuperación de las funciones motoras afectadas.

### 2.3.2 Convergencia de la biomecánica y el aprendizaje profundo

Aunque los modelos neuromusculoesqueléticos (NMS) basados exclusivamente en principios físicos cuentan con una sólida fundamentación teórica, presentan una limitación metodológica importante relacionada con su escasa flexibilidad. Su utilización suele requerir procesos de calibración individualizados para cada usuario, lo que dificulta su aplicación de forma eficiente en la práctica clínica habitual [45], [46]. Con el objetivo de superar esta limitación y mejorar la capacidad de adaptación frente a la variabilidad existente entre pacientes, las investigaciones más recientes apuestan por integrar el rigor de los modelos biomecánicos con la capacidad de aprendizaje y generalización que ofrecen las técnicas de aprendizaje automático [47].

Un ejemplo representativo de esta línea de investigación es el trabajo de Zhang et al. (2023), quienes desarrollaron un controlador para un exoesqueleto de rodilla que integra un modelo neuromusculoesquelético con una red neuronal bayesiana. La principal contribución de esta arquitectura híbrida es su capacidad para estimar el grado de incertidumbre asociado a las decisiones del sistema. De este modo, cuando las señales electromiográficas presentan un elevado nivel de ruido o el modelo no puede

inferir con suficiente confianza la intención motora del usuario, el controlador reduce el nivel de asistencia y adopta un comportamiento más conservador para garantizar la seguridad. Esta capacidad de gestionar la incertidumbre no solo mejora la precisión en la estimación de los pares articulares, sino que también incrementa la fiabilidad del sistema y aporta un valor añadido en el contexto clínico, especialmente durante la rehabilitación de pacientes con patologías complejas [48].

### 2.3.3 Herramientas de código abierto

El importante avance alcanzado en este campo durante los últimos años ha estado estrechamente relacionado con la consolidación de un amplio ecosistema de herramientas de código abierto, que ha facilitado el acceso a recursos de investigación y favorecido el desarrollo científico colaborativo [49]. Entre ellas, OpenSim, desarrollado en la Universidad de Stanford, se ha convertido en la plataforma de referencia para el modelado y la simulación del sistema locomotor humano, ofreciendo un entorno robusto y reproducible para el estudio de la biomecánica y el diseño de nuevas estrategias de control [50]. La figura 2.8 muestra la interfaz de OpenSim con varios modelos musculoesqueléticos, entre ellos un exoesqueleto de tobillo. Gracias a esta herramienta, los investigadores pueden crear modelos personalizados, simular diferentes patrones de movimiento y evaluar la interacción entre el exoesqueleto y el usuario en un entorno virtual antes de realizar ensayos sobre sistemas físicos.





Figura 2.8: Interfaz de Opensim con varios modelos musculoesqueléticos. En uno de ellos se observa un exoesqueleto de tobillo. Imagen extraída de [49].

Como complemento a esta herramientas, MuJoCo (*Multi-Joint dynamics with Contact*) es un motor de simulación física de propósito general especialmente orientado al estudio de sistemas articulados y su interacción con el entorno [51]. Su elevada eficiencia computacional, su capacidad para representar contactos y actuadores y su integración con Python han favorecido su adopción en los ámbitos de la robótica y el aprendizaje por refuerzo. Estas características resultan particularmente relevantes para el entrenamiento de políticas de control, ya que este proceso requiere ejecutar un gran número de interacciones con el entorno simulado. Aunque MuJoCo no fue desarrollado específicamente como una plataforma biomecánica, su flexibilidad permite implementar modelos musculoesqueléticos y representar

elementos como articulaciones, tendones y actuadores musculares, facilitando el estudio del control neuromusculoesquelético mediante técnicas de aprendizaje automático.

Otra herramienta relevante es Scone (*Simulation-based Control Optimization of Neuromusculoskeletal Entities*), un entorno de código abierto diseñado para realizar simulaciones predictivas del movimiento humano y animal [52]. A diferencia de los métodos basados exclusivamente en la reproducción de movimientos previamente registrados, las simulaciones predictivas permiten determinar cómo se comportaría un modelo musculoesquelético ante diferentes objetivos, restricciones o estrategias de control. Para ello, Scone organiza cada experimento mediante un escenario compuesto por un modelo, un controlador, una función objetivo y un algoritmo de optimización. Esta estructura permite estudiar el control neuromuscular, analizar los efectos de modificaciones fisiológicas y optimizar dispositivos de asistencia, como prótesis, órtesis y exoesqueletos.

Scone puede utilizar modelos procedentes de OpenSim y trabajar con diferentes motores de simulación. Entre ellos se encuentra Hyfydy (*High Fidelity Dynamics*), desarrollado específicamente para ejecutar simulaciones biomecánicas con una elevada eficiencia computacional [53]. Este motor incorpora modelos de actuadores musculotendinosos de tipo Hill, contactos basados en fuerzas y un integrador con control de error capaz de adaptar automáticamente el paso temporal de la simulación. Su objetivo es combinar el nivel de detalle biomecánico característico de OpenSim con velocidades de simulación más próximas a las ofrecidas por motores como MuJoCo. Hyfydy puede emplearse como complemento de Scone o mediante una interfaz de programación en Python, lo que facilita su integración con algoritmos de aprendizaje automático. Sin embargo, a diferencia de OpenSim, MuJoCo y Scone, no se trata de una herramienta de código abierto, sino de un software distribuido mediante licencia para aplicaciones de investigación. En las figuras 2.9a y 2.9b se muestran ejemplos de simulaciones realizadas con MuJoCo y Scone, respectivamente.



(a) Modelo musculoesquelético desarrollado en el simulador Scone. En azul se muestran los músculos, y cuanto mayor activación muscular tiene un músculo, este se va poniendo más rojo. Imagen extraída de [54].



(b) Modelo humanoide desarrollado en MuJoCo. Consta de 56 grados de libertad. Imagen extraída de [55].

Figura 2.9: Ejemplos de modelos humanos desarrollados en MuJoCo y Scone.

En conjunto, estas herramientas cubren diferentes necesidades dentro del estudio del control neuromusculoesquelético. OpenSim destaca por su capacidad para construir y analizar modelos biomecánicos detallados; MuJoCo proporciona la eficiencia necesaria para ejecutar entrenamientos de aprendizaje por refuerzo; Scone facilita la formulación y optimización de simulaciones predictivas; y Hyfydy permite acelerar la ejecución de modelos biomecánicos complejos sin renunciar a la representación detallada de los músculos y los contactos.

La disponibilidad de este tipo de infraestructuras de software, muchas de ellas abiertas y estandarizadas, favorece la colaboración entre grupos de investigación y permite centrar los esfuerzos en el desarrollo de estrategias de asistencia más eficaces. Asimismo, contribuye a acelerar la transferencia de estas tecnologías desde los entornos de investigación hasta su aplicación en la práctica clínica y las sesiones de rehabilitación.

### 2.3.4 Desafíos abiertos y limitaciones

A pesar de estos avances, la incorporación definitiva de estas tecnologías a la práctica clínica diaria continúa enfrentándose a importantes desafíos tanto desde el punto de vista computacional como fisiológico. El procesamiento en tiempo real de las señales electromiográficas de superficie (EMG) presenta una elevada sensibilidad a diferentes fuentes de variabilidad. Factores como la sudoración, el desplazamiento de los electrodos o la aparición de fatiga muscular modifican continuamente la calidad de las señales registradas, dificultando su interpretación [56]. En consecuencia, el desarrollo de métodos capaces de filtrar estas perturbaciones sin introducir retardos que comprometan el funcionamiento del bucle de control sigue constituyendo uno de los principales retos de ingeniería en este ámbito [57].

A estas dificultades relacionadas con la adquisición de señales se suma la simplificación inherente a cualquier modelo computacional. La estimación no invasiva e *in vivo* de parámetros musculares dinámicos, como la longitud óptima de las fibras musculares o la rigidez de las unidades músculo-tendinosas, continúa siendo una tarea especialmente compleja. Esta limitación resulta aún más acusada en pacientes con enfermedades neuromusculares graves, ya que la presencia de atrofia, espasticidad o alteraciones anatómicas modifica de manera significativa las propiedades biomecánicas de los tejidos. Como consecuencia, los modelos musculoesqueléticos convencionales pueden no representar con suficiente precisión estas condiciones clínicas, reduciendo la exactitud de las estimaciones y del control basado en ellas.

Las investigaciones más recientes apuntan a que la estrategia más prometedora no consiste en desarrollar un modelo biomecánico matemáticamente perfecto, sino en utilizar los modelos neuromusculoesqueléticos (NMS) como una fuente de información fisiológica que complemente a los algoritmos de aprendizaje automático. Bajo este enfoque, el conocimiento biomecánico proporciona información relevante sobre el funcionamiento del sistema musculoesquelético, mientras que las técnicas de aprendizaje permiten compensar las incertidumbres y adaptarse de forma dinámica a la variabilidad e irregularidades propias de la fisiología humana [48].



## Capítulo 3

# Materiales y métodos

En este capítulo se describen las fases de desarrollo del proyecto, así como el plan de trabajo seguido para llevar a cabo la investigación. En primer lugar, se establece el marco de trabajo que se realiza con el modelo neuromusculoesquelético de cadera de dos grados de libertad implementado en MuJoCo, para posteriormente utilizar esos resultados en los motores reales. A continuación, se describe el *dummy* que es utilizado para las validaciones en el mundo real.

Sobre la base de MuJoCo, se procede a transferir el entorno de simulación de MuJoCo a Scone para entrenar un agente de aprendizaje por refuerzo que controle un exoesqueleto de asistencia a la marcha. Una vez entrenado el agente, se describen las fases de despliegue del mismo, primero en simulación y después en un *dummy* de cadera con el objetivo de validar el comportamiento del agente entrenado en un entorno real. En la figura 3.1 se muestra un diagrama del flujo de trabajo seguido en el proyecto.




Figura 3.1: Diagrama del flujo de trabajo seguido en el proyecto. En color verde se muestra el flujo de trabajo realizado en MuJoCo, en color naranja el trabajo realizado en Scone y en color azul las partes realizadas en el mundo real, tanto con los motores AK60-6 como con el *dummy* de cadera y sus motores AK80-9.

### 3.1 Control basado en modelos musculoesqueléticos para motores eléctricos

En esta sección se describe el modelo musculoesquelético que se ha usado en MuJoCo para el desarrollo del proyecto. Se ha optado por utilizar un modelo musculoesquelético de 2 grados de libertad, uno por cadera, para simular la flexión-extensión de la misma. Posteriormente, se detalla el control de este modelo musculoesquelético mediante un controlador PID, y cómo se ha usado este control para enviar el par generado por el modelo musculoesquelético a un motor AK60-6 real mediante ROS2.


#### 3.1.1 Modelo musculoesquelético MIMo

Con el objetivo de comprender el funcionamiento de un modelo musculoesquelético básico, se ha usado el entorno de la literatura conocido como MIMo obtenido de su repositorio de GitHub [58]. Es un modelo biomecánico humanoide originalmente desarrollado para la investigación del desarrollo cognitivo de niños, y consiste en un entorno de Gymnasium que trabaja sobre MuJoCo, un simulador de código abierto diseñado para simular el movimiento realista de cuerpos articulados. A fin de visualizar el modelo MIMo en la interfaz gráfica del simulador MuJoCo, se muestra la figura 3.2a.

El modelo MIMo representa un niño humano de aproximadamente 18 meses de edad, con 82 grados de libertad entre todas sus articulaciones y 6 grados de libertad en los ojos. Debido a esto, el modelo es capaz de simular una amplia gama de movimientos, lo que hace al modelo útil en investigaciones centradas en movimientos humanos. Sin embargo, para el desarrollo de este proyecto se ha optado por simplificar el modelo MIMo a un modelo musculoesquelético de 2 grados de libertad, sólo considerando el movimiento de flexo-extensión de las caderas. Además, se han modificado una serie de parámetros del entorno para mejorar la visualización y aumentar el realismo de la simulación, como la iluminación, la gravedad, las masas de los componentes del modelo o las características de las articulaciones. Gracias a estas modificaciones, es posible simular tanto modelos humanoides infantiles como modelos de adultos. El modelo simplificado usado se muestra en la figura 3.2b.



(a) Modelo MIMo en el simulador MuJoCo.



(b) Modelo MIMo simplificado con 2 grados de libertad.

Figura 3.2: Evolución del modelo MIMo utilizado en el simulador MuJoCo. La figura 3.2a muestra el modelo original, mientras que la figura 3.2b muestra el modelo simplificado.

El modelo MIMo simplificado, como se ha mencionado, sólo considera el movimiento de flexo-extensión de las caderas. Con el objetivo de exponer los ángulos máximos y mínimos físicos establecidos para cada cadera, se muestra la figura 3.3. El ángulo máximo de flexión de cadera se ha establecido en -133 grados,

mientras que el ángulo máximo de extensión de cadera es 20 grados, por lo tanto el rango de movimiento de cada cadera es de 153 grados. Estos límites son lo suficientemente amplios como para permitir un movimiento de cadera que simule la marcha humana, pero lo suficientemente estrechos como para evitar movimientos que no sean realistas. Se considera ángulo 0 cuando la pierna está en posición paralela con el torso, que en simulación siempre será una línea perpendicular con respecto al suelo.




Figura 3.3: Límites de movimiento para las caderas en el modelo MIMo simplificado.

La posición objetivo de cada una de las caderas se obtiene de la trayectoria de referencia, se compara con la posición actual de cada cadera, y la diferencia entre ambas posiciones se introduce en el controlador PID. Para que ambas caderas no tengan la misma posición objetivo se establece un desfase del 50 % de la trayectoria de paso de cadera, de manera que cuando una cadera está en flexión, la otra se sitúa en extensión. Esto simula un movimiento natural de marcha humana. Además, dado que la posición inicial del entorno de MIMo es con ambas caderas en reposo, se ha establecido un desfase inicial en las posiciones objetivo para coincidir con la posición inicial de la trayectoria de referencia, que se corresponde con 0 grados de flexión de cadera. Así, la posición objetivo de la cadera derecha se describe en la ecuación (3.1).

$$q_{d_r}(t) = \text{trayectoria\_sana}(t + \text{desfase\_inicial}) \quad (3.1)$$

Y la posición objetivo de la cadera izquierda se muestra en la ecuación (3.2).

$$q_{d_l}(t) = \text{trayectoria\_sana}(t + \text{desfase\_50\%} + \text{desfase\_inicial}) \quad (3.2)$$

O lo que es lo mismo, la posición objetivo de la cadera izquierda es la misma que la de la cadera derecha pero con un desfase del 50 % de la trayectoria de referencia. Así, las posiciones objetivo de cada cadera son las mostradas en la figura 3.4. La velocidad de la trayectoria se ha establecido de tal forma que se tarda 2.1 segundos en completar un ciclo de marcha, lo que se corresponde con una velocidad de marcha normal en adultos sanos [59].

El modelo musculoesquelético de MIMo consta de un modelo muscular el cual, en base a unas activaciones musculares de entrada, genera un movimiento en el modelo simulado. Es por eso que, teniendo la trayectoria de referencia de marcha para la articulación de cadera y haciendo uso de un controlador PID que genere las señales de activaciones musculares, es posible mover el modelo musculoesquelético de




Figura 3.4: Comienzo de posiciones objetivo de cada cadera. La línea azul representa la posición objetivo de la cadera derecha, y la línea naranja representa la posición objetivo de la cadera izquierda. Obtenida a partir de Winter (1991) y Perry y Burnfield (2010).

manera que siga la trayectoria de referencia. Esta trayectoria de cadera, que se puede observar en la figura 3.4, se ha obtenido en base a la literatura, concretamente de Winter (1991) y Perry y Burnfield (2010). En la figura 3.5 se muestra el esquema de control que se usa junto con el modelo musculoesquelético en MuJoCo.




Figura 3.5: Esquema de control utilizado en MuJoCo con el fin de mover el modelo musculoesquelético.

El error de seguimiento  $e(t)$  de cada cadera se introduce en el controlador PID del esquema de control, definido según la ecuación 3.3.

$$\tau(t) = K_P e(t) + K_I \int_0^t e(\tau) d\tau - K_D \dot{q}(t) \quad (3.3)$$

donde

$$e(t) = q(t) - q_{\text{ref}}(t) \quad (3.4)$$

- $K_P$  es la ganancia proporcional.
- $K_I$  es la ganancia integral.

- $K_D$  es la ganancia derivativa.
- $q(t)$  es la posición actual de la articulación.
- $q_{\text{ref}}(t)$  es la posición actual de referencia.
- $\dot{q}(t)$  es la velocidad angular de la articulación.
- $e(t)$  es el error de seguimiento.
- $\tau(t)$  es el par aplicado por el controlador.

Los valores utilizados para las ganancias del controlador PID en el entorno simulado se muestran en la tabla 3.1. Dichos valores se han obtenido de forma experimental, probando distintas combinaciones de valores hasta encontrar la que mejor seguía la trayectoria de referencia de cadera.

| Término | Valor |
|---------|-------|
| $K_P$   | 0,7   |
| $K_I$   | 0,3   |
| $K_D$   | 0,0   |

Tabla 3.1: Ganancias del controlador PID de la cadera simulada en MuJoCo.

El controlador PID descrito genera un señal de salida para cada cadera, que posteriormente se normaliza entre -1 y 1. Si el resultado de la normalización es positivo se activa el flexor de esa cadera, y si es negativo se activa el extensor muscular, ambos con la correspondiente normalización. Esto provoca que, en función del par generado por el controlador PID implementado, se genere una señal de activación normalizada que se introduce en el modelo muscular de cada cadera, generando un movimiento en el modelo musculoesquelético simulado que sigue la trayectoria de referencia de cadera.

Este movimiento de cadera del modelo musculoesquelético MIMO genera un par articular continuo en cada cadera, que es el que provoca el movimiento del modelo musculoesquelético. De esta manera, el modelo musculoesquelético simulado se mueve siguiendo la trayectoria de referencia de cadera.

### 3.1.2 Control de un motor eléctrico basado en el modelo musculoesquelético

La similitud entre el modelo musculoesquelético simulado y el modelo real se valida gracias al par generado por el modelo muscular simulado. Mediante ROS2, ese par generado en cada cadera por el modelo simplificado MIMO en MuJoCo es enviado a un actuador AK60-6 Cubemars real. Es un motor completo que incluye motor BLDC, reductor 6:1, controlador integrado y encoder que permite controlar el movimiento de manera precisa y eficiente. Con un par pico de 9 Nm, estos actuadores ofrecen un alto rendimiento en términos de precisión y eficiencia [60].

La conexión entre el motor y el ordenador personal se realiza mediante un dispositivo llamado *CANdle*, diseñado para controlar actuadores. Este dispositivo permite la comunicación entre el ordenador y motores de la serie MD sin necesidad de usar un protocolo de comunicación adicional, y además permite el control de varios motores a la vez. En la figura 3.6 se muestra el dispositivo *CANdle*.


El esquema de la conexión de este dispositivo *CANdle* con el motor AK60-6 y el ordenador personal se muestra en la figura 3.7a. Se observa que el motor está conectado únicamente con el dispositivo *CANdle*, y que es este dispositivo el que se conecta con el resto de componentes. Pese a que es posible conectar el motor al ordenador mediante SPI o UART, se ha optado por usar únicamente un cable USB-C porque es




Figura 3.6: Vista frontal del *CANdle*. Se observa el puerto de conexión USB-C para la conexión al ordenador personal.

más sencillo y cómodo. Por otro lado, las baterías utilizadas son baterías de polímero de litio de 3 celdas y 11,1 V, que proporcionan la energía necesaria para alimentar tanto el motor AK60-6 como el dispositivo *CANdle* [61]. Las baterías, además, tienen un conector XT60, que es un tipo de conector ampliamente utilizado en aplicaciones de robótica y vehículos eléctricos debido a su alta capacidad de corriente y su fiabilidad. Este conector permite una conexión segura y estable entre las baterías y el dispositivo *CANdle*, garantizando un suministro de energía constante y eficiente para el funcionamiento del motor AK60-6.

El esquema de conexión completo del ecosistema de MAB Robotics con los dispositivos hardware se muestra en la figura 3.7a. Además, en la figura 3.7b se muestra el ecosistema de MAB Robotics con los dispositivos hardware en el mundo real.



(a) Diagrama de conexión del motor AK60-6 con el dispositivo *CANdle*. El dispositivo *CANdle* se conecta al ordenador personal mediante un cable USB-C.



(b) Ecosistema de MAB Robotics con dispositivos hardware. Se observa cómo ambas baterías se conectan al dispositivo *CANdle*, al igual que el motor AK60-6. El dispositivo *CANdle* se conecta al ordenador personal mediante un cable USB-C.

Figura 3.7: Ecosistema de MAB Robotics con dispositivos hardware. Se muestra tanto el diagrama de conexión del motor AK60-6 con el dispositivo *CANdle* como el ecosistema real completo.

A continuación se describen los distintos elementos de la figura 3.7:

- a: Cable USB-C que conecta el dispositivo *CANdle* con el ordenador personal.
- b: Dispositivo *CANdle* que permite la comunicación entre el ordenador personal y el motor AK60-6.
- c: Cable de conexión entre el dispositivo *CANdle* y las baterías.

- d: Baterías que alimentan el motor AK60-6 y el dispositivo *CANdle*.
- e: Cable de conexión entre el dispositivo *CANdle* y el motor AK60-6.
- f: Motor AK60-6.

Pese a que es posible establecer una conexión entre el ordenador personal y el motor mediante bibliotecas de Python, se ha optado por utilizar ROS2 para la comunicación entre el ordenador personal y el motor AK60-6. Esto se debe a que ROS2 es un framework de código abierto ampliamente utilizado en robótica, que proporciona herramientas y bibliotecas para el desarrollo de aplicaciones robóticas. Además, permite la comunicación entre diferentes nodos de manera eficiente y escalable, lo que facilita la integración de diferentes componentes del sistema. El esquema de ROS2 desarrollado para la comunicación entre el ordenador personal y el motor AK60-6 se muestra en la figura 3.8.




Figura 3.8: Diagrama de la comunicación con el motor AK60-6 mediante ROS2.

El código desarrollado crea el nodo ROS2 llamado *mimo\_hip\_torque\_replay\_runner*. Este nodo tiene un publisher que publica el par generado por una de las caderas del modelo musculoesquelético simulado en MuJoCo al motor real, y un subscriber que recibe la posición, la velocidad y el par aplicado al motor, que es el mismo que se envió desde el publisher.

El par generado por el modelo musculoesquelético en el simulador MuJoCo se envía al motor AK60-6 mediante ROS2, y la trayectoria seguida por la cadera simulada se compara con la trayectoria obtenida en el motor real. De esta manera, se puede validar el comportamiento del modelo musculoesquelético desarrollado en MuJoCo en el mundo real, y comprobar si el par generado por el modelo musculoesquelético es suficiente para mover la articulación de cadera del motor AK60-6 siguiendo la trayectoria de referencia de cadera. En caso de que el par generado por el modelo musculoesquelético no sea suficiente para mover la articulación de cadera del motor AK60-6, se puede ajustar el controlador PID del modelo musculoesquelético para generar un par mayor, o se puede ajustar el modelo musculoesquelético para que se requiera un par mayor para mover la articulación de cadera.

## 3.2 Control de cadera de un *dummy* bio-inspirado basado en el modelo musculoesquelético

La presente sección describe el diseño y características principales del *dummy* de cadera que se utiliza para validar los algoritmos desarrollados en el mundo real.

### 3.2.1 *Dummy* de cadera bio-inspirado

Se entiende por *dummy* de cadera a un modelo físico de pruebas que sirve para validar en el mundo real un algoritmo de control antes de su despliegue en el entorno final. En el caso de este trabajo, las comprobaciones experimentales en el mundo real se realizan en un *dummy* de cadera, diseñado por D. Andrés Chavarrías, miembro del grupo de investigación NAIR del CSIC del que he formado parte durante el desarrollo de este proyecto, creado mediante una impresora 3D y compuesto por un torso y dos muslos que simulan la parte inferior del cuerpo humano. Una imagen del *dummy* que se usa en este trabajo se puede observar en la figura 3.9.




Figura 3.9: *Dummy* de pruebas. Se observa que dentro del torso se encuentran las baterías para alimentar todo el circuito.

Los elementos mecánicos que se utilizan para el movimiento de cadera son motores AK80-9. Son iguales que los motores AK60-6 mencionados anteriormente, pero con un reductor 9:1 y un par pico mayor, alcanzando un máximo de 18 Nm. Un ejemplo de este motor se muestra en la figura 3.10. Al usar un motor AK80-9 para cada cadera, el *dummy* de cadera tiene un total de 2 grados de libertad, lo que permite simular el movimiento de flexo-extensión de cadera, que es el principal movimiento de la articulación de cadera durante la marcha humana.

Con el fin de proporcionar una descripción detallada del *dummy* se incluye la tabla 3.2, que muestra la masa de cada componente. Además, la tabla 3.3 muestra las dimensiones de los principales componentes del *dummy* de cadera.



Figura 3.10: Motor AK80-9. Figura obtenida de la página web de MAB Robotics [62].

| Parte del <i>dummy</i> | Masa (kg)    |
|------------------------|--------------|
| Muslo izquierdo        | 0,500        |
| Muslo derecho          | 0,500        |
| Torso                  | 3,700        |
| Motor izquierdo        | 0,485        |
| Motor derecho          | 0,485        |
| <b>Total</b>           | <b>5,670</b> |

Tabla 3.2: Masa de los componentes del *dummy*.

| Parte del <i>dummy</i> | Dimensiones (cm)                          |
|------------------------|-------------------------------------------|
| Muslos                 | 22 altura, 15 diámetro                    |
| Torso                  | 42,1 altura, 41 anchura hombros           |
| Pelvis                 | 15,9 altura, 30 anchura, 17,4 profundidad |

Tabla 3.3: Dimensiones de los componentes del *dummy*.

Finamente, en la figura 3.11 se muestran los límites de movimiento de las caderas del *dummy*. El ángulo máximo de flexión de cadera se ha establecido en 82,5 grados, y el de extensión de cadera en -85,6. De nuevo, se considera ángulo 0 cuando la pierna está en posición paralela con el torso.

### 3.2.2 Implementación del modelo musculoesquelético en Scone

Una vez mostrado el control de un modelo musculoesquelético de 2 grados de libertad con la base de MIMo, se procede a trasladar el entorno de simulación de MuJoCo a Scone con el objetivo de utilizar el modelo musculoesquelético en un entorno de simulación más completo y realista que MuJoCo. En el presente trabajo, Scone se utiliza para el entrenamiento del agente de aprendizaje por refuerzo, así como para la validación del comportamiento del agente entrenado en un entorno de simulación más realista que MuJoCo.

La integración entre el lenguaje de programación Python y Scone se realiza mediante la API de Scone llamada SconePy. Esta API permite a los usuarios interactuar con Scone desde el lenguaje de programación Python, lo que facilita la creación de entornos de simulación personalizados y la integración con otros paquetes de Python. Gracias a esto, es posible generar un entorno de simulación en Scone que se pueda usar con librerías de aprendizaje por refuerzo. Además, SconePy está diseñado con soporte para retardos neurológicos y permite la integración de modelos biológicos complejos con activaciones musculares reales y no actuadores simplificados con par como en MuJoCo. Esto garantiza un aprendizaje




Figura 3.11: Vista lateral del *dummy* de pruebas con los límites de movimiento para sus caderas.

más realista y preciso del agente debido a que se tiene en cuenta la dinámica del sistema biológico y las limitaciones de tiempo en la respuesta del sistema nervioso. Se puede observar un diagrama del flujo de entrenamiento del agente en la figura 3.12.




Figura 3.12: Diagrama del flujo de entrenamiento de un agente de aprendizaje por refuerzo.

En nuestro caso, el entorno es el modelo musculoesquelético en Scone, la recompensa es una función matemática que evalúa el rendimiento del agente, las observaciones son los datos que el agente recibe del entorno y la acción es la decisión que toma el agente en base a las observaciones recibidas. El objetivo del agente es maximizar la recompensa acumulada a lo largo del tiempo, aprendiendo a tomar decisiones óptimas.

Usando el trabajo realizado en la sección 3.1 con el modelo musculoesquelético diseñado en MuJoCo, el compañero D. Andrés Chavarrías utilizó este trabajo como base para crear un entorno de simulación en Scone lo más similar posible al entorno del modelo musculoesquelético simplificado de MuJoCo con el objetivo de utilizar un motor especializado en biomecánica y control muscular. Dicho modelo en Scone se expone en la figura 3.13.

En la figura 3.13 se observa el modelo musculoesquelético de 2 grados de libertad en Scone, que consiste en un esqueleto humanoide sin brazos ni miembros inferiores por debajo de las rodillas. Además, se observan 2 músculos en cada cadera, siendo el glúteo mayor y el iliopsoas. Pese a que una cadera humana tiene 3 grados de libertad, las caderas simuladas únicamente permiten el movimiento en uno de estos ejes, el eje de flexo-extensión. Esto se debe a que el movimiento de abducción-aducción y el




Figura 3.13: Modelo musculoesquelético en Scone. Se muestran en azul los músculos del modelo, concretamente el glúteo mayor y el iliopsoas de cada cadera.

de rotación de cadera son mínimos durante la marcha humana, y por tanto no son relevantes para el entrenamiento del agente. Con el fin de mostrar un resumen de la presente sección, se muestra la figura 3.14.




Figura 3.14: Modelo musculoesquelético en Scone y el *dummy* robótico.

En este caso, el ángulo máximo establecido en flexión de cadera es de 120 grados, mientras que el ángulo máximo de extensión de cadera es de -30. Por lo tanto, el rango de movimiento de cada cadera es de 150 grados, que es un rango de movimiento suficiente para simular la marcha humana. De nuevo, se considera ángulo 0 cuando la pierna está en posición paralela con el torso.

### 3.2.3 Interfaz gráfica de control

De forma paralela, se ha desarrollado una interfaz gráfica (GUI) que permite la visualización en tiempo real de la posición, la velocidad y el par de los motores, así como permitir el movimiento de ambos motores. Esta interfaz se ha desarrollado utilizando la aplicación QT 5 Designer, que permite a los desarrolladores crear interfaces gráficas de manera visual y sencilla gracias al método de arrastrar y soltar, sin necesidad de escribir código. Además, la interfaz gráfica también permite el lanzamiento del simulador MuJoCo con el entorno simplificado MIMo y el entrenamiento del agente de aprendizaje por refuerzo.

A continuación se describen las funcionalidades de la interfaz gráfica desarrollada, y cada una de las distintas partes se ha marcado con un recuadro de color para facilitar su identificación. En primer lugar, la figura 3.15 muestra la pantalla principal de la interfaz gráfica desarrollada.




Figura 3.15: Pantalla principal de la interfaz gráfica desarrollada.

En la parte superior izquierda, en color rojo, se encuentra un botón para añadir los motores conectados al ordenador personal. Dicho botón se utiliza para añadir los motores conectados físicamente al *CANdle* al nodo de ROS2. A su derecha, de amarillo, hay un selector del modo de control de los motores. Pese a que los motores permiten seleccionar más modos de control, la interfaz gráfica únicamente permite seleccionar el modo de impedancia. De nuevo, a su derecha, en color verde se encuentra un botón para seleccionar los motores que se desean habilitar, pudiendo habilitar indistintamente uno o ambos motores.

En la parte izquierda de la interfaz se muestran 2 gráficas en un recuadro de color azul: la superior muestra en tiempo real el par y la velocidad de los motores seleccionados, y la gráfica inferior muestra en tiempo real la posición de los motores.

En la parte superior derecha, en color naranja, se muestra un panel de control de 3 pestañas. La primera pestaña permite seleccionar las ganancias del modo impedancia de los motores, además de poder seleccionar la posición objetivo de los mismos, ya sea de forma manual enviando una posición fija o enviando una trayectoria sinuoidal. Un ejemplo de esta pestaña funcionando se muestra en la figura 3.16.

En la figura 3.16 se observa cómo a la cadera izquierda se le envía una posición fija, mientras que a la cadera derecha se le ha enviado una trayectoria sinuoidal. Además, en las gráficas se pueden ver los




Figura 3.16: Interfaz gráfica con el panel de impedancia funcionando y gráficas de posición, velocidad y par en tiempo real.

últimos segundos de las posiciones, pares y velocidad derecha. La velocidad izquierda se ha desactivado (véase su botón desactivado) porque es 0 debido a que su posición es fija.

Desde el panel del simulador, que se puede observar en la figura 3.17, es posible lanzar la simulación del entorno MIMO simplificado en MuJoCo de la misma forma que se ha descrito en la sección 3.1.



Figura 3.17: Interfaz gráfica con el panel del simulador con entorno MIMO.

Aunque no es posible modificar todos los parámetros del entorno de simulación, sí que es posible modificar los más importantes, siendo estos:

- Número de ciclos a realizar.
- Ganancia proporcional del controlador PID (0-2).
- Ganancia integral del controlador PID (0-1).
- Ganancia derivativa del controlador PID (0-0.15).
- Escala de masa del modelo musculoesquelético (0.5-3).
- Escala de rigidez de las articulaciones del modelo musculoesquelético (0.1-2.5).
- Escala de amortiguamiento de las articulaciones del modelo (0.1-2.5).
- Escala de pérdida por fricción de las articulaciones del modelo (0.1-2.5).
- Escala de inercia de las articulaciones (0.1-2).

Todas estas opciones permiten modificar el entorno de simulación para que se asemeje lo máximo posible al entorno real, y permite realizar pruebas para validar si el comportamiento del modelo es adecuado. Como el botón de lanzamiento de la simulación está conectado al mismo script de python que lanza la simulación en MuJoCo del modelo musculoesquelético simplificado en la sección 3.1, los datos de la simulación son guardados de la misma forma para su posterior análisis. Esto permite comparar los resultados obtenidos en distintas ejecuciones del simulador con diversas configuraciones y, gracias a la interfaz, es posible realizar estas pruebas de manera rápida y sencilla.

La figura 3.18 muestra la salida tras lanzar una simulación, donde aparece una ventana en la que se observa el modelo musculoesquelético simplificado a partir del modelo MIMO descrito en la sección 3.1.1.




Figura 3.18: Salida de la simulación desde la interfaz. En el fondo de la imagen la ventana de la interfaz gráfica desarrollada, y en primer plano la ventana del simulador MuJoCo con el modelo MIMO simplificado.

Similar al panel del simulador, el panel del entrenamiento permite lanzar el entrenamiento de un agente en python utilizando SconePy de la misma manera que se ha descrito en la sección 3.3.1. El proceso de entrenamiento del agente de aprendizaje por refuerzo se detalla en la sección 3.3.1.

Dicho panel de entrenamiento puede observarse en la figura 3.19, y permite seleccionar el número de episodios que se desea entrenar y la frecuencia de guardado del agente entrenado, aunque los pesos de la función de recompensa no se pueden modificar desde la interfaz. Al igual que en el panel del simulador, el botón de lanzamiento del entrenamiento está conectado al mismo script de python que




Figura 3.19: Interfaz gráfica del panel de entrenamiento. Se observa el selector de episodios y el selector de la frecuencia de guardado del agente. Además, se muestra un panel con la salida del terminal de la ejecución de un entrenamiento.

lanza el entrenamiento en la sección 3.3.1, por lo que los datos del entrenamiento son guardados de la misma forma para su análisis mediante inferencia, ya sea en el simulador de Scone o en el *dummy* real. Además, se ha diseñado un panel que muestra la salida del terminal de la ejecución del entrenamiento para que el usuario pueda visualizar en tiempo real el progreso de entrenamiento, así como los datos que se serializan de forma periódica. Este panel se muestra también en la figura 3.19 inmediatamente debajo del botón de lanzamiento del entrenamiento.

En la parte inferior de la interfaz, con un recuadro de color morado, se encuentra una tabla con los datos, también en tiempo real, que nos ofrecen ambas gráficas, añadiendo además la corriente y el voltaje de los motores.

Por último, en color rosa y en la parte inferior derecha se muestra una opción para guardar datos de los motores. Esto permite guardar mediante *rosbag* la posición, la velocidad y el par de cada motor, tanto los valores enviados como los valores recibidos, para su posterior análisis. Además, se ofrece la posibilidad de seleccionar la carpeta de guardado, así como el nombre del archivo a guardar. Esto permite guardar los datos de la interfaz gráfica de manera rápida y sencilla. Los datos guardados se pueden visualizar con cualquier herramienta de visualización de *rosbag*, y en el caso de este proyecto se ha usado la herramienta *PlotJuggler*, que permite visualizar los datos de manera rápida y sencilla.

El conjunto de figuras 3.20 muestran algunos de los datos a visualizar haciendo uso de la herramienta *PlotJuggler*. Gracias a los datos guardados con las métricas mostradas en la figura 3.16, que también se muestran en la tabla 3.4, se puede observar cómo ambos motores siguen la trayectoria de referencia.

La ganancia  $K_p$  representa la ganancia de posición, mientras que la ganancia  $K_d$  representa la ganancia de velocidad. Debido a la diferencia entre las ganancias de ambos motores, la cadera izquierda tiene un comportamiento más rígido que la cadera derecha. En cambio, la cadera derecha tiene un comportamiento más flexible debido a que su ganancia de posición es menor y su ganancia de velocidad es mayor, lo que

| Métrica          | Parámetro            | Valor |
|------------------|----------------------|-------|
| Cadera izquierda | Ganancia Kp          | 1,2   |
|                  | Ganancia Kd          | 0,2   |
|                  | Posición manual      | 100°  |
| Cadera derecha   | Ganancia Kp          | 1,0   |
|                  | Ganancia Kd          | 0,4   |
|                  | Trayectoria senoidal | -     |
|                  | Amplitud             | 95°   |
|                  | Frecuencia           | 1 Hz  |
|                  | Ciclos               | 7     |

Tabla 3.4: Parámetros de control para ambos motores al grabar datos desde la interfaz de usuario.

se traduce en un movimiento más suave, aunque tendrá un peor seguimiento de trayectorias. La ecuación del par aplicado por el motor a la cadera es la siguiente:

$$\tau = K_p \cdot (q_{ref} - q) + K_d \cdot (\dot{q}_{ref} - \dot{q}) \quad (3.5)$$

donde


- $\tau$  es el par aplicado por el motor.
- $K_p$  es la ganancia de posición.
- $K_d$  es la ganancia de velocidad.
- $q_{ref}$  es la posición de referencia enviada al motor.
- $q$  es la posición real del motor.
- $\dot{q}_{ref}$  es la velocidad de referencia enviada al motor.
- $\dot{q}$  es la velocidad real del motor.

La posición manual es la posición fija a la que se ha enviado la cadera izquierda, mientras que la trayectoria senoidal es la trayectoria que se ha enviado a la cadera derecha. La amplitud representa el valor máximo de la trayectoria senoidal, mientras que la frecuencia representa el número de ciclos por segundo de la trayectoria senoidal. Por último, los ciclos representan el número de ciclos que se han enviado a la cadera derecha. De esta forma, la cadera izquierda se ha enviado a una posición fija de 100°, mientras que la cadera derecha se ha enviado a una trayectoria senoidal de la forma:

$$y(t) = 95 \cdot \sin(2\pi t) \quad (3.6)$$


La figura 3.20a muestra la interfaz de *PlotJuggler* con la posición de ambos motores durante la grabación de datos. Su gráfica azul representa la posición angular de la cadera izquierda, mientras que su gráfica verde representa la posición angular de la cadera derecha. Por otra parte, la figura 3.20b muestra la interfaz con la posición real del motor derecho, en verde, y su posición objetivo en ese instante de tiempo, en naranja, que en este caso es la mostrada en la ecuación (3.6). Por último, la figura 3.20c muestra la velocidad y el par de ambos motores durante el rosbag. La gráfica roja representa la velocidad del motor izquierdo, mientras que la gráfica amarilla representa la velocidad del motor derecho. La gráfica

azul celeste representa el par del motor izquierdo, mientras que la gráfica azul oscuro representa el par del motor derecho.



(a) Interfaz con posición de ambos motores durante la grabación de datos. La gráfica azul representa la cadera izquierda, mientras que la gráfica verde representa la cadera derecha.

(b) Interfaz con posición real del motor derecho y su posición objetivo. La posición real se representa en color verde mientras que la posición objetivo se representa en color naranja.



(c) Interfaz con velocidad y par de ambos motores.

Figura 3.20: Visualización de datos de los motores mediante la herramienta PlotJuggler.

### 3.3 Entrenamiento de un exoesqueleto de cadera usando aprendizaje por refuerzo

En esta sección se detalla todo el proceso de entrenamiento de un agente de aprendizaje por refuerzo para controlar un exoesqueleto de cadera de asistencia a la marcha. Se describe todo el flujo de trabajo seguido, la creación del entorno de simulación en Scone, los parámetros usados durante el entrenamiento y la función de recompensa utilizada. Finalmente, se expone el proceso de inferencia del agente entrenado en el entorno de simulación y en el *dummy* de cadera.

El grupo de investigación NAIR del CSIC me ha proporcionado una licencia del software Hyfydy, que es un motor de simulación que ofrece una gran mejora en rendimiento y velocidad de simulación en comparación con el motor de simulación predeterminado de Scone. Esto provoca una gran mejora en la velocidad de entrenamiento

### 3.3.1 Entrenamiento en tarea de asistencia del exoesqueleto usando Aprendizaje por Refuerzo

Dado que la función del agente es controlar un exoesqueleto de asistencia a la marcha, es imprescindible desarrollar un exoesqueleto de cadera que pueda interactuar con el modelo musculoesquelético en Scone. Para ello, se ha añadido un exoesqueleto acoplado a las caderas del modelo musculoesquelético mostrado en la figura 3.13, que se encarga de asistir al movimiento de la marcha. Dicho exoesqueleto acoplado al modelo musculoesquelético se muestra en la figura 3.21.




Figura 3.21: Modelo musculoesquelético con exoesqueleto en Scone.

#### Función de recompensa

El agente entrenado se encarga de controlar los movimientos del exoesqueleto para asistir a la marcha del modelo humanoide, proporcionando soporte y ayuda en el movimiento de la cadera. Asimismo, la función de recompensa del agente puede modificarse para incentivar diferentes comportamientos, como minimizar el esfuerzo muscular del modelo musculoesquelético, suavizar el par aplicado por el exoesqueleto o minimizar el coste energético del motor. Dicha función de recompensa se define por la ecuación (3.7).

$$R_{\text{total}} = \sum_{n=1}^5 w_n R_n \quad (3.7)$$

Siendo  $R_n$  cada una de las recompensas y  $w_n$  el peso de cada una de ellas. La función de recompensa completa es se describe en la ecuación (3.8).

$$R_{\text{total}} = w_1 R_{\text{posición}} + w_2 R_{\text{velocidad}} - w_3 R_{\text{coste}} - w_4 R_{\text{suavidad}} - w_5 R_{\text{activaciones}} \quad (3.8)$$

A continuación se describen cada una de las recompensas que componen la función de recompensa total (3.8):

- $w_1, w_2, w_3, w_4, w_5$  son los pesos de cada una de las recompensas.

- $R_{\text{total}}$  es la recompensa total.
- $R_{\text{posición}}$  es la recompensa en función de la diferencia entre la posición actual del exoesqueleto y la posición objetivo. Premia que el exoesqueleto siga la referencia angular en ambas caderas y perjudica los errores de posición. La fórmula de esta recompensa es la siguiente:

$$R_{\text{posición}} = e^{-8 * \text{error}_p} \quad (3.9)$$

Se ha utilizado un factor de penalización de 8 para castigar los errores de posición de una forma agresiva, de manera que el agente aprenda a minimizar los errores de posición de forma más rápida.

El error es la suma de los cuadrados de los errores de posición de ambas caderas, es decir:

$$\text{error}_{\text{total}} = \text{error}_D^2 + \text{error}_I^2 \quad (3.10)$$

donde  $\text{error}_D$  y  $\text{error}_I$  son la diferencia entre la posición objetivo de la cadera y la posición actual de la cadera derecha e izquierda, respectivamente. El error de posición total  $\text{error}_{\text{total}}$  es la suma de los errores de ambas caderas.

- $R_{\text{velocidad}}$  es la recompensa en función de la diferencia entre la velocidad actual del exoesqueleto y la velocidad objetivo. Esta recompensa favorece que la velocidad angular del exoesqueleto siga la referencia en ambas caderas y perjudica errores en la velocidad. Al igual que la recompensa de posición, esta recompensa se calcula de forma similar:

$$R_{\text{velocidad}} = e^{-0,5 * \text{error}_v} \quad (3.11)$$

$$\text{error}_{\text{total}} = \text{error}_D^2 + \text{error}_I^2 \quad (3.12)$$

En este caso, el factor de penalización es de 0,5, lo que significa que los errores de velocidad son penalizados de forma menos agresiva que los errores de posición. La diferencia entre la recompensa de posición (3.9) y la recompensa de velocidad (3.11) es que la recompensa de posición tiene un factor de penalización mayor, lo que se traduce en una mayor penalización por errores que la función de recompensa de velocidad.

- $R_{\text{coste}}$  mide el coste de la acción tomada por el agente. Premia usar poco los motores para favorecer la eficiencia energética y penaliza el uso excesivo de los motores. La función de coste se describe en la ecuación (3.13).

$$R_{\text{coste}} = - \frac{\text{acción\_anterior}_D^2 + \text{acción\_anterior}_I^2}{2} \quad (3.13)$$

donde  $\text{acción\_anterior}_D$  y  $\text{acción\_anterior}_I$  son las acciones tomadas por el agente en el paso de tiempo anterior para la cadera derecha e izquierda, respectivamente. Dichas acciones pueden tomar valores entre -1 y 1. Esta recompensa penaliza el uso excesivo de los motores, ya que un uso excesivo de los motores puede provocar un sobrecalentamiento de los mismos y un desgaste prematuro de los componentes del exoesqueleto.

- $R_{\text{suavidad}}$  mide la suavidad del movimiento del motor con respecto a la acción anterior. Esta recompensa premia que el motor se mueva de manera suave y penaliza movimientos bruscos.

$$R_{\text{suavidad}} = -\frac{\text{diferencia}_D^2 + \text{diferencia}_I^2}{2} \quad (3.14)$$

$\text{diferencia}_D$  y  $\text{diferencia}_I$  representan la diferencia entre las 2 acciones anteriores, es decir, si la acción que debe tomar el agente es  $a_t$ , la diferencia se expresa de la forma descrita en la ecuación (3.15) para la cadera derecha. Como recordatorio, la acción que toma el agente es un valor entre -1 y 1.

$$\text{diferencia}_D = a_{t-1} - a_{t-2} \quad (3.15)$$

Y de forma similar, para la cadera izquierda:

$$\text{diferencia}_I = a_{t-1} - a_{t-2} \quad (3.16)$$

- $R_{\text{activaciones}}$  mide el nivel de activaciones musculares del modelo musculoesquelético. Por último, esta recompensa favorece que los músculos del modelo musculoesquelético se activen lo menos posible y penaliza activaciones excesivas de los 4 músculos, siendo estos el glúteo mayor y el iliopsoas de ambas piernas. Dado que tenemos en total 4 músculos, la función de recompensa se calcula de la siguiente manera:

$$R_{\text{activaciones}} = -\frac{\sum_{n=1}^4 \text{act}_n^2}{4} \quad (3.17)$$

Siendo  $\text{act}_n$  la activación del paso anterior de cada uno de los 4 músculos del modelo musculoesquelético. La activación muscular es un valor entre 0 y 1 que representa el grado de contracción de un músculo, donde 0 significa que el músculo está completamente relajado y 1 significa que el músculo está completamente contraído.

Los pesos utilizados en la función de recompensa 3.8 se han establecido de la forma expuesta en la tabla 3.5.

| Término                | Recompensa |
|------------------------|------------|
| Posición ( $w_1$ )     | 0,15       |
| Velocidad ( $w_2$ )    | 0,90       |
| Coste ( $w_3$ )        | 0,60       |
| Suavidad ( $w_4$ )     | 0,50       |
| Activaciones ( $w_5$ ) | 0,25       |

Tabla 3.5: Pesos de cada término de la función de recompensa.

A estos efectos, la ponderación más alta se corresponde con la recompensa de velocidad, ya que es importante que el exoesqueleto siga la referencia de velocidad angular de cadera, y la ponderación más baja se corresponde con la recompensa de posición. Esto se debe a que es preferible que el exoesqueleto aprenda a seguir la velocidad adecuada aunque no siga la posición exacta porque si el agente aprende a seguir posición, el par generado por el agente sería irregular con el objetivo de buscar esa posición exacta, mientras que si se sigue la velocidad, el par generado sería más suave y estable. Por otro lado, las recompensas de coste, suavidad y activaciones musculares tienen una ponderación intermedia, ya que son importantes para el rendimiento del exoesqueleto pero no son tan críticas como la velocidad y la posición.

Cabe resaltar que, según la función de recompensa 3.8 y los pesos establecidos en los términos de la misma 3.5, el valor máximo que puede obtener el agente en cada paso de tiempo es 1,05, mientras que el valor mínimo es -3,43. Asimismo, el valor máximo de la recompensa en un episodio completo se corresponde con 1050, mientras que el valor mínimo sería -3433,33. Esto se debe a que cada episodio tiene una duración de 1000 pasos de tiempo. El objetivo del agente es maximizar la recompensa total obtenida en cada episodio, aprendiendo a tomar decisiones que le permitan obtener la mayor recompensa posible.

### Observaciones del entorno

Para que el agente aprenda de manera eficiente es necesario seleccionar correctamente las observaciones del entorno que recibe el agente, ya que estas observaciones son las que el agente utiliza para aprender a tomar decisiones. Las observaciones que recibe el agente son las siguientes:

- Fase derecha e izquierda del ciclo de marcha.
- Posiciones angulares de la cadera.
- Velocidades angulares de la cadera.
- Posiciones objetivo de la cadera.
- Velocidades objetivo de la cadera.
- Diferencia entre las posiciones actuales y las posiciones objetivo de la cadera (error de posición).
- Diferencia entre las velocidades actuales y las velocidades objetivo de la cadera (error de velocidad).
- Posiciones angulares del exoesqueleto.
- Velocidades angulares del exoesqueleto.
- Última acción tomada por el agente.

Es importante resaltar que, al entrenar en simulación, las posiciones y velocidades de la cadera y del exoesqueleto son las mismas, ya que el exoesqueleto está acoplado al modelo musculoesquelético. Sin embargo, si se entrenase en el *dummy* real con un exoesqueleto real, las posiciones y velocidades de la cadera y del exoesqueleto no serían exactamente idénticas y por eso se le pasan ambos valores. Además, de las 10 observaciones anteriores, el agente obtiene el doble, ya que tenemos 2 caderas, y la fase tiene tanto seno como coseno, por lo que el total de observaciones que recibe el agente es de 22.

### Algoritmo de entrenamiento

En cuanto al algoritmo de entrenamiento existen varias opciones [63]:

- **PPO (Proximal Policy Optimization):** es un algoritmo de aprendizaje por refuerzo basado en políticas de gradiente pero es on-policy, por lo que se necesitan muchas interacciones con el entorno.
- **SAC (Soft Actor-Critic):** es un algoritmo actor-crítico y off-policy, lo que significa que puede aprender de experiencias pasadas y es más eficiente en términos de muestras.
- **TD3 (Twin Delayed Deep Deterministic Policy Gradient):** al igual que SAC, es un algoritmo actor-crítico y off-policy. Es más simple que SAC, pero puede atascarse en óptimos locales.

| Algoritmo | Tipo       | Espacio de acción   | Eficiencia de muestras |
|-----------|------------|---------------------|------------------------|
| PPO       | On-policy  | Discreto y Continuo | Baja-Media             |
| SAC       | Off-policy | Continuo            | Alta                   |
| TD3       | Off-policy | Continuo            | Alta                   |

Tabla 3.6: Comparación de algoritmos de aprendizaje por refuerzo.

A continuación se muestra una comparación entre estos algoritmos de aprendizaje por refuerzo:

En base a los datos de la tabla 3.6, se ha decidido utilizar el algoritmo SAC para el entrenamiento del agente, ya que es un algoritmo actor-crítico y off-policy que aprende una política estocástica optimizando simultáneamente la política y la entropía, lo que fomenta la exploración durante el entrenamiento. Además, SAC es un algoritmo eficiente en términos de muestras porque aprende de experiencias pasadas. Todo esto, junto a que los episodios de Scone son caros computacionalmente, hace que SAC sea la mejor opción para el entrenamiento del agente en este proyecto.

### Aleatorización de dominio

Para obtener un mejor agente entrenado y reducir el *sim-to-real gap*, una opción es entrenar aplicando aleatorización de dominio, o en inglés *domain randomization*, como se ha explicado anteriormente en 2.1.4. En este proyecto se ha decidido aplicar ruido gaussiano a las observaciones, exactamente de la forma:

$$obs_n = obs_n + e \quad (3.18)$$

donde

$$e = \mathcal{N}(0, 0,005^2) \quad (3.19)$$

Este error gaussiano se aplica a todas las observaciones del agente, y representa una distribución de probabilidad normal con media 0 y desviación estándar de 0,005. Esto significa que el 68 % de los errores generados por el ruido gaussiano estarán dentro del rango de -0,005 a 0,005, y el 95 % de los errores estarán dentro del rango de -0,01 a 0,01.

Este procedimiento permite simular errores que pueda haber en el mundo real, y de forma adicional también se ha aplicado un retardo aleatorio a las acciones del agente debido a que en hardware real existen retardos de comunicación entre el agente y el actuador. Dicho retardo se establece de tal forma que en la acción tomada por el agente se aplica en el paso actual o en el paso siguiente de manera aleatoria, es decir, con un retardo de 0 ó 1 pasos. De esta forma, el agente entrenado es más robusto y se adapta mejor a las condiciones del mundo real.

### Configuración del entrenamiento

Una vez definido el entorno de simulación, la función de recompensa, las observaciones y el algoritmo de entrenamiento, se procede a configurar los parámetros del entrenamiento. En la sección 3.3.1 se ha decidido usar el algoritmo SAC de la biblioteca de aprendizaje por refuerzo *Stable Baselines3*, que es una implementación de algoritmos de aprendizaje por refuerzo basada en *PyTorch*.

El modelo usa el entorno de simulación diseñado en Scone con Gymnasium. Además, tanto la frecuencia de actualización de la red como el número de pasos de gradiente se han establecido en 1 porque el entrenamiento es lo suficientemente sencillo como para que no sea necesario acumular gradientes durante

varios pasos. Por otro lado, tanto el actor como el crítico usan una red neuronal de 2 capas con 256 neuronas cada una. Se ha establecido un periodo de exploración pura en los primeros 100.000 pasos de entrenamiento, durante los cuales el agente toma acciones aleatorias para explorar el entorno y aprender sobre él. Tras este periodo de exploración, el agente comienza a aprender a partir de las recompensas obtenidas en el entorno.

El agente tiende a priorizar las recompensas a largo plazo sobre las recompensas a corto plazo, lo que significa que el agente aprende a tomar decisiones que maximizan la recompensa acumulada a lo largo del tiempo, en lugar de centrarse únicamente en la recompensa inmediata. Por último, se ha establecido un total de dos millones de pasos de entrenamiento, lo que permite al agente aprender una política efectiva para controlar el exoesqueleto y asistir al modelo musculoesquelético en su marcha. Los parámetros de entrenamiento se resumen en la tabla 3.7.

| Parámetro                          | Valor                      |
|------------------------------------|----------------------------|
| Red actor/crítico                  | Percepción Multicapa (MLP) |
| Frecuencia de actualización        | 1                          |
| Número de pasos de gradiente       | 1                          |
| Número de capas                    | 2                          |
| Número de neuronas por capa        | 256                        |
| Tasa de aprendizaje                | 0,0003                     |
| Tamaño de la memoria de repetición | 300.000                    |
| Descuento de recompensa futura     | 0,99                       |
| Actualización suave                | 0,005                      |
| Periodo de exploración             | 100.000 pasos              |
| Total de pasos de entrenamiento    | 2.000.000 pasos            |

Tabla 3.7: Configuración del entrenamiento del agente de aprendizaje por refuerzo.

### 3.3.2 Despliegue del agente entrenado

Una vez entrenado el agente con SconePy, se procede a realizar la inferencia del agente entrenado en el entorno de simulación de Scone. La interfaz de dicha aplicación con el modelo musculoesquelético se muestra en la figura 3.22.

La aplicación permite visualizar de manera gráfica una ejecución del modelo musculoesquelético con el agente controlando el exoesqueleto. Además, es posible visualizar en tiempo real las variables de interés para la función de recompensa mencionada anteriormente en la sección 3.3.1, como las posiciones y velocidades de la cadera y del exoesqueleto, el par aplicado por el exoesqueleto o las activaciones musculares del modelo. Esto permite analizar el comportamiento del agente entrenado y evaluar su rendimiento en el entorno de simulación.

Por último, una vez validado el agente entrenado en el entorno de simulación de Scone, se procede a realizar el despliegue del agente en el entorno real. Para ello, pese a que no se dispone de exoesqueleto real, se ha optado por realizar la inferencia del agente en el *dummy* de cadera mencionado, de tal forma que el par aplicado en los motores AK80-9 de las caderas es el mostrado en la ecuación (3.20):

$$\tau(t) = \tau_{agente}(t) + \tau_{PID}(t) \quad (3.20)$$

donde




Figura 3.22: Interfaz de la aplicación de Scone con el modelo musculoesquelético. De izquierda a derecha: explorador de archivos, editor de texto, visualización del modelo musculoesquelético con el exoesqueleto acoplado, y visualización de las propiedades del modelo. En la parte inferior se encuentra una gráfica con las variables de interés en tiempo real.

- $\tau(t)$  es el par aplicado por el motor en el instante de tiempo  $t$ .
- $\tau_{agente}(t)$  es el par calculado por el agente entrenado en el instante de tiempo  $t$ .
- $\tau_{PID}(t)$  es el par calculado por el controlador PID en el instante de tiempo  $t$ .

Antes del despliegue final, se realiza una prueba de control en el *dummy* de cadera para validar el comportamiento del controlador PID. A estos efectos, el par aplicado por el controlador PID se calcula mediante la ecuación (3.21).

$$\tau(t) = \tau_{PID}(t) \quad (3.21)$$

Las ganancias del controlador PID se muestran en la tabla 3.8.

| Término | Valor |
|---------|-------|
| $K_P$   | 2,5   |
| $K_I$   | 0,0   |
| $K_D$   | 0,1   |

Tabla 3.8: Ganancias del controlador PID de la cadera del *dummy*.

De esta manera, se puede validar el comportamiento del agente entrenado en un entorno real y evaluar su capacidad para asistir al movimiento de la cadera del *dummy*. Cabe destacar que, pese a que la conexión con el motor AK60-6 en la sección 3.1 se ha realizado utilizando ROS2, en esta ocasión se ha optado por usar las bibliotecas de Python proporcionadas por MAB Robotics para controlar los motores AK80-9 del *dummy* de cadera. Esto se debe a que dichas bibliotecas permiten un control más directo y eficiente de los motores que ROS2 que, pese a ser un estándar en robótica, introduce una capa adicional de complejidad y latencia en la comunicación con los motores que es preferible no tener en el caso de este proyecto.

### 3.4 Métricas de evaluación de marcha

Dado que el objetivo del proyecto es desarrollar un exoesqueleto de asistencia a la marcha, es necesario evaluar el rendimiento de los modelos musculoesqueléticos y del agente entrenado en términos de métricas de marcha. Estas métricas permiten cuantificar la calidad de la marcha y el nivel de asistencia proporcionado por el exoesqueleto. A continuación, se describen las principales métricas utilizadas para evaluar la marcha:

- **Posición de la cadera:** para evaluar la posición de la cadera, es necesario medir error de posición absoluto medio (MAE) entre la posición actual de la cadera y la posición objetivo. Esta métrica cuantifica, en promedio, el error en la posición de las caderas durante la marcha, y se calcula mediante la ecuación (3.22).

$$MAE = \frac{1}{N} \sum_{i=1}^N |pos_{real,i} - pos_{objetivo,i}| \quad (3.22)$$

donde

- $N$  es el número de muestras.
- $pos_{real,i}$  es la posición real de la cadera en la muestra  $i$ .
- $pos_{objetivo,i}$  es la posición objetivo de la cadera en la muestra  $i$ .

El error cuadrático medio (MSE) también se puede utilizar para evaluar la posición de la cadera, y se calcula mediante la ecuación (3.23).

$$MSE = \frac{1}{N} \sum_{i=1}^N (pos_{real,i} - pos_{objetivo,i})^2 \quad (3.23)$$

donde

- $N$  es el número de muestras.
- $pos_{real,i}$  es la posición real de la cadera en la muestra  $i$ .
- $pos_{objetivo,i}$  es la posición objetivo de la cadera en la muestra  $i$ .

Esta ecuación mide el promedio de los errores de posición elevados al cuadrado, lo que penaliza más los errores grandes y proporciona una medida más sensible de la precisión de la posición de la cadera durante la marcha.

A su vez, la raíz del error cuadrático medio (RMSE) también se puede utilizar para evaluar la posición de la cadera, y se calcula mediante la ecuación (3.24). Se calcula como la raíz cuadrada del MSE, proporcionando una medida de error en las mismas unidades que la posición de la cadera.

$$RMSE = \sqrt{MSE} \quad (3.24)$$

El RMSE normalizado (NRMSE) representa el RMSE normalizado con respecto al rango de valores de la posición de la cadera. Esto es especialmente útil cuando se comparan diferentes sujetos o condiciones de marcha, ya que permite una comparación más equitativa. Además, dado que muestra el resultado en porcentaje, es sencillo de interpretar. Se calcula mediante la ecuación (3.25).

$$NRMSE = \frac{RMSE}{pos_{max} - pos_{min}} \quad (3.25)$$

donde

- $pos_{max}$  es la posición máxima que puede tomar la cadera.
- $pos_{min}$  es la posición mínima que puede tomar la cadera.
- **Velocidad de la cadera:** para evaluar la velocidad de la cadera, es posible utilizar las mismas métricas que para la posición de la cadera. Concretamente, se utiliza el MAE, el MSE y el RMSE, que se calculan de la misma manera que para la posición de la cadera, pero utilizando los valores de velocidad en lugar de los valores de posición. Además, es importante tener en cuenta la velocidad máxima absoluta para evaluar la capacidad del exoesqueleto en términos de suavidad para evitar movimientos bruscos que puedan afectar la comodidad del usuario. Esta métrica se calcula mediante la ecuación (3.26).

$$Vel_{max} = \max(|vel_i|) \quad (3.26)$$

donde

- $vel_i$  es la velocidad de la cadera en la muestra  $i$ .
- **Par aplicado:** de forma similar a la velocidad, las comparaciones con el par aplicado sirven para medir la suavidad del movimiento. El par pico absoluto ayuda a evaluar la capacidad del exoesqueleto o del modelo musculoesquelético de seguir la referencia sin aplicar picos de par que puedan afectar la comodidad del usuario. Esta métrica se calcula mediante la ecuación (3.27).

$$Par_{max} = \max(|par_i|) \quad (3.27)$$

donde

- $par_i$  es el par de la cadera en la muestra  $i$ .

Por otra parte, el par medio absoluto ayuda a evaluar la capacidad del exoesqueleto o del modelo musculoesquelético de seguir la referencia aplicando un par medio controlado y estable. Esta métrica se calcula mediante la ecuación (3.28).

$$Par_{mean} = \frac{1}{N} \sum_{i=1}^N |par_i| \quad (3.28)$$

donde

- $N$  es el número de muestras.
- $par_i$  es el par de la cadera en la muestra  $i$ .

Por último, al calcular el valor cuadrático medio del par aplicado (RMS), se obtiene una medida de la magnitud del par aplicado durante la marcha, lo que permite evaluar la eficiencia del exoesqueleto o del modelo musculoesquelético en términos de control de par. El cálculo de esta métrica es similar al RMSE de posición y velocidad pero aplicado al par, y se calcula mediante la ecuación (3.29).

$$Par_{RMS} = \sqrt{\frac{1}{N} \sum_{i=1}^N (par_i)^2} \quad (3.29)$$

donde

- $N$  es el número de muestras.
- $par_i$  es el par de la cadera en la muestra  $i$ .

Además, se calcula el índice de suavidad del par aplicado de la forma mostrada en la ecuación (3.30).

$$Par_{suavidad} = \frac{\Delta Par_{RMS}}{Par_{RMS}} \quad (3.30)$$

donde

- $N$  es el número de muestras.
  - $\Delta Par_{RMS}$  es la variación del par RMS.
  - $Par_{RMS}$  es el valor cuadrático medio del par aplicado.
- **Activaciones musculares:** para evaluar las activaciones musculares del modelo musculoesquelético se utiliza el porcentaje medio de activación de cada músculo, que se calcula mediante la ecuación (3.31).

$$Act_{media} = \frac{1}{N} \sum_{i=1}^N act_i \quad (3.31)$$

donde

- $N$  es el número de muestras.
- $act_i$  es la activación del músculo en la muestra  $i$ .

Esto permite evaluar la eficiencia del exoesqueleto o del modelo musculoesquelético en términos de activación muscular, ya que un menor porcentaje de activación indica un menor esfuerzo muscular y, por lo tanto, una mayor eficiencia en la asistencia a la marcha.



## Capítulo 4

# Resultados y discusión

El capítulo de resultados se centra en la presentación y análisis de los resultados obtenidos durante el desarrollo del proyecto. Dichos resultados se exponen en el orden descrito en el capítulo "Materiales y métodos"(3), que es la misma que se ha seguido durante el desarrollo del proyecto. En primer lugar, se muestran los resultados obtenidos durante la ejecución de la simulación del ciclo de marcha en MuJoCo con el modelo musculoesquelético simulado, para posteriormente valorar los resultados obtenidos al enviar ese par generado en el simulador al motor real para evaluar su funcionamiento en el entorno físico. Finalmente se presentan los resultados obtenidos durante el entrenamiento del agente de aprendizaje por refuerzo, tanto en el entorno de simulación como en el entorno real con el *dummy*, con el objetivo de que el agente sea capaz de asistir a la marcha humana. De todos los resultados obtenidos se expone un análisis de los mismos.

### 4.1 Resultados del control de motores eléctricos basados en modelos musculoesqueléticos

La presente sección muestra los resultados obtenidos durante la ejecución de la simulación de ciclos de marcha del modelo musculoesquelético en MuJoCo y la transferencia del par generado por dicho modelo musculoesquelético al motor físico real AK60-6. Se incluyen gráficas y tablas para ambos casos.

#### 4.1.1 Seguimiento de trayectoria de marcha con un modelo musculoesquelético

Con el fin de recordar el objetivo de este experimento, se pretende evaluar el desempeño del modelo musculoesquelético simulado en MuJoCo para que el modelo sea capaz de seguir la trayectoria de marcha predefinida. Para ello, se ha simplificado un modelo musculoesquelético obtenido de la literatura y, mediante el simulador MuJoCo y con la implementación de un controlador PID, se pretende que el modelo siga la trayectoria de marcha con errores mínimos. Para las ganancias del controlador PID, se ha utilizado un valor de 0,7 para la ganancia proporcional, 0,3 para la ganancia integral y un valor de 0 para la ganancia derivativa.

Los resultados del seguimiento de la trayectoria de marcha se muestran en la figura 4.1. En ella se observan 4 gráficas, siendo estas de arriba hacia abajo: posición actual y posición objetivo de ambas caderas, par o torque aplicado en las articulaciones de ambas caderas, activaciones musculares de la

cadera derecha y activaciones musculares de la cadera izquierda. Es importante destacar que la posición actual de ambas caderas representa la posición de las caderas simuladas en cada instante de tiempo, y en la leyenda de la figura 4.1 se llama "Posición simulada". Por otra parte, la tabla con las distintas métricas obtenidas durante la simulación se muestra en la tabla 4.1. Dichas métricas se han calculado de la forma destallada en la sección "Métricas de evaluación de marcha"(3.4) del capítulo "Materiales y métodos". Tanto la figura como la tabla corresponden a la misma simulación.




Figura 4.1: Resultados obtenidos en la simulación de seguimiento de la trayectoria de marcha en MuJoCo. Las gráficas, de arriba a abajo: posición actual y posición objetivo de ambas caderas, torque aplicado en las articulaciones de ambas caderas, activaciones musculares de la cadera derecha y activaciones musculares de la cadera izquierda.

Como se ha explicado en el capítulo de "Materiales y métodos", la trayectoria entre caderas se ha desplazado un 50 % de la fase de marcha para que ambas caderas no tengan la misma posición objetivo y simular una trayectoria de marcha más realista, de modo que cuando una cadera se encuentra en flexión, la otra se encuentra en extensión. Se observa que el modelo musculoesquelético funciona correctamente, debido a que señales de par positivas activan el extensor de cadera, de modo que el ángulo de posición de las caderas crece, y de forma inversa para las señales negativas. Se han simulado 5 ciclos de marcha a 2,1 segundos por ciclo, lo que da un total de 10,5 segundos de simulación.

Los resultados de la tabla 4.1 muestran una precisión general excelente. El MAE está entre 1,43 y 1,61 grados, mientras que el RMSE está entre 1,81 y 1,88 grados, lo que representa un NRMSE (RMSE normalizado) de 1,18 % en la cadera izquierda y de 1,22 % en la derecha. El hecho de que el RMSE esté cerca del MAE indica que el sistema no tiene picos bruscos ni pérdidas de control momentáneas y que el error es suave y constante. La cadera derecha tiene un par RMS un 4,5 % mayor que la cadera izquierda, lo que se corresponde con el hecho de que los errores de posición de la cadera derecha son mayores que los de la cadera izquierda. Se observa un par relativamente bajo en ambas caderas, no superando en ningún

| Métrica          | Parámetro      | Valor izquierdo | Valor derecho |
|------------------|----------------|-----------------|---------------|
| Posición         | MAE            | 1,43°           | 1,61°         |
|                  | RMSE           | 1,81°           | 1,88°         |
|                  | NRMSE          | 1,18 %          | 1,22 %        |
| Par              | Pico absoluto  | 0,52 Nm         | 0,45 Nm       |
|                  | Medio absoluto | 0,17 Nm         | 0,19 Nm       |
|                  | RMS            | 0,22 Nm         | 0,23 Nm       |
| Activación media | Flexor         | 2,21 %          | 2,42 %        |
|                  | Extensor       | 0,35 %          | 0,43 %        |

Tabla 4.1: Resultados obtenidos en la simulación de seguimiento de la trayectoria de marcha en MuJoCo. Se muestran métricas de posición para visualizar el error de seguimiento de trayectoria, tanto los valores absolutos como los porcentuales. Además, se muestran métricas de par para visualizar el par aplicado en ambas caderas, y métricas de activación media para visualizar la activación media de los músculos flexores y extensores de ambas caderas.

caso los 0,6 Nm de valor absoluto, lo que es ideal en términos de seguridad. Los actuadores musculares simulados muestran un uso bastante mayor de los flexores frente a los extensores, lo que concuerda tanto con las diferencias de par aplicadas en extensión y flexión de cadera, como con el uso de dichos músculos en personas sanas al caminar. En general, los resultados obtenidos durante la simulación en MuJoCo son satisfactorios y muestran un buen desempeño del sistema de control implementado.

#### 4.1.2 Transferencia del modelo musculoesquelético a un motor real

El par generado por una de las caderas del modelo musculoesquelético simulado en MuJoCo se envía al motor AK60-6 para evaluar su comportamiento en un entorno real. En esta ocasión, la única señal de entrada al circuito es esa señal de par, por lo que no existe un controlador PID para disminuir errores. La figura 4.2 muestra los resultados de seguimiento obtenidos al enviar el par generado por el modelo musculoesquelético en la cadera derecha en MuJoCo al motor.

Como se puede observar en la gráfica 4.2, el par enviado al motor se corresponde con el par generado por el modelo musculoesquelético en su cadera derecha simulada. Se observa como la señal del par es la misma que en la gráfica de la figura 4.1. En esta ocasión, la posición objetivo no es la misma que en la simulación, ya que el objetivo es evaluar el desempeño del motor real al recibir el par generado por el modelo musculoesquelético simulado en MuJoCo. Por ello, la posición objetivo se ha definido como la posición que sigue la cadera derecha del modelo musculoesquelético. Se observan errores de posición, que se marcan más notablemente en los picos de flexión y extensión de cadera, aunque este error es irregular. Además, los errores de velocidad acentúan estos errores de posición debido a que, en general, la velocidad angular del motor es mayor que la necesaria.

La tabla 4.2 muestra las métricas obtenidas al enviar el par calculado por el modelo musculoesquelético simulado en MuJoCo al motor real. En primer lugar, se observa que el error de posición del motor real es relativamente bajo, con un MAE de 4,74 grados y un RMSE de 5,90 grados. Estos valores son excelentes, ya que pasar de simulación a hardware real y aumentar el error en únicamente 3 grados es un muy buen resultado. El RMSE de 5,90° únicamente ha aumentado 4 grados respecto al RMSE de la simulación en MuJoCo, lo que indica que el sistema de control implementado es robusto y capaz de mantener un buen desempeño al pasar de simulación a hardware real.




Figura 4.2: Resultados de seguimiento de trayectoria de marcha de cadera en el motor real en base a comandos de par calculados por el modelo musculoesquelético en MuJoCo. La gráfica superior muestra la posición objetivo y real del motor, mientras que la gráfica inferior muestra el par aplicado en el motor, que se corresponde con el par de la cadera derecha de la simulación en MuJoCo mostrada en la figura 4.1.1.

Por otra parte, se observa que la velocidad angular al variar entre flexión y extensión es más elevada que en la simulación, con un pico absoluto de velocidad de  $195,95^\circ/\text{s}$ , lo que provoca inconsistencias en los picos entre ciclos de marcha. Esto se contempla más claramente en la figura 4.3, donde se observa que el error de posición, definido como  $Pos_{sim} - Pos_{real}$ , es positivo en extensión de cadera (parte inferior del gráfico) y negativo en flexión de cadera (parte superior del gráfico), siendo la posición del simulador la línea roja y la posición del motor real la línea azul. Esto puede deberse a una mala calibración del simulador o a un error en la dinámica del propio modelo musculoesquelético simulado. Aún así, el error de posición es relativamente bajo y el sistema de control funciona correctamente, aunque no de forma óptima.

| Métrica                 | Valor     |
|-------------------------|-----------|
| MAE Posición            | 4,74°     |
| RMSE Posición           | 5,90°     |
| Pico absoluto Velocidad | 195,95°/s |

Tabla 4.2: Resultados numéricos obtenidos con el envío del par generado en la simulación de MuJoCo al motor real.

## 4.2 Control de *dummy* de pruebas basado en el modelo musculoesquelético

En esta sección se muestran los resultados obtenidos durante la simulación de un episodio en Scone sin la influencia del exoesqueleto. Posteriormente se presentan los resultados obtenidos al lanzar ese mismo




Figura 4.3: Comparativa del error de posición de la figura 4.2.

episodio en el entorno real con el *dummy* de cadera, con el objetivo de comparar los resultados obtenidos en el entorno de simulación con los obtenidos en el entorno real. En la figura 4.4 se muestra el esquema de control utilizado en Scone, donde se muestra el flujo de información tanto del modelo musculoesquelético como del agente entrenado, que en esta sección no se encuentra presente, ya que el objetivo es evaluar el desempeño del modelo musculoesquelético sin la influencia del agente entrenado.




Figura 4.4: Esquema de control utilizado en Scone.

Cabe destacar que, debido a la no interacción del modelo musculoesquelético con el agente y debido a que Scone es un simulador que siempre tiene las mismas condiciones iniciales, todos los episodios lanzados en Scone sin la influencia del agente entrenado son exactamente iguales.

#### 4.2.1 Resultados del episodio con el modelo musculoesquelético en Scone

En primera instancia, es necesario evaluar el desempeño del modelo musculoesquelético moviendo las caderas con la trayectoria de marcha predefinida, que se detalla en la sección 3.1.1. Esto permite evaluar el desempeño del modelo musculoesquelético desarrollado en Scone, tal y como se detalla en la sección 3.2.2, además del controlador PID sin la influencia del agente ni del exoesqueleto, y sirve como referencia para comparar posteriormente los resultados obtenidos con el agente entrenado.

Las estadísticas de la figura 4.5 se muestran en la tabla 4.3. Sin aplicar el par calculado por el agente, el modelo musculoesquelético tiene un buen desempeño, con errores de posición medios de 2,5490° y 3,8271° en la cadera izquierda y derecha respectivamente. Estos valores en el MAE representan errores de posición de un 1,69 % y de un 2,55 % con respecto a la posición de referencia, calculado de la forma detallada en la ecuación (4.1).

$$\text{MAE \%} = \frac{\text{MAE}}{\text{Pos}_{\max} - \text{Pos}_{\min}} \cdot 100 \quad (4.1)$$




Figura 4.5: Desempeño del modelo musculoesquelético sin la influencia del agente. En la primera gráfica se muestra la posición objetivo y la posición real de ambas caderas, mientras que en la segunda gráfica se muestra la velocidad objetivo y la velocidad real de ambas caderas. La tercera gráfica muestra la activación de cada uno de los músculos. El eje X de las 3 gráficas representa un paso de tiempo de 0,01 segundos.

| Métrica          | Parámetro       | Valor izquierdo             | Valor derecho               |
|------------------|-----------------|-----------------------------|-----------------------------|
| Posición         | MAE             | 2,5490°                     | 3,8271°                     |
|                  | Pico            | 9,5966°                     | 9,6746°                     |
|                  | MSE             | 13,0971°                    | 21,2617°                    |
|                  | RMSE            | 3,6190°                     | 4,6110°                     |
|                  | NRMSE           | 2,41 %                      | 3,07 %                      |
| Velocidad        | MAE             | 33,4534 °/s                 | 48,6055 °/s                 |
|                  | Máxima Absoluta | 128,2705 °/s                | 130,9893 °/s                |
|                  | MSE             | 2.232,1865 °/s <sup>2</sup> | 3.562,3904 °/s <sup>2</sup> |
|                  | RMSE            | 47,2460 °/s                 | 59,6858 °/s                 |
| Activación media | Iliopsoas       | 2,35 %                      | 2,31 %                      |
|                  | Glúteo mayor    | 2,10 %                      | 1,91 %                      |

Tabla 4.3: Resultados del modelo musculoesquelético sin la influencia del agente.

Debido a que el modelo musculoesquelético está diseñado para seguir la trayectoria de referencia, los errores de posición son bajos, y los valores de NRMSE de posición también lo demuestran. Valores por debajo de 3,1 % en ambas caderas indican que el modelo musculoesquelético es capaz de seguir la trayectoria de referencia con un error bajo, aunque no perfecto. Pese a que los errores de posición han aumentado con respecto al seguimiento de trayectoria en el simulador MuJoCo mostrado en la sección 4.1.1, estos errores de posición son aceptables.

Aún así, los errores de velocidad son bastante más acentuados que los de posición, con valores de MAE de velocidad superiores a 33°/s en la cadera izquierda y de 48°/s en la cadera derecha. Aún así, los errores de velocidad son aceptables porque, debido a la propia naturaleza del sistema de control PID, el sistema incluirá retardos debido a que no puede reaccionar instantáneamente a los cambios de velocidad de la trayectoria de referencia.

Por último, las activaciones musculares se encuentran en torno al 2 % en los 4 músculos, observando mayor activación en ambos iliopsoas, o psoas ilíaco, que en ambos glúteos mayores. Esto se corresponde con los datos observados en la tabla de resultados 4.1 de la sección anterior 4.1.1, donde se evaluó el seguimiento de la trayectoria del modelo musculoesquelético en el simulador MuJoCo. Se observa una activación mayor alrededor del paso de tiempo 160 en el iliopsoas izquierdo, correspondiente al inicio de la fase de flexión de cadera izquierda debido a que el iliopsoas es el principal flexor de cadera. En la gráfica se observa que en ese instante de tiempo hay una gran activación de dicho iliopsoas, correspondiente a la línea roja. Además, debido a esta activación fuera de lo usual, se provoca un aumento en la activación media de ambos músculos de esa cadera, y comprobando con la tabla 4.3, se observa que las activaciones musculares medias de la cadera izquierda son mayores que las de la cadera derecha pese a que el resto de métricas de posición y velocidad son peores en la cadera derecha.

#### 4.2.2 Control del *dummy* con el modelo musculoesquelético de Scone

A continuación se muestran los resultados obtenidos al controlar ambas caderas del *dummy* en base al modelo musculoesquelético de Scone, es decir, únicamente haciendo uso del controlador PID implementado. En la figura 4.6 se muestra el diagrama de flujo de control del *dummy* de pruebas, donde se observa que el flujo de información es similar al de la figura 4.4, pero en este caso el flujo de información se encuentra en el entorno real y no en el entorno de simulación. De nuevo, en este caso no se hace uso del agente entrenado.




Figura 4.6: Diagrama de flujo de control del *dummy* de pruebas.

La figura 4.7 muestra los resultados del control del *dummy* sin aplicar el par del agente entrenado. En la figura, la posición objetivo de las caderas es la misma que se ha establecido para los experimentos

anteriores, y su obtención se detalla en la sección 3.1.1. En esa figura se muestran 6 gráficas, que se complementan en parejas con la otra gráfica de su fila. Las gráficas de la columna izquierda se corresponden con los datos obtenidos a partir de la cadera izquierda, mientras que las graficas de la columna derecha muestran los datos obtenidos a partir de la cadera derecha. La primera fila muestra la posición objetivo y la posición real de la cadera correspondiente, la segunda fila muestra la velocidad objetivo y la velocidad real de las caderas, y la tercera fila muestra el par aplicado en las caderas. En todas las gráficas, el eje X representa el tiempo en segundos. La tabla 4.4 muestra los resultados obtenidos al controlar el *dummy* únicamente con el modelo musculoesquelético de Scone y el controlador PID.




Figura 4.7: Resultados obtenidos al lanzar la inferencia sin aplicar par del agente entrenado. La columna izquierda representa los resultados de la cadera izquierda, y de forma similar para la columna derecha. La primera fila muestra la posición real y objetivo de la cadera, la segunda fila muestra la velocidad real y objetivo de la cadera, y la tercera fila muestra el par aplicado en la cadera.

| Parámetro              | Valor izquierdo | Valor derecho |
|------------------------|-----------------|---------------|
| MAE Posición           | 7,3206°         | 5,6038°       |
| MAE Velocidad          | 25,3205°/s      | 29,3652°/s    |
| Par Pico               | 0,8334 Nm       | 0,8850 Nm     |
| Par RMS                | 0,3966 Nm       | 0,3119 Nm     |
| Índice de suavidad Par | 0,0621          | 0,0823        |

Tabla 4.4: Resultados del control del *dummy* de pruebas únicamente con el modelo musculoesquelético de Scone y el controlador PID.

Se observan errores de posición más altos que en la simulación de Scone de la sección anterior 4.2.1, lo que es esperable debido a que el entorno real introduce ruido y perturbaciones que no existen en

simulación. Además, tal y como se mencionó en la sección 3.2, en el control del *dummy*, ambos motores AK80-9 tienen una masa acoplada a ellos, simulando los muslos de las piernas humanas, lo que hace que el sistema sea más pesado y que el controlador PID tenga que trabajar más para mantener la trayectoria de referencia. Aun así, los errores de posición son relativamente bajos, con un MAE de  $7,3206^\circ$  en la cadera izquierda y de  $5,6038^\circ$  en la derecha, que se corresponde con errores porcentuales medios absolutos de 4,34 % y de 3,32 %, respectivamente.

Por otra parte, se observa que la velocidad angular real de ambas caderas es más alta que la velocidad objetivo, lo que indica aceleraciones y deceleraciones bruscas en el movimiento de las caderas. Esto no es ideal porque puede provocar movimientos bruscos y poco naturales en el *dummy* de pruebas, y puede ser un indicativo de que el controlador PID no está funcionando correctamente. Finalmente, aunque el par pico de ambas caderas no supere 1 Nm durante toda la ejecución, el índice de suavidad indica que hay demasiada variación en el par aplicado entre dos instantes de tiempo consecutivos, lo que indica que el par aplicado no es suave y progresivo, sino que hay picos bruscos y movimientos irregulares. Esto puede ser un indicativo de que el controlador PID, aunque sí sea capaz de seguir la trayectoria de referencia con una precisión aceptable, no es capaz de variar el par aplicado de una forma óptima, detalle importante para la seguridad del usuario final.

## 4.3 Resultados del despliegue del agente entrenado

En esta sección se presentan los resultados obtenidos durante el entrenamiento del agente, tanto en el entorno de simulación en Scone como en el entorno real con el *dummy* de pruebas. En primer lugar, se analizan los resultados obtenidos durante el entrenamiento, para después pasar a evaluar el rendimiento del agente entrenado en el simulador Scone y, por último, desplegar el agente entrenado en el entorno real y comparar con los resultados obtenidos en el entorno de simulación.

### 4.3.1 Análisis del entrenamiento

Con el objetivo de recordar el diagrama de flujo de control del agente entrenado en el simulador Scone, se vuelve a mostrar la figura 4.8, que es la misma que la figura 4.4 de la sección anterior. Aunque el flujo de información es el mismo, en esta ocasión sí se hace uso del agente entrenado, que calcula el par a aplicar en ambas caderas en base a la observación del entorno, a la recompensa que obtiene y a la trayectoria de referencia.




Figura 4.8: Esquema de control utilizado en Scone.

A fin de recordar los pesos de cada término de la función de recompensa, se muestra de nuevo tanto la función de recompensa (4.2) como el peso de cada término en la tabla 4.5.

$$R_{\text{total}} = w_1 R_{\text{posición}} + w_2 R_{\text{velocidad}} - w_3 R_{\text{coste}} - w_4 R_{\text{suavidad}} - w_5 R_{\text{activaciones}} \quad (4.2)$$

| Término                | Recompensa |
|------------------------|------------|
| Posición ( $w_1$ )     | 0,15       |
| Velocidad ( $w_2$ )    | 0,90       |
| Coste ( $w_3$ )        | 0,60       |
| Suavidad ( $w_4$ )     | 0,50       |
| Activaciones ( $w_5$ ) | 0,25       |

Tabla 4.5: Pesos de cada término de la función de recompensa.

Para analizar el aprendizaje de la política establecida por el agente, se ha realizado un seguimiento de la evolución de la recompensa obtenida por el agente durante el proceso de entrenamiento. La figura 4.9 muestra dicha evolución.




Figura 4.9: Evolución de la recompensa obtenida por el agente durante el proceso de entrenamiento. El eje horizontal representa el episodio de entrenamiento. El eje vertical de la gráfica izquierda representa la recompensa obtenida por el agente en ese episodio concreto, mientras que el eje vertical de la gráfica derecha representa la recompensa máxima hasta ese episodio.

Teniendo en cuenta que la recompensa mínima durante el entrenamiento ha sido de -336,637 y la máxima de 791,164, la recompensa obtenida por el agente aumenta a medida que avanza el entrenamiento, lo que indica que el agente está aprendiendo a mejorar su desempeño en la tarea asignada. Además, también se aprecia como el mayor aumento de recompensa por episodio se produce a partir del paso 100.000, que se corresponde con el momento en el que el agente deja de tomar acciones aleatorias para explorar el entorno y aprender sobre él, tal y como se estableció al definir el proceso de entrenamiento en la sección 3.3.1.

Según lo expuesto en la sección 3.3.1 y debido a que cada episodio tiene 1000 pasos, el valor máximo que puede obtener el agente en cada episodio es 1050, y el máximo obtenido es 791,64, lo que indica que el agente ha aprendido a controlar la cadera de manera eficiente, aunque todavía hay margen de mejora. Sin embargo, el aumento de la mejora en la recompensa obtenida por el agente tiene forma logarítmica, lo que señala que el agente puede haber alcanzado un máximo local de recompensa, y que el entrenamiento podría no mejorar significativamente a partir de este punto.

### 4.3.2 Resultados del entrenamiento del agente en el entorno de simulación

A continuación se muestran los resultados obtenidos durante el último episodio de entrenamiento. Tal y como se estableció en la sección de configuración del entrenamiento 3.3.1, el total de pasos de entrenamiento es 2 millones, y debido a que cada episodio consta de 1000 pasos, el episodio 2000 corresponde con el último episodio de entrenamiento. La figura 4.10 muestra el desempeño del agente en este episodio. Asimismo, la tabla 4.6 muestra los resultados obtenidos por el agente en este último episodio.




Figura 4.10: Desempeño del agente en el episodio 2000 del entrenamiento en simulación. El eje horizontal representa los pasos del episodio. Cada paso corresponde con 0,01 segundos. La gráfica superior izquierda muestra las posiciones objetivo y reales de ambas caderas, mientras que la gráfica superior derecha muestra las velocidades objetivo y reales de ambas caderas. La gráfica inferior izquierda muestra las activaciones musculares, y por último, la gráfica inferior derecha muestra el par aplicado por el agente en ambas caderas.

| Métrica          | Parámetro          | Valor izquierdo | Valor derecho |
|------------------|--------------------|-----------------|---------------|
| MAE              | Posición           | 2,952°          | 2,934°        |
|                  | Velocidad          | 20,562°/s       | 20,474°/s     |
| Activación media | Iliopsoas          | 5,8 %           | 6,2 %         |
|                  | Glúteo mayor       | 5,9 %           | 6,4 %         |
| Par agente       | Medio              | -0,077 Nm       | -0,056 Nm     |
|                  | Medio              | 3,867 Nm        | 4,936 Nm      |
|                  | RMS                | 4,979 Nm        | 6,162 Nm      |
|                  | Pico               | 17,762 Nm       | 17,043 Nm     |
|                  | Variación Media    | 4,167 Nm/paso   | 4,248 Nm/paso |
|                  | Variación RMS      | 5,333 Nm/paso   | 5,477 Nm/paso |
|                  | Índice de suavidad | 1,071           | 0,889         |

Tabla 4.6: Resultados del agente en el episodio 2000 del entrenamiento en simulación.

En comparación con los resultados obtenidos al desplegar al agente en el entorno simulado de Scone en el episodio 2000 con los obtenidos al lanzar un episodio sin el exoesqueleto (mostrados en la tabla 4.3), se observa una evolución positiva. El error de posición medio entre ambas caderas ha disminuido un 7,31 % (pasando de un promedio de 3,188° a 2,943°), y el error medio de velocidad entre ambas caderas

ha disminuido un 50,00 % (pasando de un promedio de 41,03°/s a 20,518°/s). Debido a que el peso de la velocidad en la función de recompensa es mayor que el de la posición, se puede deducir que el agente ha aprendido a controlar mejor la velocidad de las articulaciones sin tener tanto en cuenta la posición de las mismas.

Las activaciones medias de los músculos, en cambio, han aumentado, pasando de un 1,91-2,35 % de activación media a un 5,8-6,4 %, lo que se traduce en un incremento del 181,88 % en la activación media de los músculos, por lo que se deduce que el modelo musculoesquelético se esfuerza más al ser asistido por el agente. Este resultado no es satisfactorio, ya que el objetivo del agente es asistir al modelo musculoesquelético en su marcha, y no aumentar la activación de los músculos.

Por último, el par aplicado por el agente al finalizar el entrenamiento muestra una gran ganancia en estabilidad. El valor medio del par absoluto aplicado por el agente en ambas caderas se sitúa entre 3,867-4,936 Nm, demostrando una fuerte contención y eficiencia debido al valor elevado en el peso del coste en la función de recompensa. El RMS se mantiene controlado en un promedio de 5,571 Nm. El índice de suavidad baja de 1,4205 (valor estimado inicial) a 1,071 en el exoesqueleto izquierdo (una mejora del 24,60 %), mientras que en el derecho se sitúa en 0,889, lo que se traduce en un movimiento optimizado. La variación media por paso también se mantiene baja, promediando 4,208 Nm/paso entre ambos lados del exoesqueleto. Todos estos datos en el par indican que la fuerza aplicada por el agente varía de manera más progresiva, lo que implica un movimiento más natural y fluido de las articulaciones.

### 4.3.3 Resultados del despliegue del controlador en el entorno real

En esta sección se presentan los resultados obtenidos al desplegar el agente entrenado en el entorno real con el *dummy* de pruebas de la forma descrita en la sección de despliegue del agente entrenado 3.3.2. La figura 4.11 muestra los resultados obtenidos al lanzar la inferencia aplicando el par calculado por el agente entrenado, mientras que la tabla 4.7 muestra los resultados obtenidos en el experimento.

| Control      | Parámetro              | Valor izquierdo | Valor derecho |
|--------------|------------------------|-----------------|---------------|
| PID + Agente | MAE Posición           | 9,2615°         | 5,3254°       |
|              | MAE Velocidad          | 42,6990°/s      | 30,3916°/s    |
|              | Par Pico               | 2,0000 Nm       | 1,8651 Nm     |
|              | Par RMS                | 0,7836 Nm       | 0,5598 Nm     |
|              | Par Índice de suavidad | 0,5454          | 0,6386        |

Tabla 4.7: Resultados de la inferencia del agente entrenado en el entorno real con el *dummy* de pruebas.

La comparativa de los errores medios de posición entre la inferencia del agente entrenado mostrado en la figura 4.11 y únicamente el controlador PID mostrado en la figura 4.7 se observa en la figura 4.12, ambos experimentos realizados en el *dummy* de pruebas. El eje horizontal de ambas gráficas representa el tiempo en segundos, mientras que el eje vertical representa el error de posición en grados. Según la leyenda de las gráficas, la línea azul representa el error de posición únicamente con el controlador PID, mientras que la línea naranja representa el error de posición aplicando el par calculado por el agente entrenado además del par calculado por el controlador PID.

Comparando los resultados obtenidos al aplicar únicamente el par aplicado por el agente mostrados en la tabla 4.4, el MAE de posición entre ambas caderas sólo con el controlador PID es de 6,4622 grados, mientras que el error aplicando el par calculado por el agente es de 7,29345 grados, lo que implica un aumento del 12,86 % en el error de posición medio absoluto. Llama la atención que sí hay mejora en el




Figura 4.11: Resultados obtenidos al lanzar la inferencia en el *dummy* de pruebas aplicando par del agente entrenado. En la primera fila se muestran la posición real y objetivo de ambas caderas, mientras que en la segunda fila se muestra el par aplicado por el controlador PID utilizado (verde), el par calculado por el agente entrenado (morado) y el par total aplicado (naranja). La columna izquierda muestra los resultados de la cadera izquierda, mientras que la columna derecha muestra los resultados de la cadera derecha.

error de seguimiento en la cadera derecha, mientras que en la cadera izquierda el error ha aumentado. El error de velocidad también ha subido, concretamente un 33,65 %. Esto implica que el agente entrenado en simulación no ha sido capaz de mejorar el desempeño del controlador PID en el entorno real, como sí que hizo en el entorno simulado según los datos obtenidos en la sección anterior 4.3.2.

El par pico también ha aumentado en ambas caderas, superando el 120 % de aumento en el par pico aplicado por el agente. El par pico de la cadera izquierda llega hasta los 2 Nm exactos, lo que señala que ha alcanzado el límite seguro de par establecido por seguridad en el *dummy* de pruebas. El RMS del par aplicado también ha empeorado un 89,61 % de media entre las caderas, por lo que los motores consumen más energía de manera continua. El índice de suavidad sólo aplicando el controlador PID es bajo (0,08 en la cadera derecha y 0,06 en la cadera izquierda), mientras que aplicando el par del agente entrenado se multiplica en ambos casos por más de 8 veces, lo que implica que el par aplicado por el agente es mucho más irregular y brusco que el aplicado únicamente por el controlador PID. Esto, en términos de seguridad, es un resultado negativo, ya que el par aplicado por el agente entrenado no es progresivo ni suave, sino que hay picos bruscos y movimientos irregulares, lo que provoca movimientos poco naturales en el *dummy* de pruebas y, en un futuro, en el usuario final.




Figura 4.12: Comparativa de error de posición entre controlador PID únicamente y aplicando el par calculado por el agente entrenado. Datos obtenidos a partir de los experimentos detallados en la sección 4.2.2 y la sección 4.3.3, ambos en el entorno real con el *dummy* de pruebas.

Si se desea visualizar el movimiento del *dummy* de pruebas durante la inferencia del agente entrenado, se puede consultar el video disponible en el siguiente enlace:

[https://universidaddealcala-my.sharepoint.com/:v:/g/personal/carlos\\_eguren\\_edu\\_uah\\_es/IQBe6uSkjtIkQKQkFKNHjeeUAd552Svn6PqOtBhPjZVgqkxk?nav=eyJyZWZlcnJhbEluZm8iOmsicmVmZXJyYWxBcHAIoiJPbmVEcm12ZUZvckJlc2luZXNzIiwicmVmZXJyYWxBcHBQeUQbxjD](https://universidaddealcala-my.sharepoint.com/:v:/g/personal/carlos_eguren_edu_uah_es/IQBe6uSkjtIkQKQkFKNHjeeUAd552Svn6PqOtBhPjZVgqkxk?nav=eyJyZWZlcnJhbEluZm8iOmsicmVmZXJyYWxBcHAIoiJPbmVEcm12ZUZvckJlc2luZXNzIiwicmVmZXJyYWxBcHBQeUQbxjD).

En el video se observa que el movimiento de las caderas es brusco y poco natural, con aceleraciones y deceleraciones muy rápidas, lo que provoca que el *dummy* de pruebas se mueva de manera irregular y poco fluida. Esto se debe a que el par aplicado por el agente entrenado no es progresivo ni suave, sino que hay picos bruscos y movimientos irregulares, tal y como se ha comentado anteriormente.

## Capítulo 5

# Conclusiones y trabajos futuros

En este capítulo se presentan las conclusiones obtenidas a raíz del desarrollo del presente proyecto, así como los trabajos futuros que se podrían realizar para mejorar los sistemas desarrollados y obtener mejores resultados.

### 5.1 Conclusiones

En esta primera sección se exponen las conclusiones obtenidas a raíz del desarrollo del presente proyecto, organizadas en función de los objetivos planteados en la sección [1.2](#).

#### 5.1.1 Desarrollo de un modelo musculoesquelético de cadera capaz de seguir trayectorias de marcha humana

Los resultados obtenidos en la simulación de MuJoCo han sido satisfactorios, ya que se ha conseguido un control de la articulación de la cadera del modelo musculoesquelético, obteniendo un movimiento de la articulación que sigue la trayectoria de marcha deseada de forma suave y estable. Valores bajos de MAE y de RMSE indican errores de posición bajos y constantes. Valores de NRMSE de posición por debajo del 1,3 % en ambas caderas indican que el modelo musculoesquelético es capaz de seguir la trayectoria de marcha con una alta precisión y, teniendo en cuenta valores pico de par inferiores a 0,55 Nm, se concluye que el modelo musculoesquelético desarrollado es capaz de seguir la trayectoria de marcha deseada de forma satisfactoria.

#### 5.1.2 Transferencia del modelo musculoesquelético al *dummy* real y control de sus caderas

La transferencia del par generado por el modelo musculoesquelético al motor AK60-6 ha provocado un aumento del error de posición, lo que es esperable. Sin embargo, la velocidad angular del motor es mayor que la velocidad angular de la articulación de cadera del modelo musculoesquelético, lo que podría deberse a una mala calibración del motor o a un mal diseño del controlador de la articulación de cadera del modelo simulado. A pesar de esto, dado que el error de posición medio absoluto únicamente ha aumentado en 3° (un 194,41 %) con respecto al modelo musculoesquelético simulado, se concluye que la transferencia del par generado por el modelo musculoesquelético al motor AK60-6 es admisible para el proyecto.

### 5.1.3 Entrenamiento del agente por medio de técnicas de aprendizaje por refuerzo para el control de exoesqueletos

La evolución de la recompensa del agente por medio de técnicas de aprendizaje por refuerzo ha sido satisfactoria, ya que se ha observado una tendencia creciente de la recompensa a medida que el agente aprende a controlar el exoesqueleto acoplado a la cadera del modelo musculoesquelético, lo que sugiere que el agente es capaz de asistir al modelo musculoesquelético en su marcha.

Pese a que se ha entrenado durante dos millones de pasos, todavía hay margen de mejora porque la recompensa máxima conseguida ha sido del 75 % de la recompensa máxima posible, lo que indica que el agente todavía no ha aprendido a asistir a las articulaciones de cadera del modelo musculoesquelético de manera óptima según la función de recompensa establecida. La recompensa obtenida tiene forma logarítmica, por lo que gastar más recursos en entrenar a este agente no es eficiente, y se debería ajustar la función de recompensa para que el agente aprenda a asistir a la articulación de la cadera de manera más eficiente.

Sin embargo, el par de control generado por el agente entrenado es muy ruidoso e irregular, alcanzando una variación media de 4,2 Nm/paso. Esto representa un problema para el despliegue del agente en un entorno físico real, ya que los motores reales provocarían vibraciones e inestabilidad en el sistema, por lo que se debería mejorar el diseño de la función de recompensa para que el agente aprenda a generar un par más suave y estable.

Aún así, en el entorno de simulación Scone la política entrenada ha demostrado ser extremadamente simétrica, ya que los errores entre ambas caderas son similares, por lo que concluimos que el entrenamiento diseñado ha convergido. Además, observando los resultados obtenidos en simulación sin aplicar las acciones del agente, se comprueba que los errores en la articulación derecha son mayores que en la izquierda, lo que se traduce en que el par medio absoluto aplicado por el agente es mayor en la articulación derecha, por lo que el agente es capaz de compensar los errores propios del modelo musculoesquelético.

Sin embargo, el agente triplica las activaciones musculares con respecto al modelo musculoesquelético sin agente. En biomecánica, esto se conoce como co-activación, y es un fenómeno que provoca el agente para mejorar el seguimiento de velocidad. Dado que las activaciones musculares son sólo 4 % mayores de media con respecto al modelo sin agente y sin exoesqueleto simulado, se concluye que el agente entrenado ha sido capaz de aprender la política entrenada en simulación de forma satisfactoria.

### 5.1.4 Despliegue del agente entrenado en un sistema físico real

El despliegue del agente entrenado en el *dummy* de cadera muestra que el agente ya no es capaz de ser simétrico como sí lo era en simulación. Los errores de posición y velocidad de la cadera izquierda son más de un 60 % mayores que los de la cadera derecha, aunque el MAE de posición y velocidad de la cadera derecha se mantiene estable con respecto al despliegue sin las acciones del agente. Esto indica que el agente es capaz de asistir a la cadera derecha, pero no a la izquierda, lo que podría deberse a un problema de calibración de los motores, a un problema de control en la articulación izquierda o incluso a un error de montaje en esa parte del sistema.

El par aplicado en el *dummy* es mucho mayor que el aplicado sin agente debido al algoritmo de despliegue implementado de suma de pares en los motores. Esto provoca pares pico mayores, además de que la suavidad del par aplicado es menor, estadística no deseable en motores reales al provocar vibraciones e inestabilidad en el sistema. En conclusión, el agente entrenado ha empeorado su desempeño al pasar de la simulación al *dummy* real aunque se hayan tomado precauciones para que esto no ocurriese con el uso de las técnicas de *domain randomization* implementadas en el entrenamiento del agente.

### 5.1.5 Conclusión final

El objetivo general de este trabajo era el desarrollo de una plataforma que permitiera entrenar y validar un algoritmo de control basado en aprendizaje por refuerzo para el control de un exoesqueleto. Se ha simplificado un modelo musculoesquelético obtenido de la literatura y se han controlado los motores reales en base a ese modelo musculoesquelético. Además, se ha desarrollado e implementado toda la base de control para el entrenamiento y despliegue en hardware real de agentes de aprendizaje por refuerzo entrenados en el simulador Scone. Pese a que los resultados del despliegue del agente entrenado en el presente trabajo tiene margen de mejora, se ha demostrado que el sistema desarrollado es capaz de entrenar y desplegar agentes de aprendizaje por refuerzo en un entorno físico real, por lo que se concluye que el objetivo general del trabajo ha sido alcanzado.

## 5.2 Limitaciones del trabajo

A pesar de que el objetivo general del trabajo ha sido alcanzado, se han encontrado una serie de limitaciones, siendo las más relevantes las siguientes:

- El entrenamiento del agente ha sido realizado a una única velocidad de marcha, y no se ha validado el desempeño del agente a diferentes velocidades.
- El modelo musculoesquelético utilizado para el entrenamiento del agente está completamente acoplado al exoesqueleto, por lo que no se ha podido entrenar con un exoesqueleto realista.
- El agente entrenado ha sido desplegado directamente en el *dummy* de cadera y no en un exoesqueleto real, por lo que no se ha podido validar el desempeño del agente en un entorno completamente realista.

## 5.3 Trabajos futuros

A partir de las conclusiones obtenidas, se proponen una serie de trabajos futuros que podrían mejorar el desempeño del sistema desarrollado y obtener mejores resultados en el presente trabajo. Entre ellos se encuentran:

- Realizar un estudio del desempeño de ambos motores del *dummy* debido a que la actuación de los motores no es simétrica en ninguno de los resultados obtenidos. Estas diferencias pueden deberse a fallos en el montaje del *dummy*, a problemas de calibración de los motores o incluso a un problema de control de los algoritmos implementados.
- Realizar un estudio de la función de recompensa utilizada para el entrenamiento del agente, ya que la recompensa máxima obtenida ha sido de un 75 % de la recompensa máxima posible, lo que indica que el agente todavía no ha aprendido a controlar la articulación de la cadera de manera óptima.
- Disminuir la distancia entre la simulación y el mundo real con respecto al entrenamiento del agente. Se propone aplicar técnicas de *domain randomization* más agresivas, como la variación de la masa del modelo musculoesquelético, la variación de la rigidez de las articulaciones, la variación de la fricción de las articulaciones o incluso la variación de la geometría del modelo musculoesquelético. Esto permitiría al agente aprender a controlar la articulación de la cadera de manera más robusta y eficiente y, en última instancia, a mejorar el desempeño del agente al pasar de la simulación al mundo real.

- Diseñar y modelar un exoesqueleto de cadera para acoplarlo al *dummy* real y poder desplegar el agente entrenado en un entorno más realista. Esto permitiría validar al agente de la misma forma en la que ha sido entrenado.
- Variar la forma de entrenar para reducir el *sim-to-real gap* y mejorar el desempeño del agente al pasar de la simulación al mundo real. Se sugiere entrenar al agente en el *dummy* real, diseñando un modelo musculoesquelético para el movimiento del *dummy*. Si este enfoque es demasiado agresivo, entrenar en simulación y luego realizar un *fine-tuning* en el *dummy* real también podría ser una buena opción para mejorar el desempeño del agente al pasar de la simulación a entornos reales.

# Bibliografía

- [1] R. López, H. Aguilar, S. Salazar, R. Lozano y J. A. Torres, “Modelado y Control de un Exoesqueleto para la Rehabilitación de Extremidad Inferior con dos grados de libertad”, *Revista iberoamericana de automática e informática industrial*, vol. 11, n.º 3, págs. 304-314, 2014.
- [2] *Análisis de cuota de mercado de exoesqueletos y predicciones*, <https://www.fortunebusinessinsights.com/wearable-robotic-exoskeleton-market-104664> [Último acceso 26/junio/2026].
- [3] *Beneficios de caminar para la salud y la rehabilitación*, <https://www.ser.es/el-ejercicio-fisico-especificamente-caminar-se-ha-consolidado-como-una-herramienta-segura-y-efectiva-en-el-manejo-de-las-eras/> [Último acceso 29/junio/2026].
- [4] *Página web del grupo de investigación NAIR del CSIC*. <https://neuro-ai-robotics.github.io/> [Último acceso 30/junio/2026].
- [5] A. Chavarriás, D. Rodríguez-Cianca y P. Lanillos, “Adaptive torque control of exoskeletons under spasticity conditions via reinforcement learning”, en *2025 International Conference On Rehabilitation Robotics (ICORR)*, IEEE, 2025, págs. 705-711.
- [6] T. Moeller, F. Moehler, J. Krell-Roesch et al., “Use of lower limb exoskeletons as an assessment tool for human motor performance: A systematic review”, *Sensors*, vol. 23, n.º 6, pág. 3032, 2023.
- [7] X. Xu, C. Chen, Z. Sun, W. Xian, L. Ma e Y. Liu, “Research on Control Strategy of Lower Limb Exoskeleton Robots: A Review”, *Sensors*, vol. 26, n.º 2, pág. 355, 2026.
- [8] S. K. Hasan y A. K. Dhingra, “Development of a model reference computed torque controller for a human lower extremity exoskeleton robot”, *Proceedings of the Institution of Mechanical Engineers, Part I: Journal of Systems and Control Engineering*, vol. 235, n.º 9, págs. 1615-1637, 2021.
- [9] S. Luo, G. Androwis, S. Adamovich, E. Nunez, H. Su y X. Zhou, “Robust walking control of a lower limb rehabilitation exoskeleton coupled with a musculoskeletal model via deep reinforcement learning”, *Journal of neuroengineering and rehabilitation*, vol. 20, n.º 1, pág. 34, 2023.
- [10] M. Sharifi, S. Tripathi, Y. Chen, Q. Zhang y M. Tavakoli, “Reinforcement learning methods for assistive and rehabilitation robotic systems: A survey”, *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 2025.
- [11] W. Zhao, J. P. Queralta y T. Westerlund, “Sim-to-real transfer in deep reinforcement learning for robotics: a survey”, en *2020 IEEE symposium series on computational intelligence (SSCI)*, IEEE, 2020, págs. 737-744.
- [12] M. van Otterlo y M. Wiering, “Reinforcement Learning and Markov Decision Processes”, en *Reinforcement Learning: State-of-the-Art*, M. Wiering y M. van Otterlo, eds. Berlin, Heidelberg: Springer Berlin Heidelberg, 2012, págs. 3-42, ISBN: 978-3-642-27645-3. DOI: [10.1007/978-3-642-27645-3\\_1](https://doi.org/10.1007/978-3-642-27645-3_1). dirección: [https://doi.org/10.1007/978-3-642-27645-3\\_1](https://doi.org/10.1007/978-3-642-27645-3_1).

- [13] C. Szepesvári, *Algorithms for reinforcement learning*. Springer nature, 2022.
- [14] M. A. Wiering y M. Van Otterlo, “Reinforcement learning”, *Adaptation, learning, and optimization*, vol. 12, n.º 3, pág. 729, 2012.
- [15] M. Van Otterlo y M. Wiering, “Markov decision processes: Concepts and algorithms”, *Course on Learning and Reasoning*, 2009.
- [16] Y. Li, “Deep reinforcement learning: An overview”, *arXiv preprint arXiv:1701.07274*, 2017.
- [17] L. Rose, M. C. Bazzocchi y G. Nejat, “A model-free deep reinforcement learning approach for control of exoskeleton gait patterns”, *Robotica*, vol. 40, n.º 7, págs. 2189-2214, 2022.
- [18] J. Zhang, P. Fiers, K. A. Witte et al., “Human-in-the-loop optimization of exoskeleton assistance during walking”, *Science*, vol. 356, n.º 6344, págs. 1280-1284, 2017.
- [19] I. Choi, I. Park, E. Halilaj e I. Kang, “Musculoskeletal Motion Imitation for Learning Personalized Exoskeleton Control Policy in Impaired Gait”, *arXiv preprint arXiv:2604.09431*, 2026.
- [20] X. Tu, M. Li, M. Liu, J. Si y H. H. Huang, “A data-driven reinforcement learning solution framework for optimal and adaptive personalization of a hip exoskeleton”, en *2021 IEEE international conference on robotics and automation (ICRA)*, IEEE, 2021, págs. 10 610-10 616.
- [21] M. K. Klankers, A. Rudloff, P. Mohammadi et al., “Lessons learned from investigating robotics-based, human-like testing of an upper-body exoskeleton”, *Applied Sciences*, vol. 14, n.º 6, pág. 2481, 2024.
- [22] S. Luo, M. Jiang, S. Zhang et al., “Experiment-free exoskeleton assistance via learning in simulation”, *Nature*, vol. 630, n.º 8016, págs. 353-359, 2024.
- [23] J. Tobin, L. Biewald, R. Duan et al., “Domain randomization and generative models for robotic grasping”, en *2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, IEEE, 2018, págs. 3482-3489.
- [24] H. Barati, S. Kim, N. T. Xuan, J. Lee e Y. J. Park, “End-to-End Policy Learning for Hip Exoskeleton via Reinforcement Learning and Reflex-Based Musculoskeletal Simulation”, *IEEE Robotics and Automation Letters*, 2026.
- [25] G. Leem, J. Lee, J. Lee, S. Song y J. Won, “Exo-Plore: Exploring Exoskeleton Control Space through Human-aligned Simulation”, *arXiv preprint arXiv:2601.22550*, 2026.
- [26] L. Brunke, M. Greeff, A. W. Hall et al., “Safe learning in robotics: From learning-based control to safe reinforcement learning”, *Annual Review of Control, Robotics, and Autonomous Systems*, vol. 5, n.º 1, págs. 411-444, 2022.
- [27] J. Garcia y F. Fernández, “A comprehensive survey on safe reinforcement learning”, *Journal of Machine Learning Research*, vol. 16, n.º 1, págs. 1437-1480, 2015.
- [28] C. Glanois, P. Weng, M. Zimmer et al., “A survey on interpretable reinforcement learning”, *Machine Learning*, vol. 113, n.º 8, págs. 5847-5890, 2024.
- [29] *Anexo 22 Normativa EMA para el uso de IA en la fabricación de productos médicos*, [https://health.ec.europa.eu/document/download/5f38a92d-bb8e-4264-8898-ea076e926db6\\_en?filename=mp\\_vol4\\_chap4\\_annex22\\_consultation\\_guideline\\_en.pdf](https://health.ec.europa.eu/document/download/5f38a92d-bb8e-4264-8898-ea076e926db6_en?filename=mp_vol4_chap4_annex22_consultation_guideline_en.pdf) [Último acceso 14/junio/2026].
- [30] S. Gronauer y K. Diepold, “Multi-agent deep reinforcement learning: a survey”, *Artificial Intelligence Review*, vol. 55, n.º 2, págs. 895-943, 2022.

- [31] H. Kavianirad, M. Forouhar, H. Sadeghian, S. Endo, S. Haddadin y S. Hirche, “Model-based shared control of a hybrid FES-exoskeleton: An application in participant-specific robotic rehabilitation”, en *2023 International Conference on Rehabilitation Robotics (ICORR)*, IEEE, 2023, págs. 1-6.
- [32] T. Ma, Y. Zhang, S. D. Choi y S. Xiong, “Modelling for design and evaluation of industrial exoskeletons: A systematic review”, *Applied Ergonomics*, vol. 113, pág. 104100, 2023.
- [33] G. Nelson, A. Saunders, N. Neville et al., “Petman: A humanoid robot for testing chemical protective clothing”, *Journal of the Robotics Society of Japan*, vol. 30, n.º 4, págs. 372-377, 2012.
- [34] J. Bessler-Etten, L. Schaake, G. B. Prange-Lasonder y J. H. Buurke, “Assessing effects of exoskeleton misalignment on knee joint load during swing using an instrumented leg simulator”, *Journal of NeuroEngineering and Rehabilitation*, vol. 19, n.º 1, pág. 13, 2022.
- [35] M. Dežman, S. Massardi, D. Pinto-Fernandez et al., “A mechatronic leg replica to benchmark human–exoskeleton physical interactions”, *Bioinspiration & Biomimetics*, vol. 18, n.º 3, pág. 036009, 2023.
- [36] S. Massardi, D. Rodriguez-Cianca, M. Cenciarini et al., “Systematic evaluation of a knee exoskeleton misalignment compensation mechanism using a robotic dummy leg”, en *2023 International Conference on Rehabilitation Robotics (ICORR)*, IEEE, 2023, págs. 1-6.
- [37] R. L. McGrath, C. A. Price, W. B. Johnson y W. L. Childers, “Advancing Exoskeleton Development: Validation of a Robotic Surrogate to Measure Tibial Strain”, *Bioengineering*, vol. 11, n.º 5, pág. 490, 2024.
- [38] C. Nguiadem, M. Raison y S. Achiche, “A test bench for evaluating exoskeletons for upper limb rehabilitation”, *arXiv preprint arXiv:2112.14885*, 2021.
- [39] W. Habrah, “Robotic Phantom Knee and Digital Twin Platform for Early-Stage Exoskeleton Validation: Nonlinear Stiffness and Tuneable Soft-Tissue Compliance”, 2026.
- [40] D. Scherb, S. Wartzack y J. Miehl, “Modelling the interaction between wearable assistive devices and digital human models—A systematic review”, *Frontiers in bioengineering and biotechnology*, vol. 10, pág. 1044275, 2023.
- [41] S. Massardi, D. Rodriguez-Cianca, D. Pinto-Fernandez, J. C. Moreno, M. Lancini y D. Torricelli, “Characterization and evaluation of human–exoskeleton interaction dynamics: A review”, *Sensors*, vol. 22, n.º 11, pág. 3993, 2022.
- [42] D. Wang, X. Gu, W. Li, Y. Jin, M. Yang y H. Yu, “Evaluation of safety-related performance of wearable lower limb exoskeleton robot (WLLER): A systematic review”, *Robotics and Autonomous Systems*, vol. 160, pág. 104308, 2023.
- [43] R. Gassert y V. Dietz, “Rehabilitation robots for the treatment of sensorimotor deficits: a neurophysiological perspective”, *Journal of neuroengineering and rehabilitation*, vol. 15, n.º 1, pág. 46, 2018.
- [44] A. R. Manzoori, S. Messara, A. Di Russo, A. Ijspeert y M. Bouri, “Novel neuromuscular controllers with simplified muscle model and enhanced reflex modulation: A comparative study in hip exoskeletons”, *Wearable Technologies*, vol. 5, e21, 2024.
- [45] D. J. Saxby, B. A. Killen, C. Pizzolato et al., “Machine learning methods to support personalized neuromusculoskeletal modelling”, *Biomechanics and Modeling in Mechanobiology*, 2020.
- [46] M. J. Hambly, M. T. Worsey, D. G. Lloyd y C. Pizzolato, “Improving Calibration of EMG-Informed Neuromusculoskeletal Models Through Differentiable Physics and Muscle Synergies”, *IEEE Transactions on Biomedical Engineering*, 2025.

- [47] X. Zhang, S. Li, Z. Ying, L. Shu y N. Sugita, “Integrating musculoskeletal simulation and machine learning: a hybrid approach for personalized ankle-foot exoskeleton assistance strategies”, *Frontiers in Bioengineering and Biotechnology*, vol. 12, pág. 1442606, 2024.
- [48] L. Zhang, X. Zhang, X. Zhu, R. Wang y E. M. Gutierrez-Farewik, “Neuromusculoskeletal model-informed machine learning-based control of a knee exoskeleton with uncertainties quantification”, *Frontiers in neuroscience*, vol. 17, pág. 1254088, 2023.
- [49] A. Seth, J. L. Hicks, T. K. Uchida et al., “OpenSim: Simulating musculoskeletal dynamics and neuromuscular control to study human and animal movement”, *PLoS computational biology*, vol. 14, n.º 7, e1006223, 2018.
- [50] S. L. Delp, F. C. Anderson, A. S. Arnold et al., “OpenSim: open-source software to create and analyze dynamic simulations of movement”, *IEEE transactions on biomedical engineering*, vol. 54, n.º 11, págs. 1940-1950, 2007.
- [51] E. Todorov, T. Erez e Y. Tassa, “Mujoco: A physics engine for model-based control”, en *2012 IEEE/RSJ international conference on intelligent robots and systems*, IEEE, 2012, págs. 5026-5033.
- [52] T. Geijtenbeek, “Scone: Open source software for predictive simulation of biological motion”, *Journal of Open Source Software*, vol. 4, n.º 38, pág. 1421, 2019.
- [53] T. Geijtenbeek, “The Hyfydy simulation software”, URL: <https://hyfydy.com>, 2021.
- [54] Vídeo de modelo en el simulador Scone aprendiendo a correr. <https://x.com/i/status/1819082639799996862> [Último acceso 30/julio/2026].
- [55] S. Padmanabhan, K. Miyazawa, T. Horii y T. Nagai, “Data-Efficient Approach to Humanoid Control by Fine-Tuning a Pre-Trained GPT on Action Data”, *IEEE Access*, 2025.
- [56] I. Kyranou, S. Vijayakumar y M. S. Erden, “Causes of performance degradation in non-invasive electromyographic pattern recognition in upper limb prostheses”, *Frontiers in neurorobotics*, vol. 12, pág. 58, 2018.
- [57] N. Parajuli, N. Sreenivasan, P. Bifulco et al., “Real-time EMG based pattern recognition control for hand prostheses: A review on existing methods, challenges and future implementation”, *Sensors*, vol. 19, n.º 20, pág. 4596, 2019.
- [58] Repositorio de GitHub del modelo MIMo, <https://github.com/trieschlab/MIMo> [Último acceso 14/junio/2026].
- [59] J.-S. Yu, C. Zhuang, W.-X. Guo et al., “Reference values of gait parameters in healthy Chinese university students: A cross-sectional observational study”, *World Journal of Clinical Cases*, vol. 11, n.º 29, pág. 7061, 2023.
- [60] Motor AK60-6 usado en el proyecto. <https://www.mabrobotics.pl/product-page/ak60-6-v1-1-cubemars> [Último acceso 30/junio/2026].
- [61] Sitio web oficial de Zee Battery sobre la batería LiPo 3S 2200mAh 50C XT60, [https://zeebattery.com/products/zeee-3s-lipo-battery-2200mah-50c-xt60?\\_\\_pos=4&\\_sid=d8ace620c&\\_ss=r](https://zeebattery.com/products/zeee-3s-lipo-battery-2200mah-50c-xt60?__pos=4&_sid=d8ace620c&_ss=r) [Último acceso 14/junio/2026].
- [62] Motor AK80-9 usado en el proyecto. <https://www.mabrobotics.pl/product-page/ak80-9-cubemars-t-motor> [Último acceso 24/junio/2026].
- [63] Comparación de algoritmos de aprendizaje por refuerzo, <https://kindatechnical.com/reinforcement-learning/ppo-vs-sac-vs-td3-choosing-the-right-algorithm.html> [Último acceso 15/junio/2026].
- [64] I. Sommerville, “Software engineering 9th Edition”, *ISBN-10*, vol. 137035152, pág. 18, 2011.

- [65] *Beneficios de empresas basadas en servicios*. <https://bennettfinancials.com/what-profit-percentage-is-good-for-service-based-businesses> [Último acceso 30/julio/2026].



# Apéndice A

## Presupuesto

En el presente apéndice se detallan los precios aproximados de los materiales y recursos utilizados en el proyecto. Dicho presupuesto se puede desglosar en varias categorías distintas:

### 1. Recursos humanos

Incluye el tiempo y esfuerzo invertido por los miembros del equipo en el desarrollo del proyecto. Dado que este proyecto se ha realizado en colaboración con el grupo de investigación NAIR del CSIC, además del alumno, se ha contado con la supervisión y apoyo del tutor del proyecto en el grupo de investigación.

| Concepto         | Precio por hora (€) | Horas totales | Total (€) |
|------------------|---------------------|---------------|-----------|
| Alumno           | 15,00               | 350           | 5.250,00  |
| Supervisor       | 35,00               | 70            | 2.450,00  |
| Precio total (€) |                     |               | 7.700,00  |

Tabla A.1: Precio aproximado de los recursos humanos utilizados en el proyecto.

Se ha considerado un espacio de tiempo de 14 semanas, 5 horas diarias para el alumno y 1 hora para el supervisor. El precio por hora de ambos es aproximado.

### 2. Hardware

Incluye todos los componentes físicos necesarios para el desarrollo y funcionamiento del proyecto. Es importante tener en cuenta que los precios pueden variar dependiendo del proveedor, la región y la disponibilidad de los productos. Sólo se incluirán los precios de los materiales que no son gratis o estrictamente necesarios. Por otra parte, se asume que todo el hardware utilizado en el proyecto tiene una vida útil de 5 años, por lo que el precio total de los materiales se estima segun la ecuación (A.1).

$$\text{Precio total} = \sum_{i=1}^n (\text{Precio unidad}_i \times \text{N}^\circ \text{ unidades}_i) \times \frac{\text{Tiempo de uso del hardware}}{\text{Vida útil del hardware}} \quad (\text{A.1})$$

donde

- $n$  es el número total de materiales utilizados en el proyecto.
- $\text{Precio unidad}_i$  es el precio de una unidad del material  $i$ .
- $\text{N}^\circ \text{ unidades}_i$  es el número de unidades del material  $i$  utilizadas en el proyecto.

Sabiendo que el tiempo estimado del proyecto son 14 semanas, es decir, 98 días, y que el tiempo total de impresión de los materiales del dummy han sido 11 días, podemos calcular el preciototal del hardware utilizado en el proyecto.

| Nombre                            | Precio unidad (€) | Nº unidades | Vida útil (años) | Total (€)     |
|-----------------------------------|-------------------|-------------|------------------|---------------|
| Ordenador completo                | 800,00            | 1           | 3                | 71,80         |
| Actuador AK60-6 Cubemars          | 299,21            | 1           | 6                | 13,42         |
| Actuador AK80-9 Cubemars          | 537,38            | 2           | 6                | 48,22         |
| Dispositivo CANDle                | 99,00             | 1           | 4                | 6,66          |
| Baterías compatibles (2)          | 19,88             | 2           | 1                | 10,70         |
| Cable USB-C                       | 4,99              | 1           | 3                | 0,45          |
| Cable de conexión CANDle - AK80-9 | 5,00              | 2           | 3                | 0,89          |
| Cable de alimentación             | 5,00              | 1           | 3                | 0,45          |
| Impresora 3D                      | 1.000,00          | 1           | 5                | 6,04          |
| Dummy de pruebas                  | 185,04            | 1           | 2                | 24,91         |
| <b>Precio total (€)</b>           |                   |             |                  | <b>183,59</b> |

Tabla A.2: Precios aproximados de los materiales hardware utilizados en el proyecto.

### 3. Software

Incluye el software necesario para el desarrollo y funcionamiento del proyecto. En este caso, se ha utilizado una licencia de Hyfydy para la simulación del modelo musculoesquelético y el entrenamiento del agente de aprendizaje por refuerzo. El resto del software utilizado es de código abierto y no tiene un costo asociado.

| Nombre                       | Total (€)      |
|------------------------------|----------------|
| Licencia de Hyfydy (6 meses) | 2.500,00       |
| Visual Studio Code           | 0              |
| GitHub                       | 0              |
| Canva                        | 0              |
| <b>Precio total (€)</b>      | <b>2500,00</b> |

Tabla A.3: Precios aproximados de los materiales software utilizados en el proyecto.

### 4. Costes indirectos

En esta categoría se incluyen los gastos estructurales necesario para la realización del proyecto, como el alquiler de espacio de trabajo, mantenimiento de equipos y otros gastos generales. Según el libro *Software Engineering 9th Edition* de Ian Sommerville, los costes indirectos suelen representar entre el 20 % y el 30 % del coste total del proyecto para organizaciones con pocos costes indirectos [64]. En este caso, se ha considerado un 25 % del coste total del proyecto como costes indirectos.

$$\begin{aligned}
 \text{Costes indirectos} &= 0,25 \times (\text{Coste recursos humanos} + \text{Coste hardware} + \text{Coste software}) \\
 &= 0,25 \times (7.700,00 + 183,59 + 2.500,00) \\
 &= 2.595,90 \text{ €}
 \end{aligned} \tag{A.2}$$

## 5. Presupuesto total

A los precios anteriores hay que sumar el beneficio de la empresa, que suele ser entre el 15 % y el 30 % del coste total del proyecto en empresas enfocadas en servicios [65]. Por lo tanto, el coste total estimado del proyecto es:

| Nombre                            | Coste (€)        |
|-----------------------------------|------------------|
| Recursos humanos                  | 7.700,00         |
| Hardware                          | 183,59           |
| Software                          | 2.500,00         |
| Costes indirectos                 | 2.595,90         |
| Total                             | 12.979,49        |
| Beneficio de la empresa (20 %)    | 2.595,90         |
| Total con beneficio de la empresa | 15.575,39        |
| IVA (21 %)                        | 3.270,83         |
| <b>Coste total (€)</b>            | <b>18.846,22</b> |

Tabla A.4: Coste total aproximado del proyecto.



# Apéndice B

## Manual de despliegue

En este apéndice se describe el proceso de despliegue del trabajo desarrollado para un correcto funcionamiento del mismo. Se detallan los pasos a seguir para la instalación y configuración de los componentes necesarios, así como las instrucciones para ejecutar cada una de las partes.

### B.1 Descarga e instalación de dependencias

Para poder ejecutar el proyecto, es necesario contar con ciertas dependencias y herramientas software. En este proyecto se ha usado Conda, que es una herramienta de código abierto útil para la gestión de entornos y paquetes. Para descargar conda basta con ejecutar el siguiente comando en la terminal:

```
$ conda install anaconda::conda
```

Dado que se necesitan varias versiones distintas de bibliotecas para cada apartado del proyecto, se recomienda crear un entorno virtual para cada uno de ellos. Para ello, se puede usar el siguiente comando:

```
$ conda create -n nombre_entorno python=3.6.3
```

Pese a que la versión de Python es opcional en el comando, en el presente proyecto se han usado versiones distintas para cada entorno, por lo que se recomienda especificar la versión de Python a usar. Una vez creado el entorno, se debe activar con el siguiente comando:

```
$ conda activate nombre_entorno
```

Si todo está correcto, el prompt de la terminal debería cambiar para indicar que se ha activado el entorno virtual.

```
(nombre_entorno) $
```

Una vez activado el entorno virtual, se deben instalar las dependencias necesarias para ejecutar el proyecto. Para ello, se debe ejecutar el siguiente comando:

```
(nombre_entorno) $ pip install nombre_paquete==versión
```

Si se desea instalar varias dependencias a la vez, se pueden listar todas en el mismo comando, separadas por un espacio. Por ejemplo:

```
(nombre_entorno) $ pip install nombre_paquete1==versión nombre_paquete2==versión nombre_paquete3==versión
```

Para cerrar el entorno virtual, se debe ejecutar el siguiente comando:

```
(nombre_entorno) $ conda deactivate
```

A continuación se describen los diferentes entornos Conda utilizados en el proyecto, junto con las versiones utilizadas de las librerías más importantes para garantizar compatibilidad:

- Simulador MuJoCo con modelo MIMo:
  - Python 3.11.15
  - Gymnasium 0.29.1
  - MuJoCo 2.3.7
  - Numpy 2.0.2
- Entrenamiento del agente de aprendizaje por refuerzo:
  - Python 3.9.25
  - Gym 0.26.0
  - Gymnasium 0.29.1
  - Stable Baselines3 2.7.1
  - SconePy 0.2.0
  - Numpy 1.26.4

Además, se recomienda usar la versión de Scone 2.4.3.3209, que es compatible con la versión 0.2.0 de SconePy y la versión 1.26.4 de Numpy. Sin embargo, la versión 2.4.4 de Scone añade compatibilidad entre SconePy y Numpy 2, pero esto no ha sido probado en este proyecto, por lo que se recomienda usar las versiones mencionadas anteriormente para garantizar la compatibilidad y el correcto funcionamiento del sistema.

- Conexión con los actuadores AK80-9:
  - Python 3.12.13
  - Gymnasium 1.3.0
  - MuJoCo 3.3.0
  - Numpy 1.26.3
  - Stable Baselines3 2.9.0
  - pyCandleMAB 1.6.2

Es importante asegurarse de tener la versión de numpy 1.26.3 para garantizar la compatibilidad con todo el sistema, ya que al instalar Stable Baselines3 se instala automáticamente una versión moderna de numpy, que puede no ser compatible con la versión de pyCandleMAB. Las versiones descritas anteriormente han sido probadas y se ha verificado que funcionan correctamente en el proyecto.

- Interfaz gráfica de usuario (GUI) con Qt:
  - Python 3.10.19
  - Gymnasium 1.2.2
  - Numpy 2.2.6
  - PyQt6 6.4.2

Es necesario la instalación de ROS2. Para ello, se recomienda seguir las instrucciones de instalación de la página oficial de ROS2: <https://www.ros.org/>. En este proyecto se ha usado la versión Jazzy que es compatible con Ubuntu 22.04.

## B.2 Ejecución del proyecto

En cada uno de los apartados del proyecto, se debe activar el entorno virtual correspondiente y ejecutar el script principal de cada apartado. Es posible que los scripts permitan pasar argumentos por terminal, pero siempre serán opcionales a no ser que se indique lo contrario.

### B.2.1 Simulación del modelo MIMo en MUJoCo y transferencia a hardware

Para ejecutar la simulación del modelo MIMo en MuJoCo, se debe activar el entorno virtual correspondiente y debemos dirigirnos, desde la terminal, a la carpeta donde se encuentra el archivo `visualiza_standup_trajectory_tracking.py`. Una vez allí, se debe ejecutar el siguiente comando, siendo los argumentos opcionales en este caso:

```
(nombre_entorno1) $ python visualiza_standup_trajectory_tracking.py --argumento valor
```

Con esto se abrirá una ventana de visualización de la simulación del modelo MIMo en MuJoCo, donde se podrá observar el comportamiento del modelo al ejecutar la trayectoria de cadera. Junto con la ejecución, se guardará un archivo `.csv` con los datos de la ejecución en la carpeta `outputs/mimo/new_workflow/simulator/timestamp/`, donde `timestamp` es la fecha y hora de la ejecución.

Después de ejecutar la simulación, cambiaremos de entorno virtual para ejecutar el script de transferencia a hardware. En la misma carpeta ejecutaremos lo siguiente:

```
(nombre_entorno3) $ source /opt/ros/jazzy/setup.bash
(nombre_entorno3) $ python hip_motor_torque_replay_runner_pycandle.py
--source-csv ruta_a_archivo_csv_anterior/hip_tracking_telemetry.csv --apply-torque
```

Si se ha conectado correctamente el hardware, se ejecutará la trayectoria de cadera en los actuadores AK80-9, reproduciendo el comportamiento del modelo simulado. Junto con la ejecución, se guardará un archivo `.csv` con los datos de la ejecución en la carpeta `outputs/mimo/new_workflow/runner/timestamp_dual_pycandle-replay`.

### B.2.2 Entrenamiento e inferencia del agente de aprendizaje por refuerzo

Para llevar a cabo un entrenamiento del agente, se debe haber descargado previamente la aplicación Scone y tenerla instalada en el sistema. Después, nos dirigiremos a la carpeta donde se encuentra el archivo `entrenamiento.py`, activaremos el entorno virtual correspondiente y ejecutaremos el siguiente comando:

```
(nombre_entorno2) $ python entrenamiento.py --argumento valor
```

En este caso los argumentos también son opcionales. Si nos dirigimos a la carpeta `outputs/entrenamiento/timestamp/` encontraremos los resultados del entrenamiento realizado. Si se desean modificar los pesos de la función de recompensa, se pueden modificar la variable `DEFAULT_RW_DICT` en el archivo `nair_mimoEnv.py`.

Para ver los resultados del entrenamiento en el simulador Scone, bastará con abrir la aplicación y cargar el archivo `.sto` generado que se desee visualizar. En cambio, si se desea ejecutar la inferencia del agente entrenado en el dummy, activaremos el entorno virtual correspondiente y ejecutaremos el siguiente comando:

```
(nombre_entorno3) $ python inferencia.py --agent-path ruta_a_archivo/sac_mimo_final.zip
```

De nuevo, si se ha conectado correctamente el hardware, las caderas del dummy comenzarán a moverse siguiendo la política aprendida. Junto con la ejecución, se guardará un archivo `.csv` con los datos de la ejecución en la carpeta `outputs/inferencia/timestamp/`.

### B.2.3 Lanzamiento de la interfaz gráfica de usuario (GUI)

Para el lanzamiento de la GUI, se debe activar el entorno virtual correspondiente, nos dirigiremos a la carpeta donde se encuentra el archivo `launch_gui_completa.sh` y ejecutaremos los siguientes comandos:

```
(nombre_entorno4) $ source /opt/ros/jazzy/setup.bash
(nombre_entorno4) $ ./launch_gui_completa.sh
```

Se abrirá la interfaz gráfica, donde se podrá visualizar y ejecutar todo lo descrito anteriormente en el proyecto.

## Apéndice C

# Planificación temporal del proyecto

El siguiente diagrama de Gantt muestra la planificación temporal del proyecto, incluyendo las tareas principales y la duración estimada de cada una. El proyecto se ha dividido en 4 paquetes de trabajo diferenciados, cada uno con sus respectivas tareas. La duración total del proyecto se estima en 14 semanas, con un margen de flexibilidad para posibles retrasos o ajustes. La figura C.1 muestra el diagrama de Gantt del proyecto.

|         | Mes 1 |   |   |   | Mes 2 |   |   |   | Mes 3 |   |   |   | Mes 4 |   |   |   |
|---------|-------|---|---|---|-------|---|---|---|-------|---|---|---|-------|---|---|---|
| Semana  | 1     | 2 | 3 | 4 | 1     | 2 | 3 | 4 | 1     | 2 | 3 | 4 | 1     | 2 | 3 | 4 |
| Tarea 1 | ■     | ■ |   |   |       |   |   |   |       |   |   |   |       |   |   |   |
| Tarea 2 |       | ■ | ■ |   |       |   |   |   |       |   |   |   |       |   |   |   |
| Tarea 3 |       |   | ■ | ■ |       |   |   |   |       |   |   |   |       |   |   |   |
| Tarea 4 |       |   |   |   | ■     | ■ |   |   |       |   |   |   |       |   |   |   |
| Tarea 5 |       |   |   | ■ |       | ■ |   |   |       |   |   |   |       |   |   |   |
| Tarea 6 |       |   |   |   |       |   | ■ | ■ | ■     |   |   |   |       |   |   |   |
| Tarea 7 |       |   |   |   |       |   |   |   | ■     | ■ |   |   |       |   |   |   |
| Tarea 8 |       |   |   |   |       |   |   |   |       |   | ■ | ■ |       |   |   |   |
| Tarea 9 | ■     |   |   |   |       |   |   |   |       |   |   | ■ | ■     | ■ |   |   |

Figura C.1: Diagrama de Gantt del proyecto mostrando las tareas principales y la duración estimada de cada una.

A continuación se exponen los paquetes de trabajo y tareas principales del proyecto:

- **Paquete de trabajo 1: Investigación y análisis** (2 semanas)
  - Tarea 1: Revisión del estado del arte sobre exoesqueletos, control basado en inteligencia artificial y modelos musculoesqueléticos.
- **Paquete de trabajo 2: Control basado en modelos musculoesqueléticos** (5 semanas)
  - Tarea 2: Selección y diseño del modelo musculoesquelético adecuado para la simulación.
  - Tarea 3: Desarrollo de la arquitectura software en ROS2 para el control de motores reales.
  - Tarea 4: Validación del algoritmo desarrollado en el *dummy*.
  - Tarea 5: Desarrollo de la interfaz gráfica y el sistema de registro de datos.
- **Paquete de trabajo 3: Entrenamiento de la política de control de exoesqueletos** (4 semanas)

- Tarea 6: Desarrollo del algoritmo de aprendizaje por refuerzo para el entrenamiento de la política de control del exoesqueleto y entrenamiento.
- Tarea 7: Validación experimental del agente entrenado.
- **Paquete de trabajo 4: Análisis y documentación** (5 semanas)
  - Tarea 8: Análisis de los resultados obtenidos.
  - Tarea 9: Redacción de la memoria final del proyecto.





Universidad  
de Alcalá

2026